

Estimador Lineal de Menor Error Cuadrático Medio (LMMSE)

$$\hat{\mathbf{X}}_{lmmse} = \mu_{\mathbf{X}} + \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} (\mathbf{Y} - \mu_{\mathbf{Y}}). \quad (2)$$

Cuando \mathbf{X} e \mathbf{Y} son dos vectores conjuntamente gaussianos,

$$\hat{\mathbf{X}}_{lmmse} = \hat{\mathbf{X}}_{mmse}$$

$\hat{\mathbf{X}}_{lmmse}$ es un estimador *insesgado*. Se lo conoce también como el estimador BLU (Best Linear Unbiased).

$$\mathbb{E}[\hat{\mathbf{X}}_{lmmse}] = \mathbb{E}[\mu_{\mathbf{X}} + \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} (\mathbf{Y} - \mu_{\mathbf{Y}})] = \mu_{\mathbf{X}}$$

El error de estimación es:

$$\mathbf{E}_{lmmse} = \mathbf{X} - \hat{\mathbf{X}}_{lmmse} = \underbrace{(\mathbf{X} - \mu_{\mathbf{X}})}_{\delta_{\mathbf{X}}} - \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} \underbrace{(\mathbf{Y} - \mu_{\mathbf{Y}})}_{\delta_{\mathbf{Y}}}.$$

Su covarianza,

$$\begin{aligned} \mathbf{Cov}[\mathbf{E}_{lmmse}] &= \mathbf{Cov}[\mathbf{X} - \hat{\mathbf{X}}_{lmmse}] = \mathbb{E}[\mathbf{E}_{lmmse} \mathbf{E}_{lmmse}^*] \\ &= \mathbb{E} \left[\left(\delta_{\mathbf{X}} - \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} \delta_{\mathbf{Y}} \right) \left(\delta_{\mathbf{X}} - \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} \delta_{\mathbf{Y}} \right)^* \right] \\ &= \mathbb{E} [\delta_{\mathbf{X}} \delta_{\mathbf{X}}^*] - \mathbb{E} [\delta_{\mathbf{X}} \delta_{\mathbf{Y}}^*] \mathbf{C}_{\mathbf{Y}}^{-1} \mathbf{C}_{\mathbf{XY}}^* - \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} \mathbb{E} [\delta_{\mathbf{Y}} \delta_{\mathbf{X}}^*] \\ &\quad + \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} \mathbb{E} [\delta_{\mathbf{Y}} \delta_{\mathbf{Y}}^*] \mathbf{C}_{\mathbf{Y}}^{-1} \mathbf{C}_{\mathbf{XY}}^* \\ &= \mathbf{C}_{\mathbf{X}} - \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} \mathbf{C}_{\mathbf{YX}} \end{aligned}$$

Finalmente, el error cuadrático medio es

$$\begin{aligned} MMSE &= \mathbb{E} \left[\|\mathbf{E}_{lmmse}\|^2 \right] = \mathbb{E} [\mathbf{E}_{lmmse}^* \mathbf{E}_{lmmse}] \\ &= \mathbb{E} [\text{tr}(\mathbf{E}_{lmmse}^* \mathbf{E}_{lmmse})] = \mathbb{E} [\text{tr}(\mathbf{E}_{lmmse} \mathbf{E}_{lmmse}^*)] \\ &= \text{tr} \{ \mathbb{E} [\mathbf{E}_{lmmse} \mathbf{E}_{lmmse}^*] \} \\ &= \text{tr} \{ \mathbf{Cov}[\mathbf{E}_{lmmse}] \} \end{aligned}$$

$$\hat{\mathbf{X}}_{Immse} = \mu_{\mathbf{X}} + \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} \left(\mathbf{Y} - \mu_{\mathbf{Y}} \right).$$

$$\mathbb{E}[\hat{\mathbf{X}}_{Immse}] = \mu_{\mathbf{X}}.$$

$$\mathbf{Cov}[\mathsf{E}_{Immse}] = \mathbf{C}_{\mathbf{X}} - \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} \mathbf{C}_{\mathbf{YX}}.$$

$$MMSE = \text{tr}\left\{ \mathbf{C}_{\mathbf{X}} - \mathbf{C}_{\mathbf{XY}} \mathbf{C}_{\mathbf{Y}}^{-1} \mathbf{C}_{\mathbf{YX}} \right\}.$$

Ejercicio 1

Considere un proceso ESA en tiempo continuo $Y(t)$ de media nula y autocorrelación $R_Y(\tau) = e^{-|\tau|}$.

1. Halle el mejor estimador lineal en el sentido MSE de $X = \int_0^1 Y(t)dt$ utilizando las muestras $Y(0), Y(1)$ de Y .

2. Halle la varianza del error de estimación.

1. $\text{Voy a llamar } X = \underbrace{\int_0^1 Y(t)dt}_{\text{algo aleatorio}}$ al dominio transformado por comodidad, veamos si funciona

$$X_S = \frac{1}{S} \int_0^S Y(t)dt \quad \text{MSE}(\hat{X}) = E[\|X - \hat{X}\|^2] ; \quad \hat{X}_{\text{mmse}} = E[X|Y]$$

↓
El estimador

$$R_Y(\tau) = e^{-\tau} \mu(\tau) + e^{\tau} \mu(-\tau)$$

No es ruido blanco, claramente

$$\mu_1 = 0 \quad \therefore C_Y = R_Y \quad (\text{con } \tau = t_2 - t_1)$$

Busco el estimador lineal: $\hat{X} = g(Y) = AY + b$; minimizando por principio de ortogonalidad


$$E[X^* Y] = 0 \rightarrow X \perp Y ; \text{ queremos } \hat{X} \text{ ortogonal al error } X - \hat{X}_{\text{mmse}}$$

$$\rightarrow E[\hat{X}^* (X - \hat{X})] = 0 = E[(AY + B)^* (X - AY - B)] = 0$$

Se llega a que $A_{\text{mmse}} = [R_{XY} - \mu_X \mu_Y^*][R_Y - \mu_Y \mu_Y^*]^{-1} = C_{XY} C_Y^{-1}$

$$b_{\text{mmse}} = \mu_X - [R_{XY} - \mu_X \mu_Y^*][R_Y - \mu_Y \mu_Y^*]^{-1} \mu_Y = \mu_X - C_{XY} C_Y^{-1} \mu_Y$$

BIBO estable



$$A = C_{XY} C_Y^{-1}$$

$$\mu_X = \mu_Y \cdot H(0) = 0$$

$$b = 0$$

media nula

$$Y(0) \text{ e } Y(1)$$

vector de corr. cruzado

$$C_{XY} = E[X \cdot \underline{Y}] = R_{XY} = E[X \cdot \begin{bmatrix} Y(0) \\ Y(1) \end{bmatrix}] = \left[X Y(0) + X Y(1) \right] = E\left[Y(0) \int_0^t Y(t) dt + Y(1) \int_t^1 Y(t) dt\right]$$

Espero bien

$$= \left[\int_0^1 E[Y(0)Y(1)] dt \quad \int_0^1 E[Y(1)Y(t)] dt \right] = \left[\int_0^1 R(t) dt \quad \int_0^1 R(t-1) dt \right] = \left[\int_0^1 e^{-|t|} dt \quad \int_0^1 e^{-|t-1|} dt \right]$$

arroción

$$\left[\int_0^t e^{-|t|} dt \quad \int_0^{-|t-1|} e^{-|t|} dt \right] = \left[1 - e^{-1} \quad \frac{(e-1)}{e} \right]$$

$$C_{\gamma}^{-1} = E \left[(\gamma - \mu_{\gamma})(\gamma - \mu_{\gamma})^T \right] = \begin{pmatrix} E[\gamma(0)\gamma(0)] & E[\gamma(0)\gamma(1)] \\ E[\gamma(1)\gamma(0)] & E[\gamma(1)\gamma(1)] \end{pmatrix}^{-1} = \begin{pmatrix} R_{\gamma}(0) & R_{\gamma}(1) \\ R_{\gamma}(-1) & R_{\gamma}(0) \end{pmatrix}$$

$\gamma = \begin{pmatrix} \gamma(0) \\ \gamma(1) \end{pmatrix}$

$C_{\gamma} = R_{\gamma}$

$\mu_{\gamma} = 0$

$$= \begin{vmatrix} 1 & e^{-1} \\ e^{-1} & 1 \end{vmatrix} =$$

$$A = C_{\gamma} \cdot C_{\gamma}^{-1} = \left[1 - e^{-1} \quad \frac{(e-1)}{e} \right] \begin{vmatrix} \frac{1}{e^{2-1}} + 1 & \frac{-1}{2 \ln(e-1)} \\ \frac{-1}{2 \ln(e-1)} & \frac{e^2}{e^{2-1}} \end{vmatrix} = \begin{pmatrix} 0,462117 & 0,462117 \\ 0,462117 & 0,462117 \end{pmatrix}$$

$$\hat{x} = 0,462117 [\gamma(0) + \gamma(1)]$$

2.

$$\text{Error de estimación es } \varepsilon = x(n) - \hat{x}(n)$$

$$\text{Var}(\varepsilon) = E[(\varepsilon - \varepsilon_0)^2] = E[(x(n) - \hat{x}(n) - \mu_x + \mu_{\hat{x}})^2] = E[(x(n) - \hat{x}(n))^2]$$

↓

Lemmata es insesadu, lo $\mu_{\hat{x}} = \mu_x$; $\varepsilon_0 = 0$

$$E[x(n)^2 - 2x(n)\hat{x}(n) + \hat{x}(n)^2] = \text{Var}(x) - 2E[x\hat{x}(n)] + E[\hat{x}^2]$$

$$\text{Var}(\varepsilon) = \sigma_x^2 - 2 \cdot 0,462117 E[x\gamma(0) + x\gamma(1)] + 0,462117^2 E[(\gamma(0) + \gamma(1))^2]$$

$\int_0^1 R_{\gamma}(t)dt + \int_0^1 R_{\gamma}(t+1)dt$

$$\text{Var}(\varepsilon) = \sigma_x^2 - 1,16845 + 0,462117^2 (2R(0) + 2R(1))$$

$$\boxed{\text{Var}(\varepsilon) = \sigma_x^2 - 0,584223}$$

Ejercicio 2

Considere la medición ruidosa $Y = (1+V)X$ donde X y V son variables independientes y de media nula. Suponga que sólo conoce la varianza del ruido σ^2 . Halle el mejor estimador lineal en sentido MSE de X dada Y . Demuestre que la varianza del error es menor a la varianza de X .

$$Y = (1+V)X \quad ; \quad V \text{ ruido} \quad \sigma^2$$

$$\hat{X}_{\text{LMMSE}} = AY + B; \quad A = C_{X,Y} C_Y^{-1}$$

$$B = \mu_X - C_{X,Y} C_Y^{-1} \mu_Y$$

$$\begin{aligned} \mu_Y &= E[(1+V)X] \\ &= \mu_X + E[V \cdot X] \\ &= \mu_X = 0 \end{aligned}$$

↓
media nula

$$\hat{X}_{\text{LMMSE}} = C_{X,Y} C_Y^{-1} Y + \mu_X - C_{X,Y} C_Y^{-1} \mu_Y$$

$$\hat{X}_{\text{LMMSE}} = C_{X,Y} C_Y^{-1} (Y - \mu_Y) + \mu_X = C_{X,Y} C_Y^{-1} (Y - \mu_Y)$$

$$\mu_X = 0$$

consigne

$$\hat{X}_{\text{LMMSE}} = C_{X,Y} C_Y^{-1} Y$$

$$Y = X + Vx$$

$$C_{X,Y} = E[(X - \mu_X)(Y - \mu_Y)] = E[X \cdot (X + Vx)] = E[X \cdot X] + E[X(Vx)] = \sigma_x^2 + \sigma_v^2 \cdot \mu_v = \sigma_y^2$$

$$C_Y = E[Y \cdot Y] = E[(X + Vx)^2] = E[X^2 + 2X^2V + V^2X^2] = \sigma_x^2 + \sigma_v^2 \sigma_x^2 = \sigma_x^2(1 + \sigma_v^2)$$

$\underbrace{2E[X^2]}_{E[V]=0}$

$$\hat{X} = C_{X,Y} C_Y^{-1} Y = \frac{\sigma_x^2}{\sigma_x^2(1 + \sigma_v^2)} \frac{Y}{1 + \sigma_v^2}$$

$$\mathcal{E} = X - \hat{X} \rightarrow \text{Var}(\mathcal{E}) = E[(X - \hat{X}) - (\mu_X - \mu_{\hat{X}})^2]$$

\circ LMMSE es insensado
 $\therefore \mu_{\hat{X}} \rightarrow \mu_X$

$$E[X^2 - 2X\hat{X} + \hat{X}^2] = \sigma_x^2 - 2E\left[X \frac{Y}{1 + \sigma_v^2}\right] + E\left[\frac{Y^2}{(1 + \sigma_v^2)^2}\right] = \sigma_x^2 - \frac{2}{1 + \sigma_v^2} C_{X,Y} + \frac{C_Y}{(1 + \sigma_v^2)^2} \sigma_x^2$$

$$\text{Var}(\mathcal{E}) = \sigma_x^2 - \frac{2\sigma_x^2}{1 + \sigma_v^2} + \frac{\sigma_x^2}{(1 + \sigma_v^2)^2} = \sigma_x^2 - \frac{\sigma_x^2}{(1 + \sigma_v^2)^2} = \sigma_x^2 \left(1 - \frac{1}{1 + \sigma_v^2}\right)$$

$$\text{Como } \sigma_v^2 > 0 \rightarrow 1 - \frac{1}{1 + \sigma_v^2} < 1 \therefore \text{Var}(\mathcal{E}) < \sigma_x^2$$

Ejercicio 3

Se desea estimar una variable aleatoria X , para lo cual se utilizan 2 sensores que arrojan mediciones Y_1 e Y_2 .

$$Y_i = X + W_i, \quad i = 1, 2,$$

donde W_i son ruidos de los sensores. Se sabe que $\begin{bmatrix} X & W_1 & W_2 \end{bmatrix}^T$ es un vector Gaussiano de media nula y covarianza:

$$E \left[\begin{bmatrix} X & w_1 & w_2 \end{bmatrix} \right] = C = \begin{bmatrix} 1 & 1/2 & 1/4 \\ 1/2 & 1 & 0 \\ 1/4 & 0 & 1/3 \end{bmatrix}.$$

$\nearrow \text{Var}(x)$ $\nearrow C_{xw_1}$ $\nearrow C_{xw_2}$
 $\nearrow \text{Var}(w_1)$
 $\nearrow \text{Var}(w_2)$

Halle el mejor estimador de X basado en Y , la matriz de covarianza del error y su varianza.

$$\begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \begin{bmatrix} X \\ X \end{bmatrix} + \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}$$

$$E[(X w_1 w_2)^T] = \vec{0} \quad \therefore \mu_X = \mu_{w_1} = \mu_{w_2} = 0$$

$$\hat{X}_{\text{MLE}} = C_{xy} C_y^{-1} (Y_i - \mu_Y) + \mu_X$$

$$E[Y] = E[X + w_i] = \mu_X + \mu_{w_i} = \begin{cases} \mu_X + \mu_{w_1} \\ \mu_X + \mu_{w_2} \end{cases}$$

$$\hat{X} = C_{xy} C_y^{-1} Y_i = C_{xy} C_y^{-1} Y_i$$

$$= \vec{0} = \mu_Y$$

$$C_{xy} = E[X \cdot Y_i^T] = E[X \cdot \underbrace{\begin{bmatrix} X + w_1 \\ X + w_2 \end{bmatrix}^T}_{\text{media ruidos}}] = E \left[\begin{bmatrix} X^2 \\ X^2 \end{bmatrix} + \begin{bmatrix} X w_1 \\ X w_2 \end{bmatrix} \right] = E \left[\begin{bmatrix} X^2 \\ X^2 \end{bmatrix} \right] + E \left[\begin{bmatrix} X w_1 \\ X w_2 \end{bmatrix} \right]$$

$$E \left[\begin{bmatrix} X^2 \\ X^2 \end{bmatrix} \right] + E \left[\begin{bmatrix} X w_1 \\ X w_2 \end{bmatrix} \right] = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1/2 \\ 1/4 \end{bmatrix} + \begin{bmatrix} 1/2 \\ 1/4 \end{bmatrix} = \begin{bmatrix} 3/2 \\ 5/4 \end{bmatrix}$$

$\underbrace{\text{Var}(x)}$
 $(\mu_X = 0)$

R_{xw_i}
 $C_{xw_i} = \begin{pmatrix} \mu_X = 0 \\ \mu_{w_i} = 0 \end{pmatrix}$

los tenemos

$$Y_1 = X + w_1$$

$$Y_2 = X + w_2$$

$$C_y^{-1} = E[Y \cdot Y^T] = E \left[\begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} \begin{bmatrix} Y_1 & Y_2 \end{bmatrix} \right] = E \left[\begin{bmatrix} Y_1^2 & Y_1 Y_2 \\ Y_2 Y_1 & Y_2^2 \end{bmatrix} \right] = E \left[\begin{bmatrix} (X + w_1)^2 & (X + w_1)(X + w_2) \\ (X + w_1)(X + w_2) & (X + w_2)^2 \end{bmatrix} \right]$$

$$E[(X + w_1)^2] = \sigma_x^2 + \sigma_{w_1}^2 + 2C_{xw_1} = 1 + 1 + 2 \cdot 1/2 = 3$$

$$E[(X + w_2)^2] = \sigma_x^2 + \sigma_{w_2}^2 + 2C_{xw_2} = 1 + 1/8 + 3/4 = 1/6$$

$$E[(X + w_1)(X + w_2)] = \sigma_x^2 + C_{xw_1} + C_{xw_2} + C_{w_1 w_2} = 1 + 1/2 + 1/4 + 0 = 7/4$$

$$\therefore C_7^{-1} = \begin{vmatrix} 3 & 7/4 \\ 7/4 & 1/6 \end{vmatrix}^{-1} = \begin{vmatrix} 88/117 & -28/39 \\ -28/39 & 16/13 \end{vmatrix}$$

$$\hat{x} = \begin{vmatrix} 3/2 \\ 5/4 \end{vmatrix}^t \begin{vmatrix} 88/117 & -28/39 \\ -28/39 & 16/13 \end{vmatrix} \begin{vmatrix} y_1 \\ y_2 \end{vmatrix} = \boxed{\begin{vmatrix} 3/13 & 6/13 \\ 3/13 & 6/13 \end{vmatrix} \begin{vmatrix} y_1 \\ y_2 \end{vmatrix}} = \hat{x}$$

$C_{x_7} \quad C_7^{-1}$

$$e = x - \hat{x} \rightarrow \text{Cov}(e) = C_x - C_{x_7} C_7^{-1} C_{7x}$$

$$1 - \begin{vmatrix} 3/13 & 6/13 \\ 3/13 & 6/13 \end{vmatrix} \begin{vmatrix} 3/2 \\ 5/4 \end{vmatrix} = 1 - 12/13 = \boxed{1/13}$$

Since expanding \Rightarrow more,

Ejercicio 4

Suponga que se tienen muestras de una señal

$$Y(n) = X(n) + W(n), \quad n \in \mathbb{Z}.$$

Dicha señal tiene dos componentes: una señal de interés X , modelada como un proceso ESA, y una componente de ruido W , también modelada como un proceso ESA, descorrelacionado de X . Suponga que tiene acceso a muestras de un proceso ESA $U(n)$, $n \in \mathbb{Z}$, tal que dicha señal está descorrelacionada de W pero correlacionada con X . Asuma que todas las variables tienen media nula para simplificar el problema.

El objetivo del problema es eliminar la componente de ruido de $Y(n)$ utilizando las muestras de la señal $U(n)$. Para ello se propone estimar la señal Y mediante un estimador lineal de la forma:

$$\hat{Y}(n) = \mathbf{w}(n)^T \mathbf{u}(n),$$

donde $\mathbf{u}(n) = [U(n), \dots, U(n-N+1)]^T$ y $\mathbf{w}(n)$ es un vector (a determinar) de N elementos.

1. Analice la implementación del cancelador de ruido y realice un diagrama en bloques donde se vean las entradas del sistema y la señal de error:

$$e(n) = Y(n) - \hat{Y}(n).$$

2. Escriba la expresión $\mathbf{w}(n)$ óptimo para estimar Y en el sentido MSE y la varianza del error de estimación, mostrando que ninguno de los dos depende de n .
3. Determine por qué al estimar Y en realidad estamos obteniendo el mejor estimador MSE de X , lo que determina que el sistema funcione como un cancelador de ruido.
4. ¿Cómo implementaría el sistema en la práctica si tuviera acceso a las muestras de Y y de U ?

$$Y = X + W \quad ; \quad U \text{ ESA } \xrightarrow{\text{descorrel}} \text{correlacionado con } X \text{ pero no con } W.$$

~~$\mu_x = \mu_w = \mu_y = \mu_v = 0$~~

Queremos eliminar lo W de Y usando muestras de U .


$$\hat{Y}(n) = \beta(n)^T \mathbf{u}(n) \quad ; \quad \mathbf{u}(n) = [U(n) \ \dots \ U(n-N+1)]^T$$

↑ *cuefs del filtro*


Filtro de Wiener – Cancelador de ruido

Problema

- Medimos $x(n)$: señal $s(n)$ contaminada con ruido $v(n)$.
- Queremos limpiarla para obtener una estimación de $s(n)$
- Usamos un proceso $u(n)$ disponible (correlacionado con $v(n)$)



$$1. \hat{y}(n) = \sum_{i=0}^N \beta_i v(n-i) \quad (\text{Filtro de wiener})$$



$$2. U = \begin{bmatrix} v(0) \\ \vdots \\ v(N) \end{bmatrix} \quad \text{Como } n \in [0; N] \text{ es un problema de estimación.}$$

$$\text{Para cada } n \rightarrow \hat{y}_{\text{mse}} = C_{yv} C_v^{-1} (v - \mu_v) + \mu_y \quad ; \text{medias nulas}$$

Estime $y(n)$ con v de $(n-N) \rightarrow (0)$.

$$C_v^{-1} = R_v^{-1} = E \left[\begin{matrix} |v(-N)| & |v(-N) \dots v(0)| \\ |v(0)| & \ddots \end{matrix} \right] = \begin{vmatrix} R_v(0) & \dots & R_v(N) \\ \vdots & \ddots & \vdots \\ R_v(N) & \dots & R_v(0) \end{vmatrix}$$

$$C_{yv} = E[\gamma_{U(n)}] = E[R_{yv}(N) \dots R_{yv}(0)]$$

No depende de n , solo del h_o .

$$W = R_v^{-1} R_{yv}^* = \begin{bmatrix} w(N) \\ \vdots \\ w(0) \end{bmatrix} \longrightarrow \hat{y}(n) = \underbrace{R_{yv} R_v^{-1}}_W U.$$

\nwarrow conj. a trasp -

$$\hat{y} = \mu_y + C_{yv} C_v^{-1} (v - \mu_v) \rightarrow E[\hat{y}] = \underbrace{\mu_y}_{\text{cte nro } E} - C_{yv} C_v^{-1} \underbrace{(v - \mu_v)}_0$$

$$M_E = E[\hat{y} - \bar{y}] = \mu_y - \mu_y - C_{yv} C_v^{-1} \mu_v = 0 \quad \text{insensado}$$

$$C_{yy} = E[(\hat{y} - C_{yv} C_v^{-1} v)^* (\hat{y} - C_{yv} C_v^{-1} v)]$$

$$= \frac{E[yv^*] C_{yv}^* C_v^{-1}}{C_{yy}} - C_{yv} C_v^{-1} E[v y^*] + C_{yv} C_v^{-1} E[v v^*] C_v^{-1} C_{yv}^*$$

$$= C_y - C_{yv} C_v^{-1} C_{yy}$$


3) Se y cov $x \wedge y$ descorr w ; medias nulas:

$$\text{Entonces } \hat{y} = \mu_y + C_{yv} C_v^{-1} (v - \mu_v)$$

$$C_{yv} = \text{Cov}(y, v) = E[y \cdot v^*] = E[(x+w)v^*] = E[xv^*] + E[wv^*] = R_{x,v} + R_{w,v} = C_{x,v}$$

$$\therefore \hat{y} = C_{yv} C_v^{-1} v = C_{x,v} C_v^{-1} v \text{ separa } \hat{x} = C_{x,v} C_v^{-1} v$$

∴ Estimaremos lo x en \hat{y}



Ejercicio 5

Se desea estimar un vector aleatorio gaussiano $\mathbf{X} = [X_1, \dots, X_n]^T$ con media nula y matriz de correlación R_X . Para eso se realizan n mediciones Y_1, \dots, Y_n del siguiente modo:

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} = H\mathbf{X} + \mathbf{W},$$

donde H es una matriz de $n \times n$ determinística, conocida e inversible, y \mathbf{W} es un vector de ruido blanco gaussiano de media nula y varianza unitaria, descorrelacionado de \mathbf{X} .

1. Halle la función de densidad conjunta entre \mathbf{X} y \mathbf{Y} en términos de R_X y H .
2. Demuestre que el mejor estimador lineal en el sentido del ECM de \mathbf{X} en función de la observación \mathbf{Y} es:

$$\hat{\mathbf{X}} = R_X H^T (H R_X H^T + I)^{-1} \mathbf{Y}.$$

X y w gaussianos $\therefore Y$ gaussiana.

Vale que $E[Y] = E[H\mathbf{X}] + E[\mathbf{W}] = H\mu_{\mathbf{X}} + \mu_{\mathbf{W}} = 0$

$$C_Y = E[Y Y^*] = E[(H\mathbf{X} + \mathbf{W})(H\mathbf{X} + \mathbf{W})^*] = H C_X H^* + \mathbf{W} E[\mathbf{W}^*] H^* + H E[\mathbf{X} \mathbf{W}^*] + C_W$$

como \mathbf{X}, \mathbf{W} discr
eso vale cero

$$C_Y = H C_X H^* + C_W$$

Como $\mu_{\mathbf{X}} = 0$, $C_{XY}(t_1, t_2) = R_X(t_2 - t_1)$

$\mu_w = 0$


$$\rightarrow C_Y = H R_X H^* + R_W$$

La función de densidad jointe se puede obtener usando C_{XY} , lo medio de \mathbf{X} y \mathbf{Y} es cero \therefore lo medio de los cts es cero

$f_{x,y}(x,y) \rightarrow$ Para definirlo se captura recinto

$$\text{Sea } z = \begin{bmatrix} x \\ y \end{bmatrix} \rightarrow f_z \text{ es } f_{x,y}$$

$$E[z] = E\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} E[x] \\ E[y] \end{bmatrix} \stackrel{\text{vector}}{=} \begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$



que es en base al vector

$$z = \begin{bmatrix} x \\ y \end{bmatrix}$$

$$\text{Cov} = \begin{vmatrix} C_{x_1} & C_{x_1 x_2} & \cdots & C_{x_1 x_n} \\ C_{x_2 x_1} & \ddots & \ddots & \vdots \\ \vdots & & \ddots & C_{x_n x_n} \end{vmatrix} \rightarrow \begin{vmatrix} C_x & C_{x\gamma} \\ C_{\gamma x} & C_\gamma \end{vmatrix}$$

C_x es R_x $Hx+w$

$$C_\gamma = E[\gamma \gamma^*] = H \underbrace{E[x x^*] H^*}_{(M_\gamma=0)} + H \underbrace{E[x w^*]}_{\text{discuss}} + E[w x^*] H^* + E[w w^*]$$

Divide by γ Gauss.

$$\Rightarrow C_\gamma = H R_x H^* + I$$

$$C_{x\gamma} = E[x \gamma^*] = E[x x^*] H^* + E[\cancel{x w^*}] = R_x H^*$$

$$C_{\gamma x} = E[\gamma x^*] = H E[x x^*] + \cancel{E[w x^*]} = H R_x$$

$$\therefore \text{Cov}_z = \begin{vmatrix} C_x & C_{x\gamma} \\ C_{\gamma x} & C_\gamma \end{vmatrix} = \begin{vmatrix} R_x & R_x H^* \\ H R_x & H R_x H^* + I \end{vmatrix}$$

$$= \begin{vmatrix} I & 0 \\ 0 & H \end{vmatrix} \begin{vmatrix} R_x & R_x \\ R_x & R_x \end{vmatrix} \begin{vmatrix} I & 0 \\ 0 & H^* \end{vmatrix} + \begin{vmatrix} 0 & 0 \\ 0 & 1 \end{vmatrix}$$

$$\begin{matrix} \cancel{\begin{vmatrix} R_x & R_x \\ H R_x & H R_x \end{vmatrix}} & \begin{vmatrix} I & 0 \\ 0 & H^* \end{vmatrix} = \begin{vmatrix} R_x & R_x H^* \\ H R_x & H R_x H^* \end{vmatrix} \end{matrix}$$

$$2) \hat{X}_{\text{mse}} = C_{x\gamma} C_\gamma^{-1} \gamma = R_x H^* \cdot (H R_x H^* + I)^{-1} \gamma$$

ya los habíamos obtenido antes

Ejercicio 6

Se desea estimar la temperatura instantánea de una batería, para lo cual se dispone de un sensor que arroja muestras

$$Y(n) = T(n) + W(n), \quad (1)$$

donde $T(n)$ es la verdadera temperatura, un proceso Gaussiano ESA de media nula y autocovarianza $C_T(k) = \sigma_T^2 10^{-|k|}$, y W es ruido Gaussiano ESA de media nula y autocovarianza $C_W(k) = \sigma_W^2 10^{-|k|}$, descorrelacionado de T .

1. Indique qué clase de proceso es Y , si es ESA o no, y halle sus distribuciones finito-dimensionales.
2. Halle la distribución conjunta del vector $[T(n), Y(n)]$.
3. Suponga que se desea estimar la temperatura del siguiente modo:

$$\hat{T}(n) = aY^3(n) + bY(n) + c, \quad n \in \mathbb{Z}.$$

Halle los coeficientes a, b y c de modo de que $\hat{T}(n)$ sea el mejor estimador de $T(n)$ en el sentido del ECM. ¿Tiene sentido usar Y^3 en el estimador de T ? ¿Por qué?

4. Halle el ECM mínimo cuando $\sigma_W = \sigma_T = 1$.

1. Veamos si γ es ESA.

$$E[\gamma] = E[T + w] = \mu_T + \mu_w = 0 \quad (\text{cte})$$

$$R_\gamma = E[\gamma \gamma^*] = E[(T+w)(T+w)^*] = E[TT^* + TW^* + WT^* + WW^*] = R_T + R_W$$

$\underbrace{\qquad\qquad\qquad}_{=0 \text{ xque}} \quad w, T \text{ descor}$

Si T y w son ESA, R_T y R_W son fracc de los $\log \therefore R_\gamma$ depende de los

$\gamma \begin{cases} \text{Medio cte} \\ R_\gamma(n_2 - n_1) \end{cases} \therefore \gamma$ es ESA.

Distribuciones finito-dimensionales $\rightarrow T, w$ gaussianas $\therefore T + w \sim$ gaussiana

$$\Rightarrow \gamma \sim \text{Normal}(\mu_\gamma, C_\gamma)$$

Todos los distribuciones tienen $C_\gamma(n_1, n_2) \wedge \mu_\gamma(n) = 0 \forall n$

$$C_\gamma(n_1, n_2) = R_\gamma(n_1, n_2) = R_T(n_1, n_2) + R_W(n_1, n_2)$$

$\overbrace{R_\gamma(n_1, n_2)}^{=} = C_\gamma(n_1, n_2) + \mu_\gamma(n_1)\mu_\gamma(n_2)$

$$\text{Cor} = \begin{vmatrix} C_\gamma(n_1) & C_\gamma(n_1, n_2) \\ C_\gamma(n_2, n_1) & C_\gamma(n_2) \end{vmatrix}$$

$$\sigma_{\gamma}^2(n) = \text{Var}(\gamma(n)) = E[(\gamma(n))^2] = \sigma_T^2 + \sigma_w^2 \quad (\subset \gamma(0))$$

$$\text{Cov} = \begin{vmatrix} \sigma_T^2 + \sigma_w^2 & R_T(n_2-n_1) + R_w(n_2-n_1) \\ R_T(n_2-n_1) + R_w(n_2-n_1) & \sigma_T^2 + \sigma_w^2 \end{vmatrix} = \begin{vmatrix} \sigma_T^2 + \sigma_w^2 & \sigma_T^2 10^{-|T|} + \sigma_w^2 10^{-|T|} \\ \sigma_T^2 10^{-|T|} + \sigma_w^2 10^{-|T|} & \sigma_T^2 + \sigma_w^2 \end{vmatrix}$$

∴ la densidad conjunta para $\gamma(n_1), \gamma(n_2)$ es $\mathcal{N}(0, \begin{vmatrix} \sigma_T^2 + \sigma_w^2 & \sigma_T^2 10^{-|T|} + \sigma_w^2 10^{-|T|} \\ \sigma_T^2 10^{-|T|} + \sigma_w^2 10^{-|T|} & \sigma_T^2 + \sigma_w^2 \end{vmatrix})$

$$\gamma(n) \sim \mathcal{N}(0, \text{Var}(\gamma)) = \mathcal{N}(0, \sigma_T^2 + \sigma_w^2)$$

Distribución conjunta $\begin{bmatrix} T(n) & \gamma(n) \end{bmatrix}^t$

2 maneras: Escribo esto de forma matricial y obtengo la cov. o la hago fácil:

$$1) E[\begin{bmatrix} T \\ \gamma \end{bmatrix}] = \vec{0}$$

dual: solo despiense

2) fácil

$$\text{cov}[\begin{bmatrix} T \\ \gamma \end{bmatrix}] = \begin{bmatrix} C_T & C_{T\gamma} \\ C_{T\gamma} & C_\gamma \end{bmatrix}$$

$$= \begin{bmatrix} \sigma_T^2 & \sigma_T^2 \\ \sigma_T^2 & \sigma_T^2 + \sigma_w^2 \end{bmatrix} =$$

Varianzas

Naranjas de γ

$$E[\begin{bmatrix} T \\ \gamma \end{bmatrix}] = \vec{0}$$

$$C_T = \sigma_T^2 10^{-|T|}$$

$$\text{Mismo} \quad C_\gamma = (\sigma_T^2 + \sigma_w^2) 10^{-|T|}$$

$$\text{C}_{T\gamma} = E[\gamma \cdot T] = E[T T^* + w T^*] = R_T = C_T \quad |_{\gamma=0}$$

Cuidado

$$C_{T\gamma} = E[T \cdot \gamma^*] = E[T T^* + T w^*] = R_T = C_T \quad |_{\gamma=0}$$

$$\text{cov}_{T\gamma} = \begin{vmatrix} \sigma_T^2 10^{-|T|} & \sigma_T^2 10^{-|T|} \\ \sigma_T^2 10^{-|T|} & (\sigma_T^2 + \sigma_w^2) 10^{-|T|} \end{vmatrix} \quad |_{\gamma=0}$$

$$\text{cov}_{T\gamma} = \begin{vmatrix} \sigma_T^2 & \sigma_T^2 \\ \sigma_T^2 & \sigma_T^2 + \sigma_w^2 \end{vmatrix} \quad |_{T(n) \neq \gamma(n)}$$

$$3) \hat{T} = a \gamma^3(n) + b \gamma(n) + c$$

Si es lineal → linealizar por Taylor

$$\hat{T} = T(n) + (a \cdot 3 \gamma^2(n) + b) \gamma(n)$$

$$\hat{T} = \alpha \gamma(n) + \beta \rightarrow \text{ese es lineal}$$

γ^3 desaparece al linealizar, no tiene sentido usarlo

$$\hat{T}_{\text{lineal}} = C_{T\gamma} C_\gamma^{-1} (\gamma - \mu_\gamma) + \mu_T = E[T(n) \gamma^*(n)] .$$

$$C_\gamma^{-1}(n, n) = \text{Var}(\gamma) = \sigma_T^2 + \sigma_w^2$$

$$\frac{1}{\sigma_T^2 + \sigma_w^2} = \left[\frac{\sigma_T^2}{\sigma_T^2 + \sigma_w^2} \cdot \gamma = \frac{\hat{T}}{T} \right]$$

$$C_T(0, 0)$$

$$4. \quad \frac{1}{2} \gamma = \hat{T}$$

$$E_{\text{CM min}} \rightarrow E_{\text{CM}} = \left| T - \hat{T} \right|^2 = \left| T - \frac{1}{2} \gamma \right|^2 = E \left| T - \frac{T+w}{2} \right|^2$$

$$E \left| \frac{T-w}{2} \right|^2 = E \left[\left(\frac{T-w}{2} \right)^* \left(\frac{T-w}{2} \right) \right] = \frac{E}{4} [T^* T - w^* T - T^* w + w^* w]$$

Produtos interno

$$\frac{1}{4} \underbrace{\left(\sigma_T^2 + \sigma_w^2 \right)}_2 = \frac{2}{4} = \frac{1}{2}$$

$$\text{Sint que } \text{MMSE} = \text{tr} \left(\text{Cov}(E_{\text{MMSE}}) \right)$$

\downarrow_{min}

$$\text{Cov}_E = C_T - C_{T\gamma} C_\gamma^{-1} C_{\gamma T}$$

$$1 - 1 \cdot \frac{1}{2} \cdot 1 = \frac{1}{2}$$

$\boxed{\text{tr} \left\{ \frac{1}{2} \right\} = \frac{1}{2}}$