



Procesos estocásticos (86.09)

- Estimación lineal
- Filtro de Wiener
- Filtros adaptativos
- Problemas aplicados



Estimador lineal para procesos aleatorios

Estimador lineal para procesos aleatorios

Sean $X(n)$ e $Y(n)$ son procesos aleatorios conjuntamente ESA. Queremos un estimador lineal para inferir $X(n)$ a partir de observaciones de $Y(n)$.

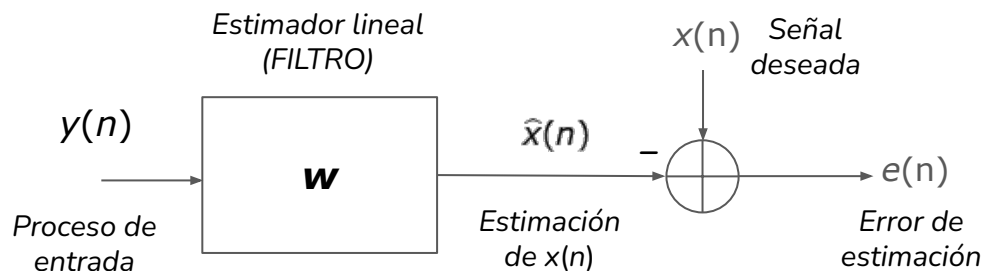
Si nos limitamos a estimadores de longitud finita, con coeficientes $\mathbf{w} = \{w_0, w_1, \dots, w_{M-1}\}$, podemos expresar el estimador como:

$$\hat{X}(n) = \sum_{i=0}^{M-1} w_i^* Y(n-i)$$

Filtro de Wiener

Filtro de Wiener

- $x(n)$ e $y(n)$ dos procesos CESA y de media nula
- \mathbf{w} un estimador lineal



Problema de optimización MMSE:

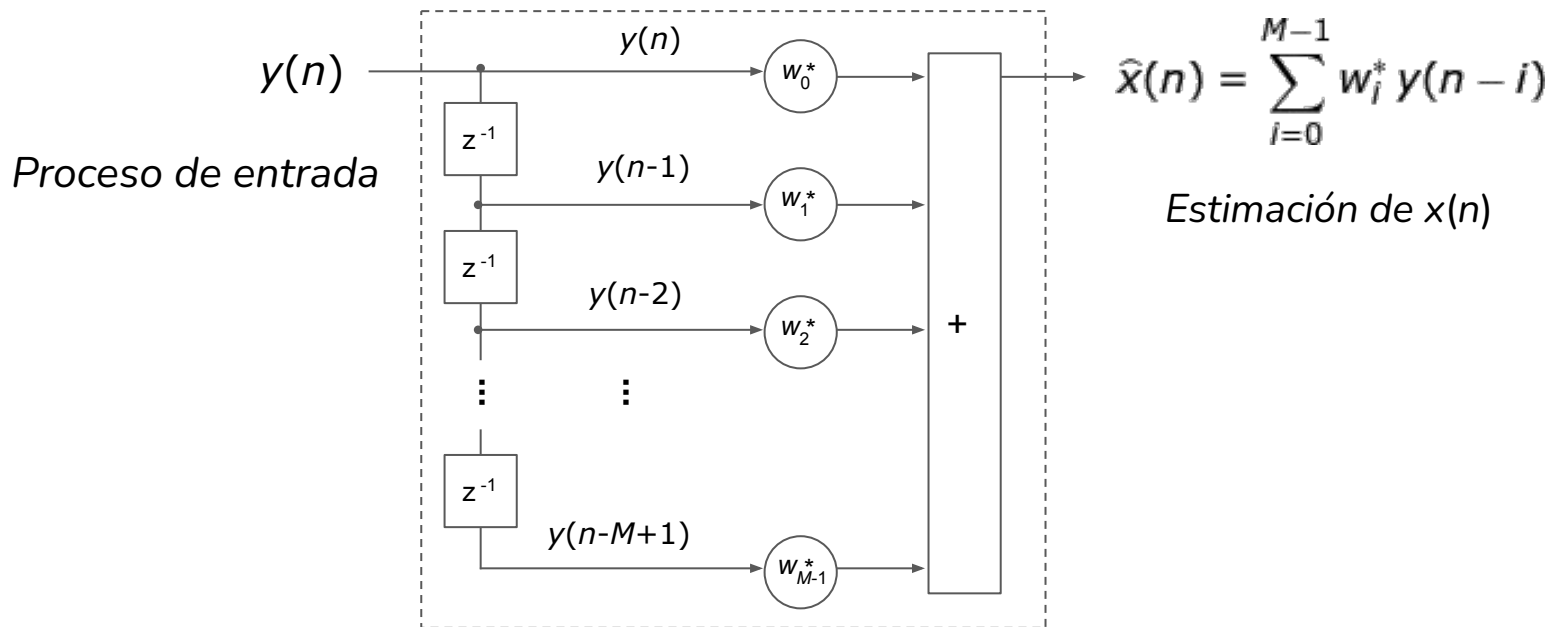
Encontrar los coeficientes $\mathbf{w} = \{w_0, w_1, \dots, w_{M-1}\}$ que minimizan la **potencia del error** $J(\mathbf{w})$:

$$J(\mathbf{w}) = E[|e(n)|^2] \rightarrow J_{\min}$$

donde $e(n) = x(n) - \hat{x}(n)$ es el error de estimación

Filtro de Wiener – Para un único proceso de entrada

Filtro de Wiener de M coeficientes



Filtro de Wiener – Notación


Estimador del filtro de Wiener FIR de largo M

$$\hat{x}(n) = \sum_{i=0}^{M-1} w_i^* y(n-i)$$

Expresión vectorial

$$\hat{x}(n) = \underbrace{\begin{bmatrix} w_0^* & w_1^* & \dots & w_{M-1}^* \end{bmatrix}}_{\mathbf{w}^H} \underbrace{\begin{bmatrix} y(n) \\ y(n-1) \\ \vdots \\ y(n-M+1) \end{bmatrix}}_{\mathbf{y}(n)} = \mathbf{w}^H \mathbf{y}(n)$$

H: hermítico (transpuesto conjugado)



Filtro de Wiener – Notación

Vector de correlación cruzada
entre $\mathbf{y}(n)$ y $x(n)$

$$\mathbf{R}_{yx} = \mathbf{R}_{xy}^H = E[\mathbf{y}(n)x(n)^*]$$

$$\mathbf{R}_{yx} = \begin{pmatrix} R_{yx}(0) \\ R_{yx}(1) \\ \vdots \\ R_{yx}(M-1) \end{pmatrix}$$

Matriz de autocorrelación de $\mathbf{y}(n)$

$$\mathbf{R}_y = E[\mathbf{y}(n)\mathbf{y}(n)^H]$$

$$\mathbf{R}_y = \begin{pmatrix} R_y(0) & R_y(1)^* & \dots & R_y(M-1)^* \\ R_y(1) & R_y(0) & \dots & R_y(M-2)^* \\ \vdots & \vdots & & \vdots \\ R_y(M-1) & R_y(M-2) & \dots & R_y(0) \end{pmatrix}$$

Filtro de Wiener

Potencia del error

$$J(\mathbf{w}) = \sigma_x^2 - \mathbf{R}_{yx}^H \mathbf{w} - \mathbf{w}^H \mathbf{R}_{yx} + \mathbf{w}^H \mathbf{R}_y \mathbf{w}$$

Coeficientes \mathbf{w} óptimos de Wiener (\mathbf{w}_o) que minimizan $J(\mathbf{w})$ (MMSE)

$$\mathbf{w}_o = \mathbf{R}_y^{-1} \mathbf{R}_{yx}$$


Filtro de Wiener – Cálculo de los coeficientes óptimos

Potencia del error

$$J(\mathbf{w}) = \sigma_x^2 - \mathbf{R}_{yx}^H \mathbf{w} - \mathbf{w}^H \mathbf{R}_{yx} + \mathbf{w}^H \mathbf{R}_y \mathbf{w}$$

Coeficientes óptimos del
filtro de Wiener FIR

$$\mathbf{w}_o = \mathbf{R}_y^{-1} \mathbf{R}_{yx}$$



Steepest descent

Steepest descent

- Resuelve el Filtro de Wiener de forma iterativa:


$$\mathbf{w}_{n+1} = \mathbf{w}_n - \frac{1}{2}\mu \nabla J(\mathbf{w}_n) \quad ; \quad \mathbf{w}_{inicial}$$

- Gradiente determinístico

$$\nabla J(\mathbf{w}_n) = -2(\mathbf{R}_{yx} - \mathbf{R}_y \mathbf{w}_n)$$

- Se requiere conocer \mathbf{R}_y y \mathbf{R}_{yx}

- Para $n \rightarrow \infty$: $\mathbf{w} \rightarrow \mathbf{w}_0 = \mathbf{R}_y^{-1} \mathbf{R}_{yx}$




Least Mean Square (LMS)

Least Mean Square (LMS)

Steepest descent

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \frac{1}{2}\mu \nabla J(\mathbf{w}_n)$$



Aproximación
del gradiente

Algoritmo LMS

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \mu \mathbf{y}(n)e(n)^*$$

Least Mean Square (LMS)

Algoritmo LMS

- $\mathbf{w}(0) = \mathbf{w}_{\text{INICIAL}}$
- Repetir desde $n = 0$
 - $\mathbf{y}(n) = [y(n) \ y(n-1) \ \dots \ y(n-M+1)]^T$
 - $e(n) = x(n) - \mathbf{w}(n)^H \mathbf{y}(n)$
 - $\mathbf{w}(n+1) = \mathbf{w}(n) + \mu \mathbf{y}(n)e(n)^*$

Hay que tener en cuenta que para representar las primeras componentes de $y(n)$ (que tendrán índices negativos) hay que interpretar donde comienza el instante 0 en esa realización.

M samples?

$$\underbrace{\quad}_{\text{M samples?}} y = [2 \ 1 \ 1 \ 6 \ 2 \ 3 \ 5 \ 3 \ 4 \ \dots]$$

↑
n = 0

Least Mean Square (LMS)

Algoritmo LMS

- $\mathbf{w}(0) = \mathbf{w}_{\text{INICIAL}}$
- Repetir desde $n = M$ hasta $N-1$
 - $\mathbf{y}(n) = [y(n) \ y(n-1) \ \dots \ y(n-M+1)]^T$
 - $e(n) = x(n) - \mathbf{w}(n)^H \mathbf{y}(n)$
 - $\mathbf{w}(n+1) = \mathbf{w}(n) + \mu \mathbf{y}(n)e(n)^*$

Para una realización de largo N ,
dado un filtro de largo M , podemos
arrancar la iteración desde $n = M$



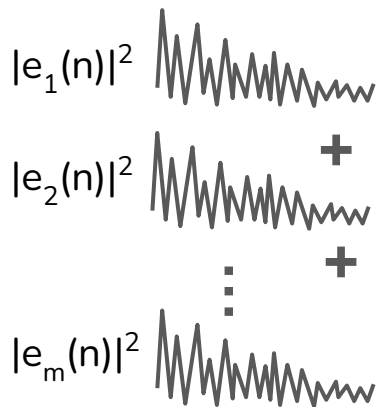
$$y = [2 \ 1 \ 1 \ 6 \ 2 \ 3 \ 5 \ 3 \ 4 \ \dots]$$

$n = M$: índice inicial

Least Mean Square (LMS) - Curva de aprendizaje

Es una estimación de la función costo J en función de las iteraciones. Donde i es una realización en particular, m son las realizaciones totales y $e_i(n)$ el error de estimación para la i -ésima realización,

$$e_i(n) = x_i(n) - \hat{x}_i(n)$$



Aplicaciones típicas

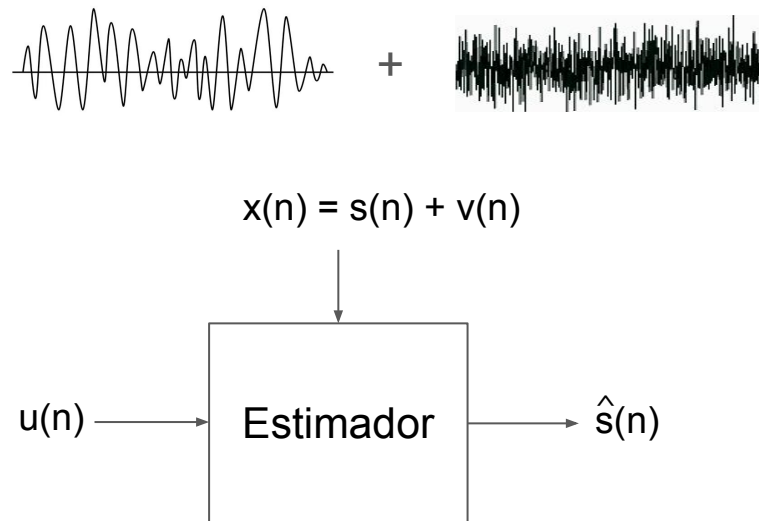
Filtro de Wiener – Aplicaciones típicas

- Cancelación de ruido
- Cancelación de interferencias
- Ecualizador
- Identificador de un sistema

Filtro de Wiener – Cancelador de ruido

Problema

- Medimos $x(n)$: señal $s(n)$ contaminada con ruido $v(n)$.
- Queremos limpiarla para obtener una estimación de $s(n)$
- Usamos un proceso $u(n)$ disponible (correlacionado con $v(n)$)



Filtro de Wiener – Cancelador de ruido

$s(n)$: proceso de interés

$v(n)$: ruido (blanco, AR, MA)

$u(n)$: proceso CESA con $v(n)$

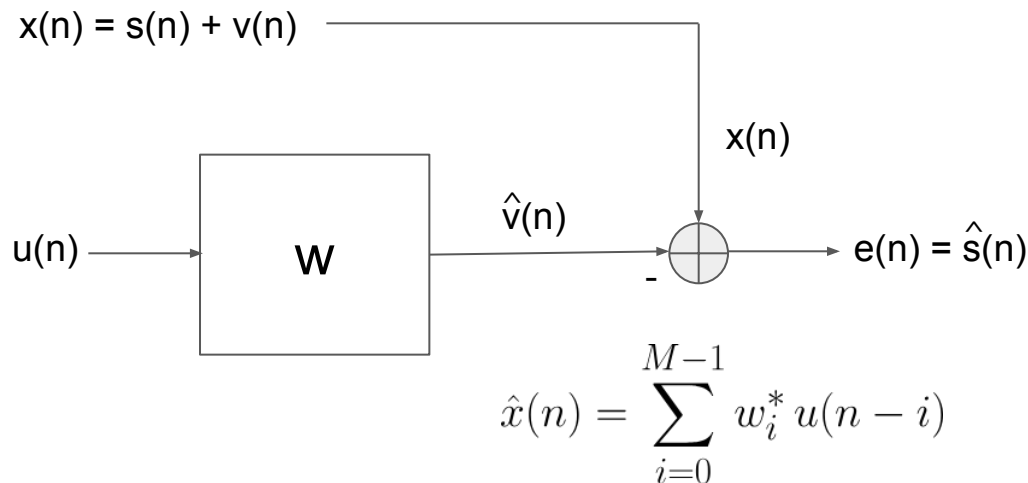
$e(n)$: estimación de $s(n)$

$\hat{x}(n)$: estimación de $v(n)$

Hipótesis

$$E[u(n-k)s^*(n)] = 0$$

$$E[u(n-k)v^*(n)] \neq 0$$




En este problema, $J(n) = \sigma_s^2 + K(n)$ converge a la potencia de señal $s(n)$ (dado que $e(n)$ estima $s(n)$)
mas la potencia de error sobre $s(n)$: $K(n) = E[|s(n) - s_{\text{est}}(n)|^2]$

Filtro de Wiener – Cancelador de interferencias

Problema

- Medimos $x(n)$: señal $s(n)$ contaminada con un proceso de banda angosta (senoidal) $g(n)$.
- Queremos limpiarla para obtener una estimación de $s(n)$
- Usamos un proceso $u(n)$ disponible (correlacionado con $g(n)$)



Filtro de Wiener – Cancelador de interferencias (1)

$s(n)$: proceso de interés

$g(n)$: interferencia

$u(n)$: proceso CESA con $g(n)$

$e(n)$: estimación de $s(n)$

$\hat{x}(n)$: estimación de $g(n)$

Hipótesis

$$E[u(n-k)s^*(n)] = 0$$

$$E[u(n-k)g^*(n)] \neq 0$$


En este problema, también $e(n)$ estima $s(n)$

Entonces podemos considerar nuevamente el error $K(n) = E(|s(n) - s_{\text{est}}(n)|^2)$

Modelo de la interferencia:

$$g(n) = A \cos(\omega_0 n + \theta) \quad (A \text{ y } \theta \text{ VAs})$$

$$x(n) = s(n) + g(n)$$



Filtro de Wiener – Cancelador de interferencias (2)

$s(n)$: proceso de interés

$g(n)$: interferencia

$u_i(n)$: proceso CESA con $g(n)$

$e(n)$: estimación de $s(n)$

$\hat{x}(n)$: estimación de $g(n)$

Hipótesis

$$E[u_0(n-k)s^*(n)] = 0$$

$$E[u_1(n-k)s^*(n)] = 0$$

$$E[u_0(n-k)g^*(n)] \neq 0$$

$$E[u_1(n-k)g^*(n)] \neq 0$$

Modelo de la interferencia:


$$g(n) = A \cos(\omega_0 n + \theta) = A \cos(\theta) \cos(\omega_0 n) + A \sin(\theta) \sin(\omega_0 n)$$

$$x(n) = s(n) + g(n)$$

Entradas

$$u_0(n) = \sin(\omega_0 n)$$

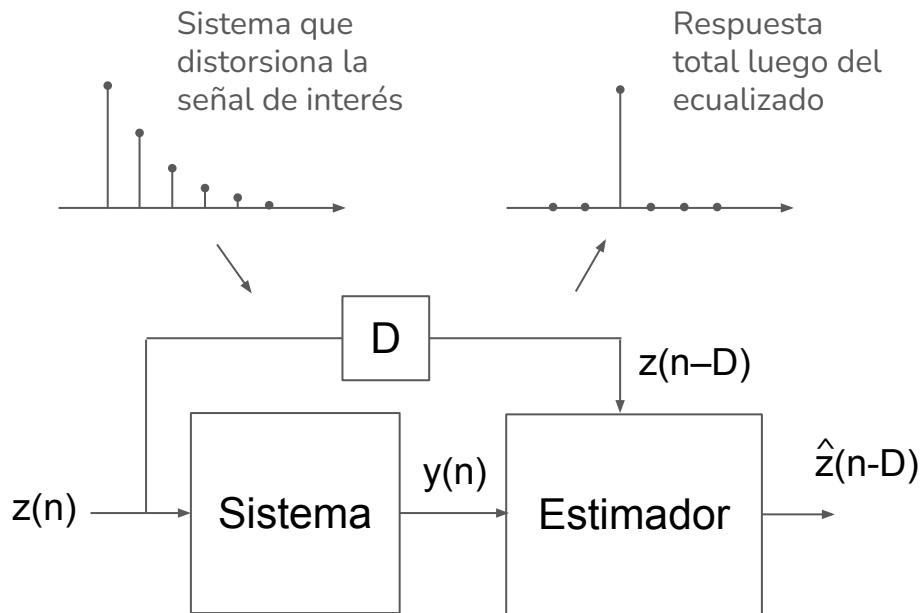
$$u_1(n) = \cos(\omega_0 n)$$



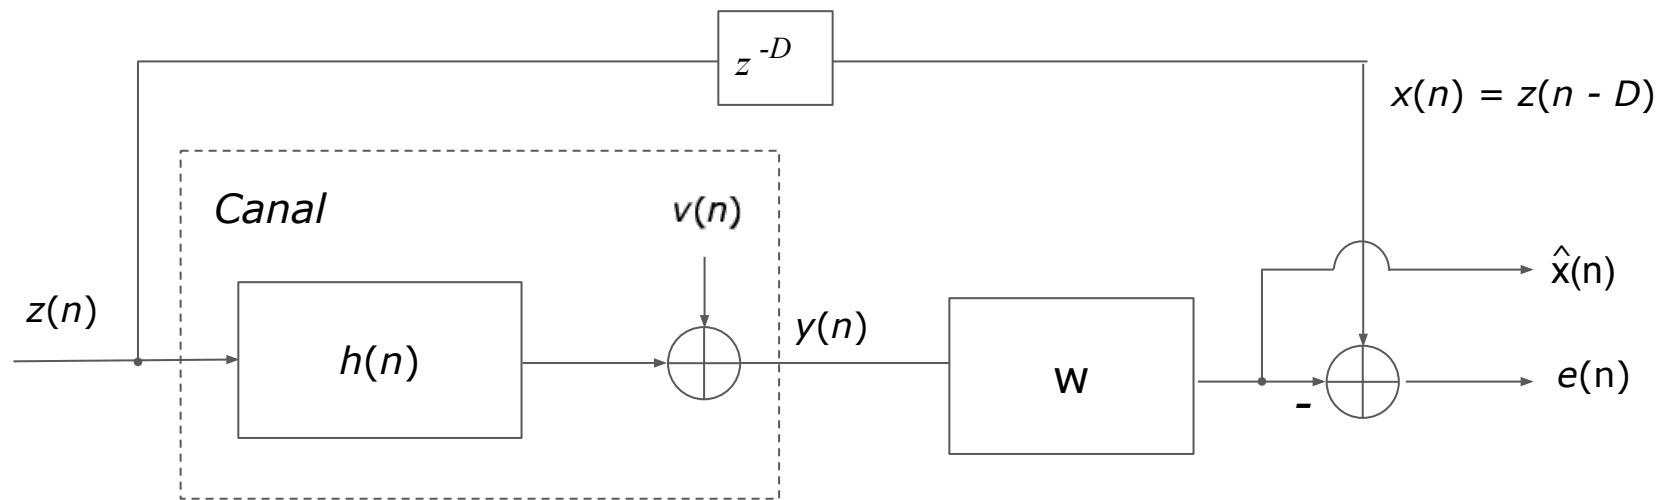
Filtro de Wiener – Ecualizador

Problema

- Medimos $y(n)$: proceso distorsionado por un sistema LTI $h(n)$ más ruido $v(n)$.
- Queremos compensar la distorsión del canal para obtener una estimación de $z(n)$.
- Usamos la salida $y(n)$ del sistema y una versión desplazada de $z(n-D)$ en una fase de entrenamiento para obtener el filtro óptimo



Filtro de Wiener – Ecualizador



$z(n)$: proceso de interés
 $v(n)$: ruido blanco
 $y(n)$: proceso CESA con $z(n)$
 $e(n)$: estimación de $s(n)$
 $\hat{x}(n)$: estimación de $z(n)$

$h(n)$: sistema LTI FIR
 D : retardo ajustable

Hipótesis

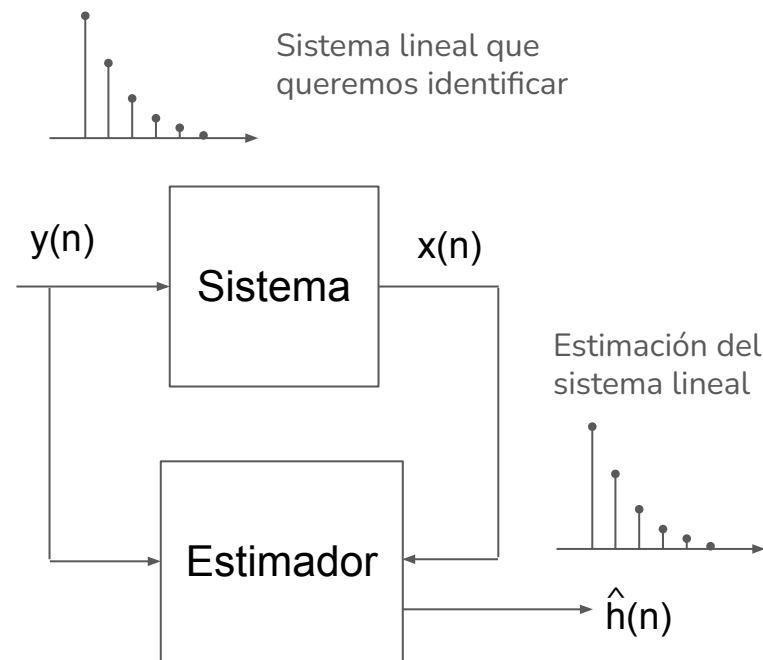
$$E[y(n-k)v^*(n)] = 0$$

$$E[y(n-k)x^*(n)] \neq 0$$

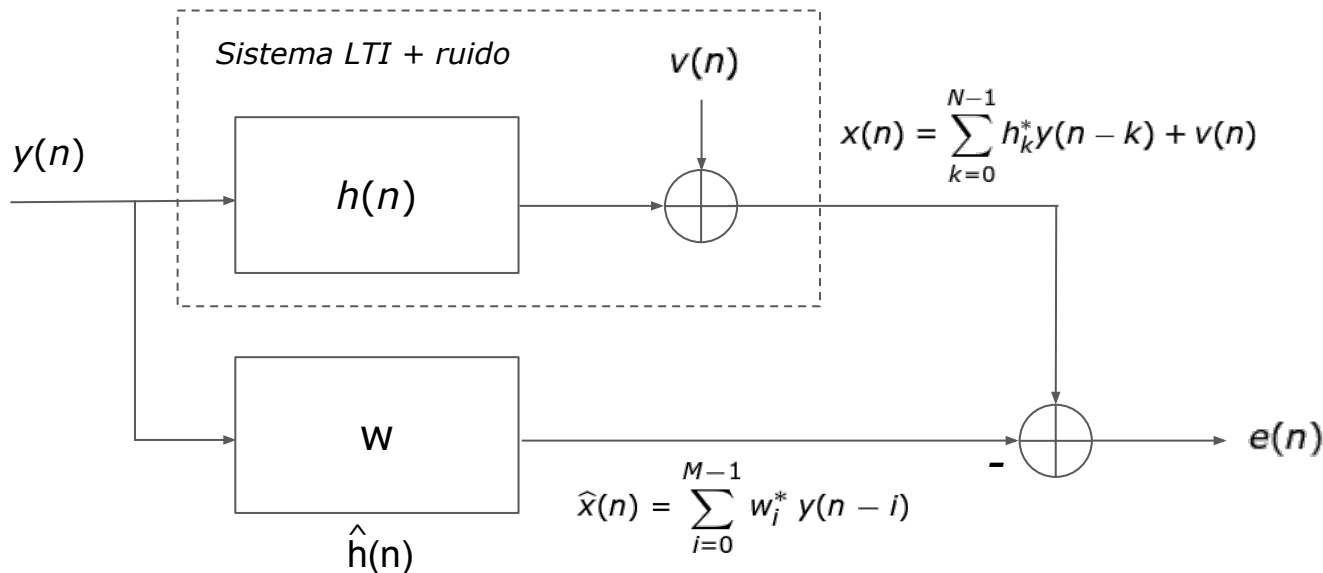
Filtro de Wiener – Identificación de un sistema LTI

Problema

- Medimos $x(n)$: proceso de salida de un sistema LTI $h(n)$ más ruido $v(n)$.
- Queremos estimar los coeficientes del sistema, $h(n)$.
- Usamos un proceso de referencia para excitar tanto el sistema LTI como el filtro de Wiener



Identificación de un sistema LTI



$h(n)$: sistema LTI de interés

$v(n)$: ruido blanco

$y(n)$: proceso de referencia

$e(n)$: estimación de $s(n)$

$w_0(n)$: estimación de $h(n)$

$\hat{x}(n)$: estimación de $x(n)$

Hipótesis

$$E[y(n-k)v^*(n)] = 0$$

$$E[y(n-k)x^*(n)] \neq 0$$


Actividad 1

Actividad 1

Se requieren estimar los coeficientes \mathbf{w} de un filtro LMS cuya entrada es una secuencia $y(n)$, de modo tal que su salida se ajuste lo mejor posible a una señal deseada $x(n)$. Para generar los procesos $x(n)$ e $y(n)$ considere que éstos pueden obtenerse como:

$$y(n) = f(n) + 0.5 f(n-1) + 0.25 f(n-2)$$

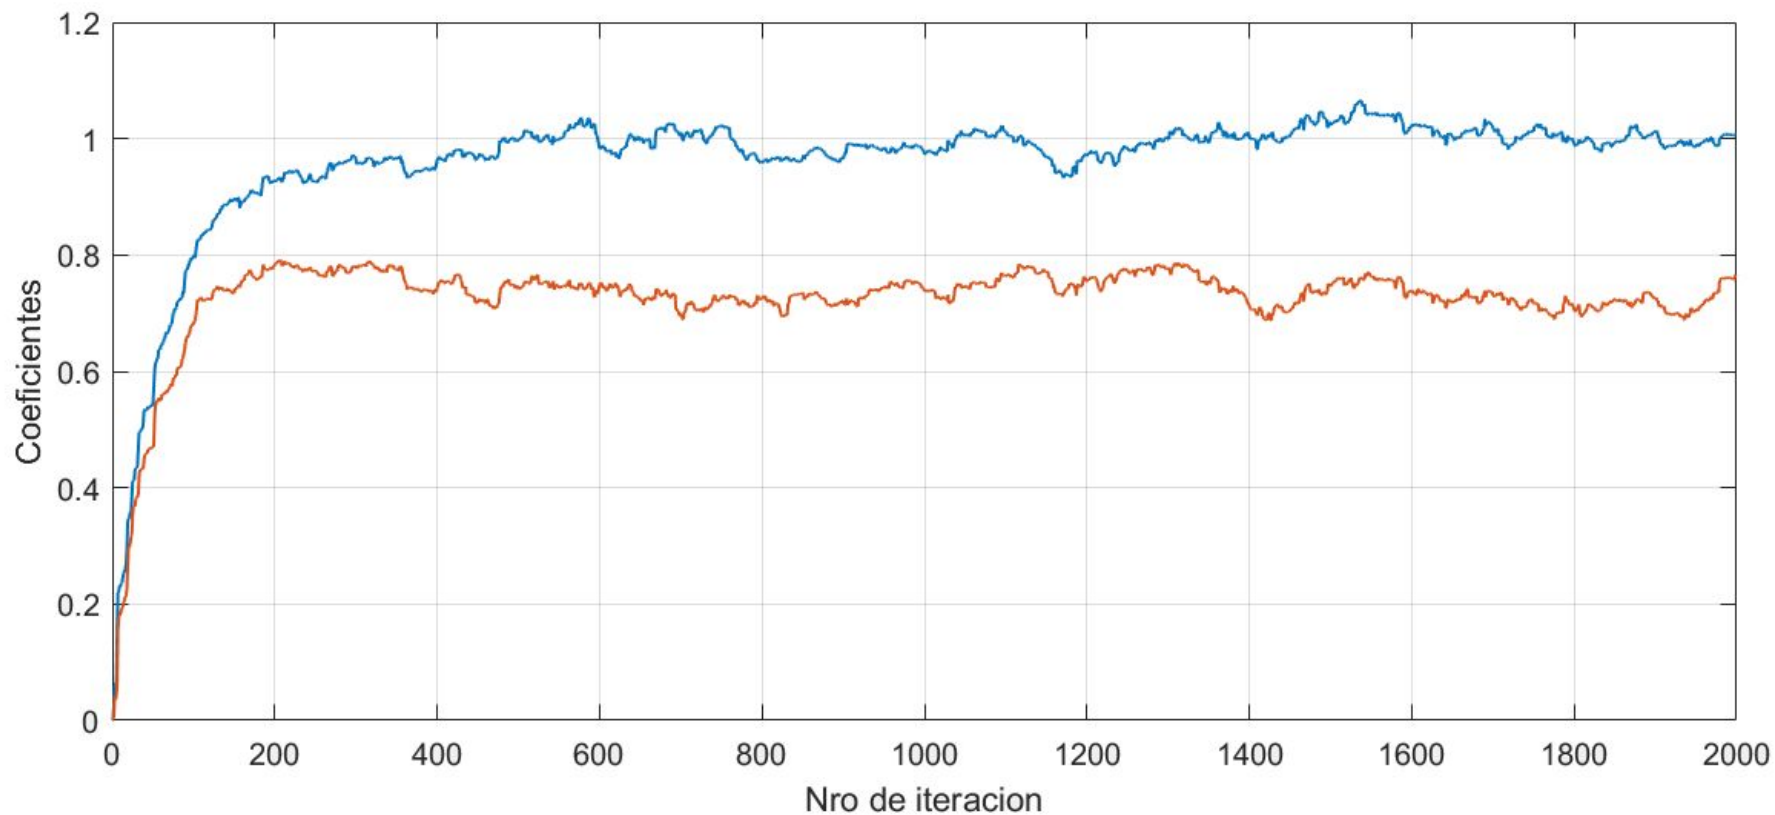
$$x(n) = f(n) + 1.2 f(n-1) + 0.6 f(n-2) + 0.3 f(n-3) + v(n)$$




donde $f(n) \sim N(0,1)$ y $v(n) \sim N(0, 0.1)$, ambos de largo $L = 2000$ e independientes

1. Implemente el filtro LMS (con $\mathbf{w}(0) = \mathbf{0}$) y obtenga los coeficientes \mathbf{w} para un largo $M = 2$ y $\mu = 0.01$, de modo tal que la salida del filtro sea una estimación del proceso $x(n)$.
2. Grafique los coeficientes \mathbf{w}_n acumulados en función de las iteraciones (para una realización). Luego simule 200 realizaciones y grafique la curva de aprendizaje $J(n)$ obtenida como promedio de todas las realizaciones.

Actividad 1



Actividad 1



Actividad 2


Actividad 2

Para el mismo problema de la actividad anterior, grafique la curvas de aprendizaje $J(n)$, con 200 realizaciones, para distintos pasos:

1. $\mu = 0.01$
2. $\mu = 0.1$

Los gráficos deben estar en escala logarítmica y superpuestos para comparar los tres casos.

Actividad 2



Actividad 3

Actividad 3

Considere el problema de la actividad 1. Para una única realización, grafique en un plano (w_0, w_1) la trayectoria de los pesos (w_1 vs w_0). También grafique ambos pesos en función de las iteraciones. Considere $\mu = 0.01$ y las siguientes condiciones iniciales:

a. $\mathbf{w}_0 = [-3.19 \ 4.47]^T$


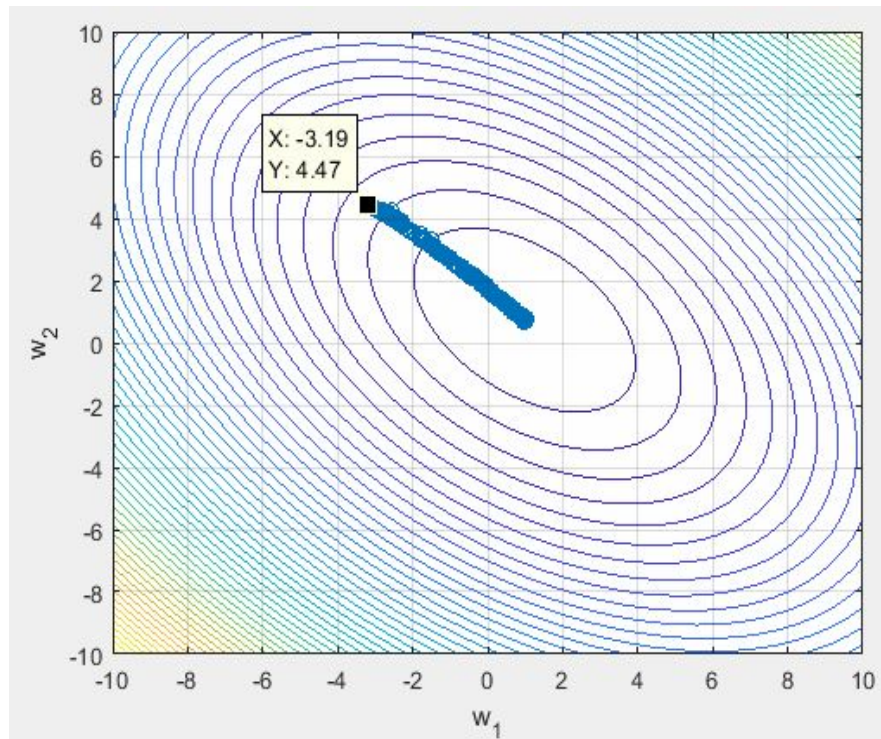
b. $\mathbf{w}_0 = [4.84 \ 4.52]^T$

c. $\mathbf{w}_0 = [1.65 \ 8.99]^T$

Ayuda: para los gráficos en el plano (w_0, w_1) defina los límites **axis([-10 10 -10 10])**



Actividad 3

1.a) $\mathbf{w}_0 = [-3.19 \ 4.47]^T$, $\mu = 0.12$.



Actividad 3

1.b) $\mathbf{w}_0 = [4.84 \ 4.52]^T$, $\mu = 0.12$.



Actividad 3

1.c) $\mathbf{w}_0 = [1.65 \ 8.99]^T$, $\mu = 0.12$.

