

Distribución Gaussiana Multivariable

Cecilia Galarza

Procesos Estocásticos
Facultad de Ingeniería, Universidad de Buenos Aires

2do cuatrimestre 2024

Media y Covarianza de un VeA

Media de un vector aleatorio

Sea $\mathbf{X} \in \mathbb{R}^n$ un VeA. Luego,

$$\begin{aligned}\mathbb{E}[\mathbf{X}] &= \mu_{\mathbf{X}} = \int_{-\infty}^{\infty} \mathbf{x} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = \underbrace{\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty}}_n \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} f_{X_1 \dots X_n}(x_1, \dots, x_n) dx_1 \cdots dx_n \\ &= \begin{bmatrix} \int_{-\infty}^{\infty} x_1 dx_1 \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_{X_1 \dots X_n}(x_1, x_2, \dots, x_n) dx_2 \cdots dx_n \\ \vdots \\ \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_{X_1 \dots X_n}(x_1, \dots, x_{n-1}, x_n) dx_1 \cdots dx_{n-1} \int_{-\infty}^{\infty} x_n dx_n \end{bmatrix} \\ &= \begin{bmatrix} \int_{-\infty}^{\infty} x_1 f_{X_1}(x_1) dx_1 \\ \vdots \\ \int_{-\infty}^{\infty} x_n f_{X_n}(x_n) dx_n \end{bmatrix} = \begin{bmatrix} \mathbb{E}[X_1] \\ \vdots \\ \mathbb{E}[X_n] \end{bmatrix}\end{aligned}$$

Repaso varianza y correlación

Recordemos que si X es una V.A cuya media es μ_X , su *varianza* está definida como

$$\mathbb{V}[X] = \mathbb{E}[(X - \mu)^2].$$

Igualmente, si X e Y son dos V.A, definimos la *covarianza* entre X e Y como

$$\text{Cov}[X, Y] = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)].$$

Decimos que X e Y están *descorrelacionadas* si $\text{Cov}[X, Y] = 0$

Matriz de covarianza

Ahora, sea $\mathbf{X} \in \mathbb{R}^n$ un VeA. La **Matriz de Covarianza** de \mathbf{X} está definida del siguiente modo:

$$\mathbf{Cov}(\mathbf{X}) = C_{\mathbf{X}} = \mathbb{E}[(\mathbf{X} - \mu_{\mathbf{X}})(\mathbf{X} - \mu_{\mathbf{X}})^t]$$

Matriz de covarianza

$$\begin{aligned} C_{\mathbf{X}} &= \mathbb{E} \left\{ \begin{bmatrix} X_1 - \mu_{X_1} \\ \vdots \\ X_n - \mu_{X_n} \end{bmatrix} \begin{bmatrix} X_1 - \mu_{X_1} & \cdots & X_n - \mu_{X_n} \end{bmatrix} \right\} \\ &= \mathbb{E} \left\{ \begin{bmatrix} (X_1 - \mu_{X_1})^2 & \cdots & (X_1 - \mu_{X_1})(X_n - \mu_{X_n}) \\ \vdots & \ddots & \vdots \\ (X_n - \mu_{X_n})(X_1 - \mu_{X_1}) & \cdots & (X_n - \mu_{X_n})^2 \end{bmatrix} \right\} \\ &= \begin{bmatrix} \underbrace{\mathbb{E}[(X_1 - \mu_{X_1})^2]}_{\mathbb{V}[X_1]} & \cdots & \underbrace{\mathbb{E}[(X_1 - \mu_{X_1})(X_n - \mu_{X_n})]}_{\text{Cov}[X_1, X_n]} \\ \vdots & \ddots & \vdots \\ \text{Cov}[X_n, X_1] & \cdots & \mathbb{V}[X_n] \end{bmatrix} \end{aligned}$$

Propiedades de C_X

- Es una matriz simétrica, $C_X = C_X^t$
- Es una matriz definida positiva, $C_X \geq 0$.
 - Todos los autovalores son positivos, $\lambda_i \geq 0, i = 1, \dots, n$
 - Los autovectores forman una base ortonormal,
 $p_i^t p_j = \delta_{ij}, i, j = 1, \dots, n$
 - Sea P la matriz de autovectores y Λ la de autovalores. Luego,

$$C_X = P \Lambda P^t$$

donde $PP^t = P^t P = I_n$ y $\Lambda = \text{diag}(\lambda_i)$.

Propiedades de C_X : VeA degenerado

Qué sucede si C_X tiene autovalores nulos? Es decir, C_X es una matriz singular?

- Recordemos que sucede con $X \in \mathbb{R}$, $\mathbb{E}[X] = \mu_X$ y $\mathbb{V}(X) = \sigma_X^2$

$$\sigma_X^2 = 0 \iff \mathbb{P}[X = \mu_X] = 1$$

La V.A se comporta como una constante igual a su media.

- Para el caso n -dimensional tenemos el siguiente resultado:

Teorema. C_X es singular si y solo si existe un vector $\mathbf{v} \neq \mathbf{0}$ tal que $\mathbb{P}(\mathbf{v}^t(\mathbf{X} - \mu_X) = 0) = 1$.

En este caso decimos que \mathbf{X} es un VeA *degenerado*.

Propiedades de $C_{\mathbf{X}}$: VeA degenerado

- Un modo interpretar este resultado es ver que si \mathbf{X} es un VeA degenerado, entonces existe una dirección fija (\mathbf{v}) que va a ser ortogonal a todas las realizaciones ($\mathbf{x} - \mu_{\mathbf{X}}$). Es decir que con probabilidad 1 NO vamos a observar realizaciones de \mathbf{X} que se encuentren en el espacio generado por \mathbf{v} desplazado en $\mu_{\mathbf{X}}$.
- Es decir, hay componentes del VeA redundantes que se pueden determinar a partir de las demás.

VeA degenerados: demostración del teorema

- C_X singular entonces $\exists \mathbf{v} \neq \mathbf{0}$: $\mathbb{P}(\mathbf{v}^t(\mathbf{X} - \mu_X) = 0) = 1$.
 C_X singular implica que C_X existe $\mathbf{v} \neq \mathbf{0}$ tal que $C_X \mathbf{v} = \mathbf{0}$.
Entonces $\mathbf{v}^t C_X \mathbf{v} = 0$. Ahora definimos $Y = \mathbf{v}^t(\mathbf{X} - \mu_X)$. Para cualquier $a > 0$, la cota de Markov establece que

$$\mathbb{P}(Y^2 \geq a) \leq \frac{\mathbb{E}[Y^2]}{a} = \frac{\mathbf{v}^t C_X \mathbf{v}}{a} = 0,$$

Luego, $\mathbb{P}(Y^2 = 0) = 1$, y por ende, $\mathbb{P}(\mathbf{v}^t(\mathbf{X} - \mu_X) = 0) = 1$.

- $\exists \mathbf{v} \neq \mathbf{0}$: $\mathbb{P}(\mathbf{v}^t(\mathbf{X} - \mu_X) = 0) = 1$ luego, C_X es singular.
 $Y = \mathbf{v}^t(\mathbf{X} - \mu_X) \in \mathbb{R}$ es una V.A. de media nula. Vimos que si $\mathbb{P}[Y = 0] = 1$ implica que su varianza es nula, es decir

$$\sigma_Y^2 = \mathbb{E}[Y^2] = \mathbf{v}^t C_X \mathbf{v} = 0.$$

Esto implica que C_X es singular.



Transformación afín de \mathbf{X}

Sea \mathbf{X} un VeA con covarianza $C_{\mathbf{X}}$. Consideramos una transformación afín formada a partir de la matriz $A \in \mathbb{R}^{m \times n}$ y el vector $b \in \mathbb{R}^m$,

$$\mathbf{Y} = A\mathbf{X} + b.$$

Entonces

$$\mathbb{E}[\mathbf{Y}] = \mathbb{E}[A\mathbf{X} + b] = A\mathbb{E}[\mathbf{X}] + b$$

$$\begin{aligned}\mathbf{Cov}(\mathbf{Y}) &= \mathbb{E} \{ [\mathbf{Y} - \mathbb{E}[\mathbf{Y}]] [\mathbf{Y} - \mathbb{E}[\mathbf{Y}]]^t \} \\ &= \mathbb{E} \{ [A\mathbf{X} + b - A\mathbb{E}[\mathbf{X}] - b] [A\mathbf{X} + b - A\mathbb{E}[\mathbf{X}] - b]^t \} \\ &= \mathbb{E} \{ [A(\mathbf{X} - \mathbb{E}[\mathbf{X}])] [A(\mathbf{X} - \mathbb{E}[\mathbf{X}])]^t \} \\ &= \mathbb{E} \{ [A(\mathbf{X} - \mathbb{E}[\mathbf{X}])] [(\mathbf{X} - \mathbb{E}[\mathbf{X}])]^t A^t \} \\ &= A \mathbb{E} \{ [\mathbf{X} - \mathbb{E}[\mathbf{X}]] [\mathbf{X} - \mathbb{E}[\mathbf{X}]]^t \} A^t = AC_{\mathbf{X}}A^t\end{aligned}$$

Transformación afín (recap importante!)

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$$

$$\mathbb{E}[\mathbf{Y}] = \mathbf{A}\mathbb{E}[\mathbf{X}] + \mathbf{b}$$

$$\mathbf{Cov}(\mathbf{Y}) = \mathbf{C}_Y = \mathbf{A}\mathbf{C}_X\mathbf{A}^t$$


Observaciones:

- \mathbf{b} desplaza la media
- \mathbf{b} no afecta la covarianza

Distribución Gaussiana Multivariable

Repaso de distribución gaussiana o normal

La VA Z tiene distribución gaussiana, o $Z \sim \mathcal{N}(\mu, \sigma^2)$ si



$$f_Z(z) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(z-\mu)^2/2\sigma^2}, \quad z \in \mathbb{R}.$$

Algunas propiedades:

- $f_Z(z)$ es máxima en μ y simétrica,

$$f_Z(\mu - z) = f_Z(\mu + z) \quad , \quad \forall z \in \mathbb{R}.$$

- $\mathbb{E}[Z] = \mu$ y $\mathbb{V}[Z] = \mathbb{E}[(Z - \mu)^2] = \sigma^2.$

Repaso de distribución gaussiana o normal

gaussiana estándar o normal estándar , $\mathcal{N}(0, 1)$.

$$F_Z(z) = \Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-u^2/2} du.$$

Función $Q(z)$:

$$Q(z) = 1 - \Phi(z) = \frac{1}{\sqrt{2\pi}} \int_z^{+\infty} e^{-u^2/2} du.$$

Ambas funciones se obtienen de tablas.

Distribución gaussiana Multivariable (Definición 1)

Un VeA \mathbf{X} tiene una distribución gaussiana multivariable si existe un vector $\mu_{\mathbf{X}}$ y una matriz simétrica $C_{\mathbf{X}} \geq 0$ tal que la PDF conjunta es:

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} \det(C_{\mathbf{X}})^{1/2}} e^{-\frac{1}{2}(\mathbf{x}-\mu_{\mathbf{X}})^T C_{\mathbf{X}}^{-1}(\mathbf{x}-\mu_{\mathbf{X}})} \quad , \quad \mathbf{x} \in \mathbb{R}^n.$$

Decimos que $\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}})$. Es posible demostrar que

- Esperanza: $\mathbb{E}[\mathbf{X}] = \mu_{\mathbf{X}}$.
- Covarianza: $\mathbf{Cov}[\mathbf{X}] = C_{\mathbf{X}}$

Cuando $\mu_{\mathbf{X}} = 0$ y $C_{\mathbf{X}} = \mathbf{I}_n$ tenemos una distribución normal estándar.

Distribución Gaussiana Multivariable (Definición 2)

\mathbf{X} tiene una distribución gaussiana multivariable si y sólo si,
 $\forall \mathbf{A} \in \mathbb{R}^{m \times n}$, $m \leq n$, $\mathbf{Y} = \mathbf{A}\mathbf{X}$ sigue una distribución gaussiana. Esta última queda especificada por

$$\mathbb{E}[\mathbf{Y}] = \mathbf{A}\mu_{\mathbf{X}} \quad \mathbf{Cov}(\mathbf{Y}) = \mathbf{A}\mathbf{C}_{\mathbf{X}}\mathbf{A}^T$$

Observaciones:

- Se puede partir de la Definición 1 y probar la Definición 2 como una propiedad o viceversa.
- La distribución gaussiana queda completamente definida por la esperanza y su matriz de covarianza.

Distribuciones marginales

Si \mathbf{X} es un VeA gaussiano, luego sus componentes y todo subvector son gaussianos.

Este resultado es una consecuencia de que toda transformación lineal de un VeA gaussiano produce otro VeA gaussiano.

- Como $X_i = \mathbf{1}_i^T \mathbf{X}$, donde $\mathbf{1}_i = [0, \dots, 0, 1, 0, \dots, 0]^t$, entonces X_i es el resultado de una transformación lineal de \mathbf{X} . Por lo tanto, X_i es gaussiana con

$$\mathbb{E}[X_i] = \mathbf{1}_i^t \mu_{\mathbf{X}} = (\mu_{\mathbf{X}})_i, \quad \mathbb{V}[X_i] = \mathbf{1}_i^t C_{\mathbf{X}} \mathbf{1}_i = (C_{\mathbf{X}})_{i,i}.$$

- En forma más general, un subvector $\mathbf{X}_I = [X_{i_1}, \dots, X_{i_k}]^t$ de \mathbf{X} es gaussiano.

$$\mathbf{X}_I = \begin{bmatrix} \mathbf{1}_{i_1}^t \\ \vdots \\ \mathbf{1}_{i_k}^t \end{bmatrix} \mathbf{X} = \mathbf{1}_I^t \mathbf{X} \quad \longrightarrow \quad \begin{cases} \mathbb{E}[\mathbf{X}_I] = \mathbf{1}_I^t \mu_{\mathbf{X}} = (\mu_{\mathbf{X}})_I \\ \mathbf{Cov}(\mathbf{X}_I) = \mathbf{1}_I^t C_{\mathbf{X}} \mathbf{1}_I = (C_{\mathbf{X}})_{I,I} \end{cases}$$

Gaussiana condicionada por Gaussiana

PDF condicional

Sea $\mathbf{X} \in \mathbb{R}^n$, $\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}})$,

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \quad \mathbf{X}_1 \in \mathbb{R}^{n_1}, \mathbf{X}_2 \in \mathbb{R}^{n_2} \quad n_1 + n_2 = n.$$

Buscamos la distribución condicional de \mathbf{X}_1 cuando $\mathbf{X}_2 = \mathbf{x}_2$. Vamos a demostrar que

$f_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1|\mathbf{X}_2 = \mathbf{x}_2)$ es gaussiana con

- $\mathbb{E}[\mathbf{X}_1|\mathbf{X}_2 = \mathbf{x}_2] = \mu_{\mathbf{X}_1} + C_{\mathbf{X}_1, \mathbf{X}_2} C_{\mathbf{X}_2, \mathbf{X}_2}^{-1} (\mathbf{x}_2 - \mu_{\mathbf{X}_2})$
- $\text{Cov}(\mathbf{X}_1|\mathbf{X}_2 = \mathbf{x}_2) = C_{\mathbf{X}_1} - C_{\mathbf{X}_1, \mathbf{X}_2} C_{\mathbf{X}_2, \mathbf{X}_2}^{-1} C_{\mathbf{X}_2, \mathbf{X}_1}.$

PDF condicional cuando $n = 2$

- Consideremos primero el caso bidimensional, es decir, $\mathbf{X} = [X_1, X_2]^t$.

$$\begin{aligned} f_{X_1|X_2}(x_1|X_2 = x_2) &= \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_2}(x_2)} \\ &= \frac{1}{2\pi\sigma_1\sigma_2(1-\rho^2)^{1/2}} e^{-\frac{1}{2} \frac{1}{1-\rho^2} \left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{x_1-\mu_1}{\sigma_1} \frac{x_2-\mu_2}{\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2} \right]} \\ &= \frac{1}{\sqrt{2\pi\sigma_2^2}} e^{-\frac{1}{2} \frac{(x_2-\mu_2)^2}{\sigma_2^2}} \\ &= \frac{1}{\sqrt{2\pi\sigma_1^2(1-\rho^2)}} e^{-\frac{1}{2\sigma_1^2(1-\rho^2)} \left[x_1 - \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2) - \mu_1 \right]^2}. \end{aligned}$$

- Luego, $f_{X_1|X_2}(x_1|X_2 = x_2)$ corresponde a una pdf gaussiana con

$$\mathbb{E}[X_1|X_2 = x_2] = \mu_1 + \frac{\rho\sigma_{X_1}}{\sigma_2}(x_2 - \mu_2).$$

$$\mathbb{V}[X_1|X_2 = x_2] = (1 - \rho^2)\sigma_1^2.$$

PDF condicional cuando $n = 2$

- La media condicional $\mu_{X_1|X_2=x_2}$ es una función afín de x_2 .
- La varianza condicional $\sigma_{X_1|X_2=x_2}^2$ es independiente del valor de x_2 .
- Si $\rho = 0$, X_1 y X_2 son independientes. Luego,
 $f_{X_1|X_2}(x_1|X_2 = x_2) = f_{X_1}(x_1)$. Esto queda claro en las ecuaciones anteriores considerando $\rho = 0$, $\mu_{X_1|X_2=x_2} = \mu_1$ y $\sigma_{X_1|X_2=x_2}^2 = \sigma_1^2$.
- Si $|\rho| = 1$, las variables están perfectamente correlacionadas. Luego al observar $\mathbf{X}_2 = \mathbf{x}_2$ podemos determinar perfectamente \mathbf{X}_1 , es decir $\sigma_{X_1|X_2=x_2}^2 = 0$. Nuevamente, esto se verifica en las ecuaciones anteriores.

PDF condicional: caso general

Partimos de la definición

$$\begin{aligned} f_{\mathbf{x}_1|\mathbf{x}_2}(\mathbf{x}_1|\mathbf{x}_2) &= \frac{f_{\mathbf{x}_1, \mathbf{x}_2}(\mathbf{x}_1, \mathbf{x}_2)}{f_{\mathbf{x}_2}(\mathbf{x}_2)} = \frac{f_{\mathbf{x}}(\mathbf{x})}{f_{\mathbf{x}_2}(\mathbf{x}_2)} \\ &= \frac{\frac{1}{(2\pi)^{n/2} \det(C_{\mathbf{x}})^{1/2}} e^{-\frac{1}{2}(\mathbf{x}-\mu_{\mathbf{x}})^t C_{\mathbf{x}}^{-1}(\mathbf{x}-\mu_{\mathbf{x}})}}{\frac{1}{(2\pi)^{n_2/2} \det(C_{\mathbf{x}_2})^{1/2}} e^{-\frac{1}{2}(\mathbf{x}_2-\mu_{\mathbf{x}_2})^t C_{\mathbf{x}_2}^{-1}(\mathbf{x}_2-\mu_{\mathbf{x}_2})}} \end{aligned}$$

Para calcular $f_{\mathbf{x}}$ necesitamos invertir $C_{\mathbf{x}}$ y calcular su determinante.
Para ello, particionamos la matriz de covarianza

$$C_{\mathbf{x}} = \begin{bmatrix} C_{\mathbf{x}_1} & C_{\mathbf{x}_1, \mathbf{x}_2} \\ C_{\mathbf{x}_2, \mathbf{x}_1} & C_{\mathbf{x}_2} \end{bmatrix}.$$

Presentamos dos resultados auxiliares para matrices en bloques.

Inversión de matrices por bloques

Sea $\mathbf{A} \in \mathbb{R}^{n \times n}$ una matriz no singular particionada del siguiente modo:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{1,1} & \mathbf{A}_{1,2} \\ \mathbf{A}_{2,1} & \mathbf{A}_{2,2} \end{bmatrix}$$

Definimos

$$\mathbf{A}_* = \mathbf{A}_{1,1} - \mathbf{A}_{1,2} \mathbf{A}_{2,2}^{-1} \mathbf{A}_{2,1}.$$

Esta matriz se la conoce como el complemento de Schur del bloque $\mathbf{A}_{2,2}$ de la matriz \mathbf{A} . Asumimos que todas las inversas involucradas existen. Luego:

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_*^{-1} & -\mathbf{A}_*^{-1} \mathbf{A}_{1,2} \mathbf{A}_{2,2}^{-1} \\ -\mathbf{A}_{2,2}^{-1} \mathbf{A}_{2,1} \mathbf{A}_*^{-1} & \mathbf{A}_{2,2}^{-1} + \mathbf{A}_{2,2}^{-1} \mathbf{A}_{2,1} \mathbf{A}_*^{-1} \mathbf{A}_{1,2} \mathbf{A}_{2,2}^{-1} \end{bmatrix}$$

$$\det(\mathbf{A}) = \det(\mathbf{A}_{2,2}) \det(\mathbf{A}_*).$$

PDF condicional: caso general

Retomamos la derivación de $f_{\mathbf{x}_1|\mathbf{x}_2}$

- Aplicando el resultado de inversión por bloques a la matriz $C_{\mathbf{x}}$ calculamos el complemento de Schur

$$C_{\mathbf{x}*} = C_{\mathbf{x}_1} - C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1}$$

Luego,

$$\begin{aligned} C_{\mathbf{x}}^{-1} &= \begin{bmatrix} C_{\mathbf{x}_1} & C_{\mathbf{x}_1, \mathbf{x}_2} \\ C_{\mathbf{x}_2, \mathbf{x}_1} & C_{\mathbf{x}_2} \end{bmatrix}^{-1} \\ &= \begin{bmatrix} C_{\mathbf{x}*}^{-1} & -C_{\mathbf{x}*}^{-1} C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} \\ -C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} C_{\mathbf{x}*}^{-1} & C_{\mathbf{x}_2}^{-1} + C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} C_{\mathbf{x}*}^{-1} C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} \end{bmatrix} \end{aligned}$$

$$\det(C_{\mathbf{x}}) = \det(C_{\mathbf{x}_2}) \det(C_{\mathbf{x}*}).$$

PDF condicional: caso general

- Utilizando la partición de $C_{\mathbf{X}}^{-1}$, calculamos:

$$\begin{aligned}
 (\mathbf{x} - \mu_{\mathbf{X}})^t C_{\mathbf{X}}^{-1} (\mathbf{x} - \mu_{\mathbf{X}}) &= \begin{bmatrix} \mathbf{x}_1 - \mu_{\mathbf{x}_1} \\ \mathbf{x}_2 - \mu_{\mathbf{x}_2} \end{bmatrix}^t \begin{bmatrix} C_{\mathbf{x}_1} & C_{\mathbf{x}_1, \mathbf{x}_2} \\ C_{\mathbf{x}_2, \mathbf{x}_1} & C_{\mathbf{x}_2} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{x}_1 - \mu_{\mathbf{x}_1} \\ \mathbf{x}_2 - \mu_{\mathbf{x}_2} \end{bmatrix} \\
 &= (\mathbf{x}_1 - \mu_{\mathbf{x}_1})^t C_{\mathbf{x}_*}^{-1} (\mathbf{x}_1 - \mu_{\mathbf{x}_1}) \\
 &\quad - (\mathbf{x}_1 - \mu_{\mathbf{x}_1})^t C_{\mathbf{x}_*}^{-1} C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} (\mathbf{x}_2 - \mu_{\mathbf{x}_2}) - (\mathbf{x}_2 - \mu_{\mathbf{x}_2})^t C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} C_{\mathbf{x}_*}^{-1} (\mathbf{x}_1 - \mu_{\mathbf{x}_1}) \\
 &\quad + (\mathbf{x}_2 - \mu_{\mathbf{x}_2})^t \left\{ C_{\mathbf{x}_2}^{-1} + C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} C_{\mathbf{x}_*}^{-1} C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} \right\} (\mathbf{x}_2 - \mu_{\mathbf{x}_2}) \\
 &= \begin{bmatrix} \mathbf{x}_1 - \underbrace{(\mu_{\mathbf{x}_1} + C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} (\mathbf{x}_2 - \mu_{\mathbf{x}_2}))}_{\mu_*} \end{bmatrix}^t C_{\mathbf{x}_*}^{-1} \begin{bmatrix} \mathbf{x}_1 - \underbrace{(\mu_{\mathbf{x}_1} + C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} (\mathbf{x}_2 - \mu_{\mathbf{x}_2}))}_{\mu_*} \\ \\ \end{bmatrix} \\
 &\quad + (\mathbf{x}_2 - \mu_{\mathbf{x}_2})^t C_{\mathbf{x}_2}^{-1} (\mathbf{x}_2 - \mu_{\mathbf{x}_2}).
 \end{aligned}$$

Definimos $\mu_* = \mu_{\mathbf{x}_1} + C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} (\mathbf{x}_2 - \mu_{\mathbf{x}_2})$.

PDF condicional: caso general

- Incorporando esta expresión y la de $\det(C_{\mathbf{X}})$ en $f_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1|\mathbf{x}_2)$ obtenemos

$$e^{-\frac{1}{2}[(\mathbf{x}-\mu_{\mathbf{X}})^t C_{\mathbf{X}}^{-1}(\mathbf{x}-\mu_{\mathbf{X}}) - (\mathbf{x}_2 - \mu_{\mathbf{X}_2})^t C_{\mathbf{X}_2}^{-1}(\mathbf{x}_2 - \mu_{\mathbf{X}_2})]} = e^{-\frac{1}{2}(\mathbf{x}_1 - \mu_*)^t C_{\mathbf{X}*}^{-1}(\mathbf{x}_1 - \mu_*)}$$

$$\frac{\frac{1}{(2\pi)^{n/2} \det(C_{\mathbf{X}})^{1/2}}}{\frac{1}{(2\pi)^{n_2/2} \det(C_{\mathbf{X}_2})^{1/2}}} = \frac{1}{(2\pi)^{n_1/2} \det(C_{\mathbf{X}*})^{1/2}}$$

- Luego,

$$f_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1|\mathbf{x}_2) = \frac{1}{(2\pi)^{n_1/2} \det(C_{\mathbf{X}*})^{1/2}} e^{-\frac{1}{2}(\mathbf{x}_1 - \mu_*)^t C_{\mathbf{X}*}^{-1}(\mathbf{x}_1 - \mu_*)}.$$

Ésta es una pdf gaussiana de media μ_* y covarianza $C_{\mathbf{X}*}$, es decir,

$$f_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1|\mathbf{x}_2) = \mathcal{N}(\mu_{\mathbf{X}_1} + C_{\mathbf{X}_1, \mathbf{X}_2} C_{\mathbf{X}_2}^{-1}(\mathbf{x}_2 - \mu_{\mathbf{X}_2}), C_{\mathbf{X}_1} - C_{\mathbf{X}_1, \mathbf{X}_2} C_{\mathbf{X}_2}^{-1} C_{\mathbf{X}_2, \mathbf{X}_1}).$$

Transformación afín de un VeA gaussiano

Transformaciones afines de un VeA gaussiano

Vimos que si $\mathbf{X} \in \mathbb{R}^n$ es un VeA Gaussiano, luego toda transformación lineal del mismo es también gaussiano. Analicemos qué ocurre cuando tomamos una transformación afín. Sean $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$. Noten que m puede ser distinto a n , es decir A puede ser rectangular. Definimos

$$\mathbf{Y} = A\mathbf{X} + b.$$

- Vimos que en una transformación afín

$$\mu_{\mathbf{Y}} = A\mathbb{E}[\mathbf{X}] + b, \quad C_{\mathbf{Y}} = AC_{\mathbf{X}}A^t$$

- Sabemos que $A\mathbf{X}$ sigue una distribución gaussiana. Luego, $\mathbf{Y} \sim \mathcal{N}(\mu_{\mathbf{Y}}, C_{\mathbf{Y}})$.
- Usando transformaciones afines, podemos transformar cualquier distribución gaussiana en una normal estándar y viceversa. Vamos a trabajar sólo con gaussianas no-degeneradas.

Transformaciones afines de un VeA gaussiano

Sea $\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}})$, con $C_{\mathbf{X}} > 0$.

- Descomponemos $C_{\mathbf{X}} = P_{\mathbf{X}} \Lambda_{\mathbf{X}} P_{\mathbf{X}}^t$
- Como $\Lambda_{\mathbf{X}} > 0$, entonces $\Lambda_{\mathbf{X}} = \Lambda_{\mathbf{X}}^{1/2} \Lambda_{\mathbf{X}}^{1/2}$
- Definimos una transformación $\mathbf{Z} = A\mathbf{X}$ con $A = \Lambda_{\mathbf{X}}^{-1/2} P_{\mathbf{X}}^t$. Entonces

$$C_{\mathbf{Z}} = \underbrace{\Lambda_{\mathbf{X}}^{-1/2} P_{\mathbf{X}}^t}_A C_{\mathbf{X}} \underbrace{P_{\mathbf{X}} \Lambda_{\mathbf{X}}^{-1/2}}_{A^t} = \Lambda_{\mathbf{X}}^{-1/2} P_{\mathbf{X}}^t P_{\mathbf{X}} \Lambda_{\mathbf{X}} P_{\mathbf{X}}^t P_{\mathbf{X}} \Lambda_{\mathbf{X}}^{-1/2} = \mathbf{I}_n$$

- Completamos con el desplazamiento $b = -A\mu_{\mathbf{X}}$, $\mathbf{Z} = A\mathbf{X} + b$.
Luego este desplazamiento no afecta la covarianza pero desplaza la media.

$$\mathbb{E}[\mathbf{Z}] = A\mu_{\mathbf{X}} + (-A\mu_{\mathbf{X}}) = 0$$

Transformaciones afines de \mathbf{X}

Normalización de VeA Gaussiano

Sea $\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}})$. La transformación

$$\mathbf{Z} = \Lambda_{\mathbf{X}}^{-1/2} P_{\mathbf{X}}^t (\mathbf{X} - \mu_{\mathbf{X}})$$

resulta en un VeA normal estandar, es decir $\mathbf{Z} \sim \mathcal{N}(0, \mathbf{I}_n)$

Transformaciones afines de \mathbf{X}

Del mismo modo, partiendo de un VeA normal estándar, podemos obtener un VeA gaussiano con media y covarianza dadas.

Normalización de VeA Gaussiano


Sean $\mathbf{Z} \sim \mathcal{N}(0, \mathbf{I}_n)$, $\mathbf{Y} \sim \mathcal{N}(\mu_{\mathbf{Y}}, C_{\mathbf{Y}})$ donde $C_{\mathbf{Y}} = P_{\mathbf{Y}}\Lambda_{\mathbf{Y}}P_{\mathbf{Y}}^t$. Luego,

$$\mathbf{Y} = P_{\mathbf{Y}}\Lambda_{\mathbf{Y}}^{1/2}\mathbf{Z} + \mu_{\mathbf{Y}}$$

Transformaciones afines de \mathbf{X} (recap)

$$\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}}) \quad C_{\mathbf{X}} = P_{\mathbf{X}} \Lambda_{\mathbf{X}} P_{\mathbf{X}}^t$$

$$\mathbf{Y} \sim \mathcal{N}(\mu_{\mathbf{Y}}, C_{\mathbf{Y}}) \quad C_{\mathbf{Y}} = P_{\mathbf{Y}} \Lambda_{\mathbf{Y}} P_{\mathbf{Y}}^t$$



Relación entre VeA Gaussiano y la distribución χ^2

Distribución χ^2

Sea $\mathbf{X} \in \mathbb{R}^n$ un VeA Gaussiano a partir del cual formamos la V.A.

$$Y = (\mathbf{X} - \mu_{\mathbf{X}})^T \mathbf{C}_{\mathbf{X}}^{-1} (\mathbf{X} - \mu_{\mathbf{X}}).$$

$$Y \sim \chi_n^2$$

Y tiene una distribución chi-cuadrado con n grados de libertad.

Relación entre VeA Gaussiano y la distribución χ^2

- 1 Sea $\mathbf{Z} = \mathbf{C}_{\mathbf{X}}^{-1/2}(\mathbf{X} - \mu_{\mathbf{X}})$. Por ser transformación lineal de VeA gaussiano es gaussiano. Más aún, $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.
- 2 Entonces, cada $Z_i \sim \mathcal{N}(0, 1)$ y son independientes.

3

$$\begin{aligned} Y &= (\mathbf{X} - \mu_{\mathbf{X}})^T \mathbf{C}_{\mathbf{X}}^{-1} (\mathbf{X} - \mu_{\mathbf{X}}) \\ &= (\mathbf{X} - \mu_{\mathbf{X}})^T \mathbf{C}_{\mathbf{X}}^{-1/2} \mathbf{C}_{\mathbf{X}}^{-1/2} (\mathbf{X} - \mu_{\mathbf{X}}) = \mathbf{Z}^t \mathbf{Z} = \sum_{i=1}^n Z_i^2. \end{aligned}$$

- 4 Cada término Z_i^2 tiene una distribución chi-cuadrado con 1 grado de libertad.
- 5 Luego, $Y \sim \chi_n^2$.

Función Característica de una gaussiana

Función característica de V.A. normal estándar

Vamos a trabajar el problema para una sola variable aleatoria. Para ello, partimos de la definición de Función Característica. Para el caso de la normal estándar $\mathcal{N}(0, 1)$ tenemos,

$$\begin{aligned}\Phi_Z(\omega) &= \mathbb{E}[e^{j\omega Z}] = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{j\omega z} e^{-\frac{z^2}{2}} dz \\ &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{-\frac{\omega^2}{2}} e^{-\frac{(z-j\omega)^2}{2}} dz = e^{-\frac{\omega^2}{2}} \underbrace{\frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{-\frac{u^2}{2}} du}_1 = e^{-\frac{\omega^2}{2}}.\end{aligned}$$

La FC resulta entonces

$$\Phi_Z(\omega) = e^{-\frac{\omega^2}{2}}, \quad \omega \in \mathbb{R}.$$

Función característica de V.A. gaussiana

A partir de la normal estándar, podemos obtener cualquier distribución gaussiana. En particular, si $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$,

$$X = \sigma_X Z + \mu_X.$$

Luego, aplicando las propiedades de las funciones características,

$$\Phi_X(\omega) = e^{j\omega\mu_X} \Phi_Z(\sigma_X\omega) = e^{j\omega\mu_X} e^{-\frac{\sigma_X^2\omega^2}{2}}$$

Observaciones

- $\Phi_Z(\omega) = e^{-\frac{\omega^2}{2}}$ y $f_Z(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$ tienen la misma forma funcional. Difieren solamente en un factor de escala.
- La media μ_X determina un factor de fase de $\Phi_X(\omega)$. El módulo sólo depende de σ_X .
- A mayor valor de σ_X , $f_X(x)$ es una “campana” más dispersa alrededor de μ_X y $\Phi_X(\omega)$ es una “campana” más concentrada alrededor del origen.

Momentos de VA gaussiana

- Comenzamos con la normal estándar. A partir de $\Phi_Z(\omega)$ hallamos sus momentos utilizando el teorema de momentos. Desarrollamos en serie de Taylor:

$$\begin{aligned}\Phi_Z(\omega) &= e^{-\frac{\omega^2}{2}} = \sum_{k=0}^{\infty} \frac{(-\omega^2/2)^k}{k!} \\ &= \sum_{k=0}^{\infty} \left(-\frac{1}{2}\right)^k \frac{(2k)!}{k!} \frac{\omega^{2k}}{(2k)!} = \sum_{k=0}^{\infty} \Phi_Z^{(k)}(0) \frac{\omega^k}{k!}.\end{aligned}$$

- Igualando los términos de igual potencia, se tiene que

$$\left. \frac{d^{(k)}\Phi_Z(\omega)}{d\omega^{(k)}} \right|_{\omega=0} = \Phi_Z^{(k)}(0) = \begin{cases} 0 & \text{si } k \text{ es impar,} \\ \left(-\frac{1}{2}\right)^{(k/2)} \frac{k!}{(k/2)!} & \text{si } k \text{ es par.} \end{cases}$$

Momentos de VA gaussiana

- El teorema de momentos establece que

$$\mathbb{E}[Z^k] = \frac{1}{j^k} \Phi_Z^{(k)}(0).$$

Por ende,

$$\mathbb{E}[Z^{(2m+1)}] = 0 \quad \mathbb{E}[Z^{2m}] = \frac{1}{2^m} \frac{(2m)!}{m!}$$

Verificamos el resultado con los primeros dos momentos:

$$\mathbb{E}[Z] = \frac{1}{j} \Phi_Z^{(1)}(0) = 0 \quad \mathbb{V}(Z) = \mathbb{E}[Z^2] = \frac{1}{j^2} \Phi_Z^{(2)}(0) = -\left(-\frac{1}{2}\right) 2 = 1.$$

- En forma general, para $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$

$$\mathbb{E}[(X - \mu_X)^{(2m+1)}] = 0 \quad \mathbb{E}[(X - \mu_X)^{2m}] = \sigma_X^{2m} \frac{1}{2^m} \frac{(2m)!}{m!}$$

Independencia y Correlación

Observación

- En general

X_1, \dots, X_n V.A independientes $\implies X_1, \dots, X_n$ V.A descorrelacionadas

Claramente, si X_i, X_j son independientes, su covarianza es

$$\text{Cov}(X_i, X_j) = \mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])] = \mathbb{E}[X_i - \mathbb{E}[X_i]] \mathbb{E}[X_j - \mathbb{E}[X_j]] = 0 \quad \square$$

Pero

X_1, \dots, X_n V.A descorrelacionadas $\not\implies X_1, \dots, X_n$ V.A independientes

- Se plantea una excepción cuando X_1, \dots, X_n son V.A conjuntamente gaussianas

Gaussianas Independientes

El vector $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{X}}, \mathbf{C}_{\mathbf{X}})$ tiene componentes descorrelacionadas (es decir, $\mathbf{C}_{\mathbf{X}}$ es diagonal) si y sólo si sus componentes son independientes, es decir,

$$\mathbf{C}_{\mathbf{X}} \text{ es diagonal} \iff f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^n f_{X_i}(x_i).$$

En este caso,

$$X_1, \dots, X_n \text{ V.A descorrelacionadas} \iff X_1, \dots, X_n \text{ V.A independientes}$$

Demostración

- (\Rightarrow): $C_{\mathbf{X}} = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$. Luego,

$$(\mathbf{x} - \mu_{\mathbf{X}})^T C_{\mathbf{X}}^{-1} (\mathbf{x} - \mu_{\mathbf{X}}) = \sum_{i=1}^n \frac{(x_i - \mu_i)^2}{\sigma_i^2}, \quad \det(C_{\mathbf{X}}) = \prod_{i=1}^n \sigma_i^2$$

Usando las propiedades de la función exponencial,

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} \det(C_{\mathbf{X}})^{1/2}} e^{-\frac{1}{2}(\mathbf{x} - \mu_{\mathbf{X}})^T C_{\mathbf{X}}^{-1} (\mathbf{x} - \mu_{\mathbf{X}})} = \prod_{i=1}^n \underbrace{\frac{1}{(2\pi\sigma_i^2)^{1/2}} e^{-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}}}_{f_{X_i}(x_i)}.$$

- (\Leftarrow): $f_{\mathbf{X}}(\mathbf{x}) = \prod f_{X_i}(x_i)$. Por ser \mathbf{X} una gaussiana multivariable, sus componentes tienen que ser VA gaussianas. Luego,

$$f_{X_i}(x_i) = \frac{e^{-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}}}{\sqrt{2\pi\sigma_i^2}} \Rightarrow f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^n \underbrace{\frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}}}_{f_{X_i}(x_i)} \Rightarrow C_{\mathbf{X}} = \text{diag}(\sigma_i^2)$$

Independencia y PDF condicional

Vimos que si \mathbf{X}_1 y \mathbf{X}_2 son dos VeA conjuntamente gaussianos, la PDF condicional es una gaussiana de media y matriz de covarianza

$$\mathbb{E}[\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2] = \mu_{\mathbf{X}_1} + \mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} \mathbf{C}_{\mathbf{X}_2}^{-1} (\mathbf{x}_2 - \mu_{\mathbf{X}_2}) \quad \mathbf{Cov}(\mathbf{X}_1 | \mathbf{X}_2) = \mathbf{C}_{\mathbf{X}_1} - \mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} \mathbf{C}_{\mathbf{X}_2}^{-1} \mathbf{C}_{\mathbf{X}_2, \mathbf{X}_1}$$

- Si \mathbf{X}_1 y \mathbf{X}_2 están descorrelacionados, $\mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} = 0$. Por ende,

$$\mathbb{E}[\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2] = \mu_{\mathbf{X}_1} \quad \mathbf{Cov}(\mathbf{X}_1 | \mathbf{X}_2) = \mathbf{C}_{\mathbf{X}_1}$$

y $f_{\mathbf{X}_1 | \mathbf{x}_2} = f_{\mathbf{X}_1}$, es decir \mathbf{X}_1 y \mathbf{X}_2 son independientes.

- Por otro lado, si \mathbf{X}_1 y \mathbf{X}_2 son independientes $f_{\mathbf{X}_1 | \mathbf{x}_2} = f_{\mathbf{X}_1}$. Para ello,

$$\mu_{\mathbf{X}_1} + \mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} \mathbf{C}_{\mathbf{X}_2}^{-1} (\mathbf{x}_2 - \mu_{\mathbf{X}_2}) = \mu_{\mathbf{X}_1} \quad \text{y} \quad \mathbf{C}_{\mathbf{X}_1} - \mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} \mathbf{C}_{\mathbf{X}_2}^{-1} \mathbf{C}_{\mathbf{X}_2, \mathbf{X}_1} = \mathbf{C}_{\mathbf{X}_1}$$

La única posibilidad que esto se cumpla $\forall \mathbf{x}_2$ es que $\mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} = 0$.

Componentes principales

Conjuntos de nivel

- Una forma de visualizar y comprender mejor la forma de la PDF de un vector gaussiano es analizar los conjuntos de nivel. Dado un α constante, se define el conjunto de nivel

$$\{\mathbf{x} \in \mathbb{R}^n : f_{\mathbf{x}}(\mathbf{x}) = \alpha\}$$

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{\sqrt{\det(2\pi \mathbf{C}_{\mathbf{x}})}} e^{-(\mathbf{x} - \mu_{\mathbf{x}})^T \mathbf{C}_{\mathbf{x}}^{-1} (\mathbf{x} - \mu_{\mathbf{x}})/2} = \alpha,$$

$$\implies (\mathbf{x} - \mu_{\mathbf{x}})^T \mathbf{C}_{\mathbf{x}}^{-1} (\mathbf{x} - \mu_{\mathbf{x}}) = \beta, \quad \text{donde } \beta \text{ es otra constante.}$$

Esta ecuación describe a un elipsoide en \mathbb{R}^n .

Direcciones principales

Vimos que $C_{\mathbf{X}} = P\Lambda P^t$, con $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ y $PP^t = \mathbf{I}_n$.

Reemplazando esta expresión en la ecuación de la elipsoide, tenemos

$$\beta = \underbrace{(\mathbf{x} - \mu_{\mathbf{X}})^t P}_{\mathbf{y}^t} \Lambda^{-1} \underbrace{P^t (\mathbf{x} - \mu_{\mathbf{X}})}_{\mathbf{y}}$$

Definimos un vector auxiliar $\mathbf{y} = P^t(\mathbf{x} - \mu_{\mathbf{X}})$. Luego recordando que $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$,

$$\beta = \mathbf{y}^t \Lambda^{-1} \mathbf{y} = \sum_{i=1}^n \frac{y_i^2}{\lambda_i}.$$

Los auto-vec de $C_{\mathbf{X}}$ son las *Direcciones principales* del elipsoide cuyos ejes tienen una longitud proporcional a los auto-val de $C_{\mathbf{X}}$.

Ejemplo: curvas de nivel en \mathbb{R}^2

- $\mathbf{X} = [X, Y] \sim \mathcal{N}(0, C_{\mathbf{X}})$.
- La matriz de covarianza es

$$C_{\mathbf{X}} = \begin{bmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{bmatrix} \longrightarrow C_{\mathbf{X}}^{-1} = \frac{1}{\sigma_X^2\sigma_Y^2(1-\rho^2)} \begin{bmatrix} \sigma_Y^2 & -\rho\sigma_X\sigma_Y \\ -\rho\sigma_X\sigma_Y & \sigma_X^2 \end{bmatrix}.$$


- Luego,

$$\mathbf{x}^T C_{\mathbf{X}}^{-1} \mathbf{x} = \frac{1}{1-\rho^2} \left[\frac{x^2}{\sigma_X^2} - 2\rho \frac{x}{\sigma_X} \frac{y}{\sigma_Y} + \frac{y^2}{\sigma_Y^2} \right].$$


Las curvas de nivel son $\{(x, y) \in \mathbb{R}^2 : \frac{x^2}{\sigma_X^2} - 2\rho \frac{x}{\sigma_X} \frac{y}{\sigma_Y} + \frac{y^2}{\sigma_Y^2} = c\}$

- Las longitudes de los semiejes principales son proporcionales a σ_X y σ_Y .


Ejemplo: curvas de nivel en \mathbb{R}^2



$\rho = 0 \rightarrow X, Y$
descorrelacionadas



$\rho > 0$



$\rho < 0$

Análisis de componentes principales

- Los conjuntos de nivel de la pdf de $\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}})$ son elipsoides cuyas direcciones son los auto-vec $\{p_1, \dots, p_n\}$. El largo de cada eje es proporcional al auto-val asociado $\{\lambda_1, \dots, \lambda_n\}$.
Supongamos que los auto-vec están ordenados de modo que $\lambda_1 \geq \dots \geq \lambda_n$.
- Si a partir de un auto-val, los auto-val restantes son mucho más pequeños, es decir, $\lambda_1 \geq \dots \geq \lambda_r \gg \lambda_{r+1} \geq \dots \geq \lambda_n$, las realizaciones de \mathbf{X} van a tener mayor variación en las direcciones p_1, \dots, p_r que en las restantes direcciones de \mathbb{R}^n .
- Una idea para *comprimir* la información contenida en el vector \mathbf{X} es observar solamente las primeras r componentes.
- Es decir, vamos a aproximar \mathbf{X} por un VeA en el subespacio generado por $\{p_1, \dots, p_r\}$.

Análisis de componentes principales

Sin falta de generalidad, vamos a considerar que $\mu_{\mathbf{X}} = 0$.

Las *componentes principales* de \mathbf{X} son las proyecciones de \mathbf{X} en cada una de sus direcciones principales. Es decir, la i -ésima componente principal tiene la forma

$$Y_i = p_i^t \mathbf{X}.$$

- Y_i es una V.A (pregunta: es gaussiana?)
- Para representar \mathbf{X} como combinación lineal de $\{p_1, \dots, p_r\}$ utilizamos las primeras r componentes principales:

$$\hat{\mathbf{X}}_r = \sum_{i=1}^r Y_i p_i = \sum_{i=1}^r p_i^t \mathbf{X} p_i.$$

Obviamente, cuando $r = n$, $\hat{\mathbf{X}}_n = \mathbf{X}$.

- Este análisis se llama *Análisis de componentes principales* o PCA (principal component analysis).

Ejemplo: PCA en \mathbb{R}^2

Sea $\mathbf{X} = [X_1, X_2]^t$ de media nula y matriz de covarianza

$$\mathbf{C}_\mathbf{X} = \begin{bmatrix} \sigma^2 & \rho\sigma^2 \\ \rho\sigma^2 & \sigma^2 \end{bmatrix}.$$

Cuál es la media cuadrática del error de representación $\mathbb{E}[\|\mathbf{X} - \hat{\mathbf{X}}_r\|^2]$?

- En este caso, la diagonalización de $\mathbf{C}_\mathbf{X}$ resulta en

$$\lambda_1 = \sigma^2(1 + \rho), \quad \lambda_2 = \sigma^2(1 - \rho), \quad p_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad p_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Ejemplo: PCA en \mathbb{R}^2

- La primera componente principal de \mathbf{X}

$$Y_1 = p_1^t \mathbf{X} = \frac{X_1 + X_2}{\sqrt{2}}$$

y la mejor representación en un subespacio de dimensión 1 es

$$\hat{\mathbf{X}}_1 = Y_1 p_1 = \frac{X_1 + X_2}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

- La segunda componente principal de \mathbf{X} es

$$Y_2 = p_2^t \mathbf{X} = \frac{X_1 - X_2}{\sqrt{2}}$$

Ejemplo: PCA en \mathbb{R}^2

- Claramente, si tomamos ambas componentes obtenemos

$$\hat{\mathbf{X}}_2 = Y_1 p_1 + Y_2 p_2 = \frac{X_1 + X_2}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \frac{X_1 - X_2}{2} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \mathbf{X}.$$

- Como $\mathbf{X} - \hat{\mathbf{X}}_1 = Y_2 p_2 = (p_2^t \mathbf{X}) p_2$, el error de la representación es

$$\begin{aligned} \mathbb{E} [\|\mathbf{X} - \hat{\mathbf{X}}_1\|^2] &= \mathbb{E} [|p_2^t \mathbf{X}|^2 \|p_2\|^2] = \mathbb{E} [|p_2^t \mathbf{X}|^2] \quad \text{por ser } \|p_2\| = 1 \\ &= \mathbb{E} [p_2^t \mathbf{X} \mathbf{X}^t p_2] = p_2^t C_{\mathbf{X}} p_2 = \lambda_2 = \sigma^2(1 - \rho). \end{aligned}$$

- *Interpretación:* cuánto más fuerte sea la correlación entre las variables, menor será el error. En el caso degenerado las dos componentes se desplazan en un subespacio de dimensión 1. Como $\rho = 1$, $\mathbb{E}[\|\mathbf{X} - \hat{\mathbf{X}}_1\|^2] = 0$.

Reducción de la dimensionalidad en imágenes



Reconstrucciones de una imagen del dígito 4 de la base de datos MNIST usando (a) $r = 1$, (b) $r = 2$, (c) $r = 4$, (d) $r = 8$, (e) $r = 16$, (f) $r = 32$, (g) $r = 64$, (h) $r = 128$, (i) $r = 400$ componentes principales.

Ejercicios

Ejercicio: Vector gaussiano degenerado

Sea $Z \sim \mathcal{N}(0, 1)$. Definimos el VeA

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} Z \\ 2Z + 1 \end{bmatrix}.$$

Calcular la pdf conjunta $f_{\mathbf{x}}(\mathbf{x})$.

Solución

- De la definición de \mathbf{X} , deducimos que $X_1 \sim \mathcal{N}(0, 1)$.
- Igualmente, $X_2 = 2X_1 + 1$, y por ende X_2 es gaussiana por ser transformación afín de una gaussiana. Más aún, $X_2 \sim \mathcal{N}(1, 4)$.
- Como $X_2 = 2X_1 + 1$, observamos que la realización x_1 determina sin ambigüedades la realización de X_2 .
- Utilizando la ley de cadena obtenemos


$$\begin{aligned}f_{\mathbf{X}}(\mathbf{x}) &= f_{X_1, X_2}(x_1, x_2) = f_{X_1}(x_1) f_{X_2|X_1=x_1}(x_2|x_1) \\&= \frac{1}{\sqrt{2\pi}} e^{-x_1^2/2} \delta(x_2 - (2x_1 + 1)).\end{aligned}$$

- No hay una única forma de escribir la PDF conjunta.


$$\begin{aligned}f_{\mathbf{X}}(\mathbf{x}) &= f_{X_1, X_2}(x_1, x_2) = f_{X_2}(x_2) f_{X_1|X_2=x_2}(x_1) \\&= \frac{1}{\sqrt{8\pi}} e^{-(x_2-1)^2/2} \delta\left(x_1 - \frac{x_2 - 1}{2}\right).\end{aligned}$$

Solución

Realizaciones de \mathbf{X}



Curvas de Nivel de $f_{\mathbf{X}}$



Ejercicio: V.As marginalmente pero no conjuntamente gaussianas

Sean $X \sim \mathcal{N}(0, 1)$ y $B \sim \text{Ber}(1/2)$, independientes entre sí. Definimos

$$Y = (2B - 1)X.$$

Determinar si X e Y son conjuntamente gaussianas o no.

Solución

- Para que las V.A sean conjuntamente gaussianas, las dos deben ser gaussianas. X lo es. Tenemos que ver qué pasa con Y . Para ello, calculamos la cdf:

$$\begin{aligned}F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(B = 1)\mathbb{P}(X \leq y) + \mathbb{P}(B = 0)\mathbb{P}(-X \leq y) \\&= \frac{1}{2}\mathbb{P}(X \leq y) + \frac{1}{2}\mathbb{P}(X \geq -y) = \mathbb{P}(X \leq y).\end{aligned}$$

Es decir, Y es gaussiana y tiene la misma distribución que X .

- La suma resulta $W = X + Y = 2BX$. Luego,

$$\begin{aligned}F_W(w) &= \mathbb{P}(W \leq w) = \mathbb{P}(B = 1)\mathbb{P}(2X \leq w) + \mathbb{P}(B = 0)\mathbb{P}(0 \leq w) \\&= \frac{1}{2}\mathbb{P}(X \leq \frac{w}{2}) + \frac{1}{2}\mathbb{1}\{w \geq 0\} \longrightarrow W \text{ no es normal.}\end{aligned}$$

- Como hay una combinación lineal de X e Y que no es gaussiana, entonces X e Y no son conjuntamente gaussianas, pese a ser cada una marginalmente gaussianas.

Solución

Cómo es la distribución conjunta $f_{X,Y}(x, y)$?

- Como $Y = (2B - 1)X$, cuando $X = x$, $Y = x$ o $Y = -x$ dependiendo de si $B = 1$ o $B = 0$. Es decir que

$$f_{Y|X}(y|X = x) = \mathbb{P}[B = 1]\delta(y - x) + \mathbb{P}[B = 0]\delta(y + x)$$

- Utilizando la regla de la cadena

$$f_{X,Y}(x, y) = f_{Y|X}(y|X = x)f_X(x) = \frac{1}{2} [\delta(y - x) + \delta(y + x)] f_X(x)$$

Claramente, no es gaussiana.

Ejercicio: Gaussianas independientes

Un transmisor de radio envía una señal $s > 0$ que es recibida en un receptor utilizando tres caminos. Las señales que llegan al receptor por cada camino son:

$$X_1 = s + N_1 \quad X_2 = s + N_2 \quad X_3 = s + N_3$$

donde N_1, N_2, N_3 son variables aleatorias gaussianas independientes con media cero y varianza unitaria.

- 1 Hallar la pdf conjunta de $\mathbf{X} = [X_1, X_2, X_3]^t$
- 2 Determine si las componentes de \mathbf{X} son variables aleatorias independientes.
- 3 Hallar la probabilidad de que el mínimo de las tres señales sea positivo.
- 4 Hallar la probabilidad de que la mayoría de las señales sean positivas.

Ejercicio: Canal de comunicaciones

La señal transmitida por un canal de comunicaciones se suele modelar con un $\text{VeA } \mathbf{X} \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$ de módulo A y módulo al cuadrado B

$$\mathbf{X} = \begin{bmatrix} U \\ V \end{bmatrix} \quad A = \sqrt{U^2 + V^2} \quad B = A^2.$$

Luego, $A \sim \text{Rayleigh}(\sigma)$ y $B \sim \text{Exp}(\frac{\sigma^2}{2})$.

$$f_A(a) = \frac{a}{\sigma^2} e^{-a^2/(2\sigma^2)} \quad , \quad f_B(b) = \frac{\sigma^2}{2} e^{-b\sigma^2/2} \quad a, b \geq 0$$

Para combatir las perturbaciones del canal se agrega redundancia en el mensaje. En un modelo sencillo, se envían N versiones independientes de una misma señal en forma consecutiva, $\mathbf{X}_1, \dots, \mathbf{X}_N$. Una señal es descartada si su amplitud al cuadrado B_k está por debajo de un umbral γ .

Hallar la probabilidad de que las N señales estén por debajo de ese umbral.

V.A conjuntamente gaussianas

Sean X e Y dos V.A conjuntamente gaussianas de media nula.
Demuestre que

$$\mathbb{E}[X^2 Y^2] = \mathbb{E}[X^2]\mathbb{E}[Y^2] + 2\mathbb{E}^2[XY]$$

Ayuda: Utilice el resultado de gaussiana condicionada por gaussiana y la expresión de los momentos de una gaussiana.