

Vectores Aleatorios

Cecilia Galarza

Procesos Estocásticos
Facultad de Ingeniería, Universidad de Buenos Aires

2do cuatrimestre 2024

Esperanza

El operador esperanza

Sea \mathbf{X} un vector aleatorio n -dimensional. La media o esperanza de \mathbf{X} es vector de las esperanzas de sus componentes:

$$\mathbb{E}[\mathbf{X}] = \mu_{\mathbf{X}} = \begin{bmatrix} \mathbb{E}[X_1] \\ \vdots \\ \mathbb{E}[X_n] \end{bmatrix}.$$

El operador esperanza: Propiedades

- El operador $\mathbb{E}[\cdot]$ es un operador lineal, luego $\forall \mathbf{A} \in \mathbb{R}^{m \times n}$ y $\forall \mathbf{b} \in \mathbb{R}^m$ tenemos:

$$\mathbb{E}[\mathbf{AX} + \mathbf{b}] = \mathbf{A}\mathbb{E}[\mathbf{X}] + \mathbf{b}.$$

- En forma general, si \mathbf{g} es una función $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^m$, tenemos

$$\mathbb{E}[\mathbf{g}(\mathbf{X})] = \begin{bmatrix} \mathbb{E}[g_1(\mathbf{X})] \\ \vdots \\ \mathbb{E}[g_m(\mathbf{X})] \end{bmatrix}.$$

La esperanza condicional

Sea un evento A . Luego, definimos el operador $\mathbb{E}[\cdot|A]$

$$\mathbb{E}[\mathbf{X}|A] = \int_{\mathbb{R}^n} \mathbf{x} f_{\mathbf{X}|A}(\mathbf{x}) d\mathbf{x}.$$

- En particular, si $A = \{X_1 = x_1\}$

$$\mathbb{E}[X_2|X_1 = x_1] = \int_{\mathbb{R}} x_2 f_{X_2}(x_2|X_1 = x_1) dx_2 = g(x_1).$$

Vemos que $\mathbb{E}[X_2|X_1 = x_1]$ es una función de x_1 . Si consideramos todas las posibles realizaciones de x_1 es decir, consideramos la aleatoriedad de X_1 , $g(X_1)$ es una VA.

Ley de la esperanza total

Tenemos la V.A. $g(X_1) = \mathbb{E}[X_2|X_1] = \int_{\mathbb{R}} x_2 f_{X_2|X_1}(x_2|X_1) dx_2$. Luego,

$$\begin{aligned}
 \mathbb{E}[g(X_1)] &= \mathbb{E}\left[\mathbb{E}[X_2|X_1]\right] = \int_{\mathbb{R}} g(x_1) f_{X_1}(x_1) dx_1 \\
 &= \int_{\mathbb{R}} \int_{\mathbb{R}} x_2 \underbrace{f_{X_2|X_1}(x_2|X_1 = x_1) f_{X_1}(x_1)}_{f_{X_1, X_2}(x_1, x_2)} dx_2 dx_1 \\
 &= \int_{\mathbb{R}} x_2 \underbrace{\int_{\mathbb{R}} f_{X_1, X_2}(x_1, x_2) dx_1}_{f_{X_2}(x_2)} dx_2 = \mathbb{E}[X_2]
 \end{aligned}$$

Propiedades de la esperanza condicional

- *Ley de esperanza total.* $\mathbb{E}[\mathbb{E}[\mathbf{X}|\mathbf{Y}]] = \mathbb{E}[\mathbf{X}]$.
- *Esperanza condicional de una constante.* $\mathbb{E}[\mathbf{a}|\mathbf{X}] = \mathbf{a}$.
- *Linealidad.* $\mathbb{E}[a\mathbf{Y} + b\mathbf{Z}|\mathbf{X}] = a\mathbb{E}[\mathbf{Y}|\mathbf{X}] + b\mathbb{E}[\mathbf{Z}|\mathbf{X}]$.
- *Esperanza condicional de una función.*
 $\mathbb{E}[\mathbf{g}(\mathbf{X})\mathbf{h}(\mathbf{Y})|\mathbf{X}] = \mathbf{g}(\mathbf{X})\mathbb{E}[\mathbf{h}(\mathbf{Y})|\mathbf{X}]$.
- *Redundancia en condiciones.* $\mathbb{E}[\mathbf{Y}|\mathbf{X}, \mathbf{g}(\mathbf{X})] = \mathbb{E}[\mathbf{Y}|\mathbf{X}]$.

Esperanza condicional de VA independientes

Si \mathbf{X} y \mathbf{Y} son independientes, entonces $\mathbb{E}[\mathbf{X}|\mathbf{Y}] = \mathbb{E}[\mathbf{X}]$.

Esta propiedad es una consecuencia directa de

$$f_{\mathbf{X},\mathbf{Y}}(\mathbf{x}, \mathbf{y}) = f_{\mathbf{X}}(\mathbf{x})f_{\mathbf{Y}}(\mathbf{y}) \iff \mathbf{X}, \mathbf{Y} \text{ independientes}$$

Función Característica

Función característica de una VA

En el análisis de señales y sistemas, la transformada de Fourier es una herramienta que permite simplificar ciertos análisis. Podemos incorporar esta herramienta también al analizar VA.

Para ello, definimos la *función característica* de una variable aleatoria:

$$\begin{aligned}\Phi_X : \mathbb{R} &\longrightarrow \mathbb{C} \\ \Phi_X(\omega) &= \mathbb{E}[e^{j\omega X}],\end{aligned}$$

donde $j = \sqrt{-1}$. Considerando la PDF generalizada, tenemos

$$\Phi_X(\omega) = \int_{-\infty}^{\infty} e^{j\omega x} f_X(x) dx.$$

Par transformado

- $\Phi_X(\omega)$ y $f_X(x)$ forman un par Fourier transformado:

$$\Phi_X(\omega) = \int_{-\infty}^{\infty} e^{j\omega x} f_X(x) dx = \mathcal{F}(f_X)(-\omega).$$

- Utilizando la transformada inversa obtenemos:

$$f_X(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-j\omega x} \Phi_X(\omega) d\omega = \mathcal{F}^{-1}(\Phi_X)(-x), \quad x \in \mathbb{R}.$$

Par transformado

Si X es una VAD que toma valores en $D = \{y_1, y_2, \dots\}$, tenemos

$$f_X(x) = \sum_{y \in D} p_X(y) \delta(x - y).$$

Luego,

$$\Phi_X(\omega) = \int_{-\infty}^{\infty} e^{j\omega x} \sum_{y \in D} p_X(y) \delta(x - y) dx = \sum_{y \in D} p_X(y) e^{j\omega y} = \mathcal{F}_d(p_X)(-\omega),$$

donde $\mathcal{F}_d(p_X)$ es la transformada de Fourier de tiempo discreto de la PMF p_X . Claramente,

$$p_X(x) = \frac{1}{2\pi} \int_{-\pi}^{+\pi} e^{-j\omega x} \Phi_X(\omega) d\omega = \mathcal{F}_d^{-1}(\Phi_X)(-x), \quad x \in D.$$

En el caso de una VAD, $\Phi_X(\omega) = \Phi_X(\omega + 2\pi)$ por propiedades de \mathcal{F}_d .

Función característica de un vector aleatorio

El concepto de función característica se puede ampliar a vectores aleatorios. Sea \mathbf{X} un VeA n -dimensional. Se define la función característica del siguiente modo:

$$\begin{aligned}\Phi_{\mathbf{X}} : \mathbb{R}^n &\rightarrow \mathbb{C} \\ \Phi_{\mathbf{X}}(\boldsymbol{\omega}) &= \mathbb{E}[e^{j\boldsymbol{\omega}^T \mathbf{X}}]\end{aligned}$$

- Como antes, la FC y la PDF de \mathbf{X} forman un par transformado:

$$\Phi_{\mathbf{X}}(\boldsymbol{\omega}) = \mathcal{F}\{f_{\mathbf{X}}\}(-\boldsymbol{\omega}) \quad , \quad f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^n} \int_{\mathbb{R}^n} \Phi_{\mathbf{X}}(\boldsymbol{\omega}) e^{-j\boldsymbol{\omega}^T \mathbf{x}} d\boldsymbol{\omega}.$$

- En este caso, la transformada de Fourier es multidimensional. Esto queda explícito al considerar el vector de n dimensiones $\boldsymbol{\omega}$.

Propiedades de la función característica

Sea $\mathbf{X} \in \mathbb{R}^n$ un vector aleatorio. Si $n = 1$ es una variable aleatoria.

- $\Phi_{\mathbf{X}}(0) = 1$
- La FC siempre existe y es máxima en el origen:

$$\begin{aligned} |\Phi_{\mathbf{X}}(\omega)| &= \left| \int_{-\infty}^{\infty} e^{j\omega^T \mathbf{x}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} \right| \leq \int_{-\infty}^{\infty} \left| e^{j\omega^T \mathbf{x}} f_{\mathbf{X}}(\mathbf{x}) \right| d\mathbf{x} \\ &= \int_{-\infty}^{\infty} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = \Phi_{\mathbf{X}}(0). \end{aligned}$$

- La FC de $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ donde $\mathbf{A} \in \mathbb{R}^{m \times n}$, y $\mathbf{b} \in \mathbb{R}^m$ es:

$$\begin{aligned} \Phi_{\mathbf{Y}}(\omega) &= \mathbb{E}[e^{j\omega^T \mathbf{Y}}] = \mathbb{E}[e^{j\omega^T (\mathbf{A}\mathbf{X} + \mathbf{b})}] \\ &= e^{j\omega^T \mathbf{b}} \mathbb{E}[e^{j\omega^T \mathbf{A}\mathbf{X}}] = e^{j\omega^T \mathbf{b}} \Phi_{\mathbf{X}}(\mathbf{A}^T \omega). \end{aligned}$$

- Si las componentes de \mathbf{X} son independientes

$$\Phi_{\mathbf{X}}(\omega) = \mathbb{E}[e^{j\omega^T \mathbf{X}}] = \mathbb{E}[e^{j\omega_1 X_1} \dots e^{j\omega_n X_n}] = \prod_{i=1}^n \mathbb{E}[e^{j\omega_i X_i}] = \prod_{i=1}^n \Phi_{X_i}(\omega_i).$$

Momentos de un vector aleatorio

Momentos de una variable aleatoria

Una VA se define con su CDF. Una alternativa es definir todos sus momentos.

- El *momento* de orden n de una VA X lo denotamos m_n y se define como

$$m_n = \mathbb{E}[X^n] = \int_{-\infty}^{\infty} x^n f_X(x) dx.$$

Momentos de componentes de un vector aleatorio

Podemos generalizar los conceptos de momentos a las componentes de un vector aleatorio.

- Los *momentos* se definen como

$$m_{i_1, \dots, i_n} = \mathbb{E}[X_1^{i_1} \dots X_n^{i_n}], \quad i_1, \dots, i_n \in \mathbb{N}_0.$$

Notar que esto incluye los momentos de cada una de las VAs X_1, \dots, X_n por separado. Por ejemplo:

$$m_{1,0,\dots,0} = \mathbb{E}[X_1] = \mu_{X_1}.$$

Teorema de los momentos

Consideramos primero $n = 1$.

- Derivando k veces Φ_X con respecto a ω obtenemos

$$\Phi_X^{(k)}(\omega) = \frac{\partial^k \Phi_X(\omega)}{\partial \omega^k} = \mathbb{E}[(jX)^k e^{j\omega X}].$$

- Evaluamos esta expresión en $\omega = 0$ y reordenamos:

$$\mathbb{E}[X^k] = \frac{1}{j^k} \Phi_X^{(k)}(0).$$

Este resultado nos permite obtener los momentos a partir de las derivadas de la FC, lo cual a veces resulta más sencillo que realizar la integración directa.

Teorema de los momentos

La generalización al caso vectorial es la siguiente:

$$\mathbb{E}[X_1^{i_1} \dots X_n^{i_n}] = \frac{1}{j^{i_1+\dots+i_n}} \frac{\partial^{i_1+\dots+i_n} \Phi_{\mathbf{X}}(\mathbf{0})}{\partial \omega_1^{i_1} \dots \partial \omega_n^{i_n}}.$$

La demostración es completamente análoga y queda como ejercicio.

Transformaciones de vectores aleatorios

Transformaciones de vectores aleatorios

Sea \mathbf{X} , \mathbf{Y} dos VeAs tal que $\mathbf{Y} = \mathbf{g}(\mathbf{X})$ donde

$$\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

En general, la CDF de \mathbf{Y} es

$$F_{\mathbf{Y}}(\mathbf{y}) = \mathbb{P}(\mathbf{Y} \leq \mathbf{y}) = \mathbb{P}(\mathbf{g}(\mathbf{X}) \leq \mathbf{y}) = \int_{R_{\mathbf{y}}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x},$$

donde $R_{\mathbf{y}} = \{\mathbf{x} : \mathbf{g}(\mathbf{x}) \leq \mathbf{y}\}$. Podemos obtener la PDF de \mathbf{Y} (posiblemente generalizada) como

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{\partial^m F_{\mathbf{Y}}(\mathbf{y})}{\partial y_1 \dots \partial y_m}.$$

Transformaciones de vectores aleatorios

Una alternativa al procedimiento anterior, es hallar la FC de \mathbf{Y} y luego tomar la antitransformada de Fourier para hallar $f_{\mathbf{Y}}(\mathbf{y})$. Analizaremos este procedimiento en el caso de una función afín.

Distribución de una combinación lineal de VA

Sea $Y = \sum_{i=1}^n a_i X_i = \mathbf{a}^T \mathbf{X}$.

- Usando las propiedades de la FC, tenemos que

$$f_Y(y) = \mathcal{F}^{-1} [\Phi_Y(\omega)] (-y) = \mathcal{F}^{-1} [\Phi_{\mathbf{X}}(\mathbf{a}\omega)]$$

- Si las componentes de \mathbf{X} son independientes tenemos que

$$\Phi_{\mathbf{X}}(\mathbf{a}\omega) = \prod_{i=1}^n \Phi_{X_i}(a_i\omega).$$

Distribución de una combinación lineal de VA

- Por la propiedad de escalado de Fourier,

$$\mathcal{F}^{-1}(\Phi_X(a\omega))(y) = \frac{1}{|a|} f_X\left(\frac{y}{a}\right)$$

- Luego, por el teorema de convolución de Fourier,

$$\begin{aligned} f_Y(y) &= \mathcal{F}^{-1}\left[\prod_{i=1}^n \Phi_{X_i}(a_i\omega)\right] \\ &= \frac{1}{2\pi} \int_{\mathbb{R}} \left(\prod_{i=1}^n \Phi_{X_i}(a_i\omega)\right) e^{-j\omega y} d\omega \\ &= \frac{1}{|a_1|} f_{X_1}\left(\frac{y}{a_1}\right) * \dots * \frac{1}{|a_n|} f_{X_n}\left(\frac{y}{a_n}\right). \end{aligned}$$

Suma de V.A independientes

Sean X_1, \dots, X_n independientes

Si $Y = \sum_{i=1}^n X_i$

$$f_Y(y) = f_{X_1}(y) * \dots * f_{X_n}(y).$$

Transformación lineal o afín (caso biyectivo)

Sea $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$, con \mathbf{A} una matriz cuadrada y no singular. Vimos que

$$\Phi_{\mathbf{Y}}(\omega) = \Phi_{\mathbf{X}}(\mathbf{A}^T \omega) e^{j\omega^T \mathbf{b}}$$

Considerando el par transformado entre la FC y la PDF,

$$\begin{aligned} f_{\mathbf{Y}}(\mathbf{y}) &= \frac{1}{(2\pi)^n} \int_{\mathbb{R}^n} \Phi_{\mathbf{X}}(\mathbf{A}^T \omega) e^{j\omega^T (\mathbf{b} - \mathbf{y})} d\omega \\ &= \frac{1}{(2\pi)^n} \int_{\mathbb{R}^n} \Phi_{\mathbf{X}}(\mathbf{A}^T \omega) e^{-j\omega^T \mathbf{A} \mathbf{A}^{-1} (\mathbf{y} - \mathbf{b})} d\omega \\ &= \frac{1}{(2\pi)^n} \int_{\mathbb{R}^n} \Phi_{\mathbf{X}}(\mathbf{A}^T \omega) e^{-j(\mathbf{A}^T \omega)^T \mathbf{A}^{-1} (\mathbf{y} - \mathbf{b})} d\omega \end{aligned}$$

Transformación lineal o afín (caso biyectivo)

Haciendo un cambio de variable $\boldsymbol{\nu} = \mathbf{A}^T \boldsymbol{\omega}$, tenemos

$$\begin{aligned}
 f_Y(\mathbf{y}) &= \frac{1}{(2\pi)^n} \frac{1}{|\det(\mathbf{A}^T)|} \int_{\mathbb{R}^n} \Phi_X(\boldsymbol{\nu}) e^{-j\boldsymbol{\nu}^T \mathbf{A}^{-1}(\mathbf{y}-\mathbf{b})} d\boldsymbol{\nu} \\
 &= \frac{1}{|\det(\mathbf{A})|} \underbrace{\frac{1}{(2\pi)^n} \int_{\mathbb{R}^n} \Phi_X(\boldsymbol{\nu}) e^{-j\boldsymbol{\nu}^T \mathbf{A}^{-1}(\mathbf{y}-\mathbf{b})} d\boldsymbol{\nu}}_{\mathcal{F}^{-1}(\Phi_X)(-\mathbf{A}^{-1}(\mathbf{y}-\mathbf{b}))} \\
 &= \frac{f_X(\mathbf{A}^{-1}(\mathbf{y}-\mathbf{b}))}{|\det(\mathbf{A})|}, \quad \mathbf{y} \in \mathbb{R}^n.
 \end{aligned}$$

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$$

$$f_Y(\mathbf{y}) = \frac{f_X(\mathbf{A}^{-1}(\mathbf{y}-\mathbf{b}))}{|\det(\mathbf{A})|}$$

Transformación biyectiva y suave

- Sea $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ una función inversible
- Luego, $\mathbf{g}(\mathbf{x}) = \mathbf{y}$ tiene una única solución.
- Sea $E(\mathbf{x}_0)$ un entorno alrededor de \mathbf{x}_0 y $F(\mathbf{x}_0) = \{\mathbf{g}(\mathbf{x}) : \mathbf{x} \in E(\mathbf{x}_0)\}$ el entorno alrededor de $\mathbf{g}(\mathbf{x}_0)$.
Luego,

$$\mathbb{P}(\mathbf{X} \in E(\mathbf{x}_0)) = \mathbb{P}(\mathbf{Y} \in F(\mathbf{x}_0)) \Rightarrow \int_{E(\mathbf{x}_0)} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = \int_{F(\mathbf{x}_0)} f_{\mathbf{Y}}(\mathbf{y}) d\mathbf{y}.$$

Transformación biyectiva y suave

- Considerando un cambio de variable en la integral, obtenemos la siguiente relación entre las PDFs conjuntas:

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{f_{\mathbf{X}}(\mathbf{g}^{-1}(\mathbf{y}))}{|\det(J(\mathbf{g}^{-1}(\mathbf{y})))|},$$

donde J es el Jacobiano de la transformación dado por

$$J(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1}(\mathbf{x}) & \dots & \frac{\partial g_1}{\partial x_n}(\mathbf{x}) \\ \vdots & \vdots & \vdots \\ \frac{\partial g_n}{\partial x_1}(\mathbf{x}) & \dots & \frac{\partial g_n}{\partial x_n}(\mathbf{x}) \end{bmatrix}.$$

Transformación general suave

- Si $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ es una función suave pero no inversible, dado un \mathbf{y} la ecuación $\mathbf{g}(\mathbf{x}) = \mathbf{y}$ tiene en general varias soluciones $\mathbf{x}_1, \dots, \mathbf{x}_k$.
- En este caso, hay que sumar las contribuciones de cada una de las soluciones. Luego,

$$f_{\mathbf{Y}}(\mathbf{y}) = \sum_{i=1}^k \frac{f_{\mathbf{X}}(\mathbf{x}_i)}{|\det(J(\mathbf{x}_i))|},$$

donde $J(\mathbf{x}_i)$ es el Jacobiano de la transformación dado por

$$J(\mathbf{x}_i) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1}(\mathbf{x}_i) & \dots & \frac{\partial g_1}{\partial x_n}(\mathbf{x}_i) \\ \vdots & \vdots & \vdots \\ \frac{\partial g_n}{\partial x_1}(\mathbf{x}_i) & \dots & \frac{\partial g_n}{\partial x_n}(\mathbf{x}_i) \end{bmatrix}.$$

Transformación general suave

El método anterior también se puede aplicar a una transformación $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ con $m \neq n$ agregando variables auxiliares X_i o Y_i de forma tal que se obtenga una nueva transformación $\mathbf{h} : \mathbb{R}^p \rightarrow \mathbb{R}^p$ donde $p = \max(n, m)$.