

# Estimación Lineal

Cecilia Galarza

Procesos Estocásticos  
Facultad de Ingeniería, Universidad de Buenos Aires

1er cuatrimestre 2025

# Estimación de Menor Error Cuadrático Medio

Sean  $\mathbf{X} \in \mathbb{R}^n$  e  $\mathbf{Y} \in \mathbb{R}^m$  dos vectores aleatorios, cuya estadística conjunta es conocida. Se desea estimar  $\mathbf{X}$  a partir de la observación de una realización  $\mathbf{y}$ , es decir, se busca una función

$$g(\mathbf{y}) : \mathbb{R}^m \rightarrow \mathbb{R}^n \text{ tal que} \\ \hat{\mathbf{x}} = g(\mathbf{y}) \text{ esté cercano a } \mathbf{X}$$

Si  $\hat{\mathbf{x}} = g(\mathbf{y})$  es visto como la transformación del VeA  $\mathbf{Y}$ , entonces  $\hat{\mathbf{X}}$  es un VeA. Un posible criterio de *cercanía* es el *Error Cuadrático Medio* (MSE, *Mean Square Error*)

Criterio  $\leftarrow$   $MSE(\hat{\mathbf{X}}) = \mathbb{E} [\|\mathbf{X} - \hat{\mathbf{X}}\|^2]$

# Estimador MMSE

## Definición (Estimador MMSE)

*El estimador MMSE (Minimum Mean Square Error) es el que minimiza  $MSE(\hat{\mathbf{X}})$ ,*

$$\hat{\mathbf{X}}_{mmse} = \arg \min_{\hat{\mathbf{X}}=g(\mathbf{Y})} \mathbb{E} \left[ \|\mathbf{X} - \hat{\mathbf{X}}\|^2 \right]$$

## Teorema

*El estimador MMSE es la esperanza condicional*

$$\hat{\mathbf{X}}_{mmse} = \mathbb{E} [\mathbf{X} | \mathbf{Y}]$$

# $\hat{\mathbf{X}}_{mmse}$ es la esperanza condicional: demostración

Para simplificar notación, llamamos:

$$\mu(\mathbf{Y}) = \mathbb{E}[\mathbf{X}|\mathbf{Y}] \quad \text{y} \quad \Delta(\mathbf{Y}) = \mu(\mathbf{Y}) - \hat{\mathbf{X}}(\mathbf{Y}).$$

Luego,

$$\mathbf{X} - \hat{\mathbf{X}}(\mathbf{Y}) = \mathbf{X} - \mu(\mathbf{Y}) + \mu(\mathbf{Y}) - \hat{\mathbf{X}}(\mathbf{Y}) = \mathbf{X} - \mu(\mathbf{Y}) + \Delta(\mathbf{Y}).$$

Retomando el MSE

$$\begin{aligned} MSE &= \mathbb{E} \left[ \|\mathbf{X} - \hat{\mathbf{X}}\|^2 \right] = \mathbb{E} \left[ (\mathbf{X} - \hat{\mathbf{X}})^t (\mathbf{X} - \hat{\mathbf{X}}) \right] \\ &= \mathbb{E} \left[ (\mathbf{X} - \mu + \Delta)^t (\mathbf{X} - \mu + \Delta) \right] \\ &= \underbrace{\mathbb{E} \left[ \|\mathbf{X} - \mu\|^2 \right]}_{\textcircled{1}} + \underbrace{\mathbb{E} \left[ (\mathbf{X} - \mu)^t \Delta \right] + \mathbb{E} \left[ \Delta^t (\mathbf{X} - \mu) \right]}_{\textcircled{2}} + \underbrace{\mathbb{E} \left[ \Delta^t \Delta \right]}_{\textcircled{3}} \end{aligned}$$

# $\hat{\mathbf{X}}_{mmse}$ es la esperanza condicional: demostración

$$\textcircled{1} = \mathbb{E} [\|\mathbf{X} - \mu(\mathbf{Y})\|^2]$$

No depende de  $\hat{\mathbf{X}}$ , no lo considero para la minimización

# $\hat{\mathbf{X}}_{mmse}$ es la esperanza condicional: demostración

$$\begin{aligned}
 \textcircled{2} &= \mathbb{E} \left[ (\mathbf{X} - \mu)^t \underbrace{(\mu - \hat{\mathbf{X}})}_{\Delta(\mathbf{Y})} \right] + \mathbb{E} \left[ \underbrace{(\mu - \hat{\mathbf{X}})^t}_{\Delta(\mathbf{Y})^t} (\mathbf{X} - \mu) \right] \\
 &= 2\mathbb{E} \left[ (\mathbf{X} - \mu(\mathbf{Y}))^t \Delta(\mathbf{Y}) \right]
 \end{aligned}$$

Recordemos que  $\forall \mathbf{X}, \mathbf{Y}, \mathbb{E}[\mathbf{X}] = \mathbb{E}_{\mathbf{X}}[\mathbb{E}_{\mathbf{X}|\mathbf{Y}}[\mathbf{X}|\mathbf{Y}]]$ .

$$\begin{aligned}
 \mathbb{E} \left[ (\mathbf{X} - \mu(\mathbf{Y}))^t \Delta(\mathbf{Y}) \right] &= \mathbb{E} \left[ \mathbb{E}[(\mathbf{X} - \mu(\mathbf{Y}))^t \Delta(\mathbf{Y}) | \mathbf{Y}] \right] \\
 &= \mathbb{E} \left[ \mathbb{E} [\mathbf{X}^t \Delta(\mathbf{Y}) - \mu(\mathbf{Y})^t \Delta(\mathbf{Y}) | \mathbf{Y}] \right] \\
 &= \mathbb{E} \left[ \underbrace{\mathbb{E}[\mathbf{X}^t | \mathbf{Y}]}_{\mu(\mathbf{Y})^t} \Delta(\mathbf{Y}) - \mu(\mathbf{Y})^t \Delta(\mathbf{Y}) \right] = 0
 \end{aligned}$$

$\hat{\mathbf{X}}_{mmse}$  es la esperanza condicional: demostración

$$\textcircled{3} = \mathbb{E} \left[ \|\Delta(\mathbf{Y})\|^2 \right] = \mathbb{E} \left[ \left\| \mu(\mathbf{Y}) - \hat{\mathbf{X}} \right\|^2 \right] = \mathbb{E} \left[ \left\| \mathbb{E}[\mathbf{X} | \mathbf{Y}] - \hat{\mathbf{X}} \right\|^2 \right]$$

# $\hat{\mathbf{X}}_{mmse}$ es la esperanza condicional: demostración

## Recapitulando

- ①, no depende de  $\hat{\mathbf{X}}$
- ② es nulo
- ③ =  $\mathbb{E} \left[ \left\| \mathbb{E}[\mathbf{X}|\mathbf{Y}] - \hat{\mathbf{X}} \right\|^2 \right]$


Minimizar MSE con respecto a  $\hat{\mathbf{X}}(\mathbf{Y})$  equivale a minimizar ③. Luego,

$$\hat{\mathbf{X}}_{mmse} = \mathbb{E}[\mathbf{X}|\mathbf{Y}].$$



# Principio de ortogonalidad

Recordemos que  $\mathbf{X}$  y  $\mathbf{Y}$  son ortogonales sii  $\mathbb{E}[\mathbf{X}^t \mathbf{Y}] = 0$ .



$$\begin{aligned} \mathbb{E} \left[ \hat{\mathbf{X}}_{mmse}^t(\mathbf{Y}) \left( \mathbf{X} - \hat{\mathbf{X}}_{mmse}(\mathbf{Y}) \right) \right] &= \mathbb{E}_{\mathbf{Y}} \left[ \mathbb{E}_{\mathbf{X}|\mathbf{Y}} \left[ \hat{\mathbf{X}}_{mmse}^t(\mathbf{y}) \mathbf{X} - \hat{\mathbf{X}}_{mmse}^t(\mathbf{y}) \hat{\mathbf{X}}_{mmse}(\mathbf{y}) \mid \mathbf{y} \right] \right] \\ &= \mathbb{E}_{\mathbf{Y}} \left[ \hat{\mathbf{X}}_{mmse}^t \mathbb{E}[\mathbf{X}|\mathbf{Y}] - \hat{\mathbf{X}}_{mmse}^t \hat{\mathbf{X}}_{mmse} \right] = 0 \end{aligned}$$

Los vectores  $\hat{\mathbf{X}}_{mmse}$  y  $(\mathbf{X} - \hat{\mathbf{X}}_{mmse})$  son ortogonales entre sí

# Ejemplo

Sea la VA  $Y = X + W$  donde  $X \sim \text{Ber}(p)$  y  $W \sim \mathcal{N}(0, 1)$ ,  $X$  y  $W$  independientes. Halle el estimador MMSE de  $X$  al observar  $Y$ .

Sabemos que

$$\hat{X}_{mmse} = \mathbb{E}[X|Y].$$

Planteamos

$$\varphi(y) = \mathbb{E}[X|Y = y].$$

Esta función se conoce como función de *regresión*.

## Ejemplo (cont.)

Como  $X \sim \text{Ber}(p)$ ,

$$\varphi(y) = 0 \mathbb{P}(X = 0 | Y = y) + 1 \mathbb{P}(X = 1 | Y = y) = \mathbb{P}(X = 1 | Y = y).$$

Usando la definición de probabilidad condicional y Bayes:

$$\mathbb{P}(X = 1 | Y = y) = \frac{f_{Y|X=1}(y) \mathbb{P}(X = 1)}{f_Y(y)}.$$

Por definición  $Y$  es una mezcla de gaussianas:

$$f_Y(y) = (1 - p) \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} + p \frac{1}{\sqrt{2\pi}} e^{-\frac{(y-1)^2}{2}}.$$

Por otro lado,

$$f_{Y|X=1}(y) = f_W(y - 1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(y-1)^2}{2}}.$$

## Ejemplo (cont.)

Combinando todo se tiene:

$$\begin{aligned}\varphi(y) &= \frac{pe^{-\frac{(y-1)^2}{2}}}{(1-p)e^{-\frac{y^2}{2}} + pe^{-\frac{(y-1)^2}{2}}} = \frac{p}{(1-p)e^{-\frac{1}{2}[y^2-(y-1)^2]} + p} \\ &= \frac{p}{p + (1-p)e^{\frac{1}{2}-y}}.\end{aligned}$$

$$\longrightarrow \hat{X}_{mmse} = \frac{p}{p + (1-p)e^{\frac{1}{2}}e^{-y}}.$$

*Observaciones:*

- $X \in \{0, 1\}$ , pero  $\hat{X}_{mmse} \in [0, 1]$ .
- $\phi(y) = \frac{p}{p+(1-p)e^{\frac{1}{2}}e^{-y}} \longrightarrow$  función no-lineal en  $y$ .

# Notación

$$\mu_{\mathbf{X}} = \mathbb{E}[\mathbf{X}] \quad , \quad \mathbf{C}_{\mathbf{X}} = \mathbb{E} \left[ (\mathbf{X} - \mu_{\mathbf{X}}) (\mathbf{X} - \mu_{\mathbf{X}})^t \right]$$

$$\mu_{\mathbf{Y}} = \mathbb{E}[\mathbf{Y}] \quad , \quad \mathbf{C}_{\mathbf{Y}} = \mathbb{E} \left[ (\mathbf{Y} - \mu_{\mathbf{Y}}) (\mathbf{Y} - \mu_{\mathbf{Y}})^t \right] \quad , \quad \mathbf{R}_{\mathbf{Y}} = \mathbb{E}[\mathbf{Y}\mathbf{Y}^t]$$

$$\mathbf{R}_{\mathbf{XY}} = \mathbb{E}[\mathbf{X}\mathbf{Y}^t] \quad , \quad \mathbf{C}_{\mathbf{XY}} = \mathbb{E} \left[ (\mathbf{X} - \mu_{\mathbf{X}}) (\mathbf{Y} - \mu_{\mathbf{Y}})^t \right]$$

# Estimador Lineal de Menor Error Cuadrático Medio (LMMSE)

Es interesante limitar la búsqueda de  $\hat{\mathbf{X}} = g(\mathbf{Y})$  a estimadores del tipo,

$$g(\mathbf{Y}) = \mathbf{A}\mathbf{Y} + \mathbf{b}.$$

donde  $\mathbf{A} \in \mathbb{C}^{n \times m}$  y  $\mathbf{b} \in \mathbb{C}^n$  son constantes. Para minimizar el MSE planteamos el principio de ortogonalidad, es decir

$$\mathbb{E} \left[ \underbrace{(\mathbf{A}\mathbf{Y} + \mathbf{b})^t}_{\hat{\mathbf{x}}^t} \underbrace{(\mathbf{X} - \mathbf{A}\mathbf{Y} - \mathbf{b})}_{\mathbf{x} - \hat{\mathbf{x}}} \right] = 0 \quad (1)$$

# LMMSE

Por el principio de ortogonalidad, tenemos

$$\mathbb{E} \left[ \underbrace{(\mathbf{A}\mathbf{Y} + \mathbf{b})^t}_{\hat{\mathbf{X}}^t} \underbrace{(\mathbf{X} - \mathbf{A}\mathbf{Y} - \mathbf{b})}_{\mathbf{X} - \hat{\mathbf{X}}} \right] = 0.$$

Como  $\hat{\mathbf{X}}^t(\mathbf{X} - \hat{\mathbf{X}}) \in \mathbb{R} \implies \hat{\mathbf{X}}^t(\mathbf{X} - \hat{\mathbf{X}}) = \text{tr} [\hat{\mathbf{X}}^t(\mathbf{X} - \hat{\mathbf{X}})]$ .

Entonces, buscamos  $\mathbf{A}$  y  $\mathbf{b}$  tal que

$$\mathbb{E} \left\{ \text{tr} \left[ (\mathbf{A}\mathbf{Y} + \mathbf{b})^t (\mathbf{X} - \mathbf{A}\mathbf{Y} - \mathbf{b}) \right] \right\} = 0$$

## LMMSE

Recordando que  $\text{tr}(ABC) = \text{tr}(BCA) = \text{tr}(CAB)$ , desarrollamos

$$\begin{aligned}
 0 &= \mathbb{E} \left\{ \text{tr} \left[ (\mathbf{A}\mathbf{Y} + \mathbf{b})^t (\mathbf{X} - \mathbf{A}\mathbf{Y} - \mathbf{b}) \right] \right\} \\
 &= \mathbb{E} \left\{ \text{tr} \left[ \mathbf{Y}^t \mathbf{A}^t \mathbf{X} + \mathbf{b}^t \mathbf{X} - \mathbf{Y}^t \mathbf{A}^t \mathbf{A} \mathbf{Y} - \mathbf{b}^t \mathbf{A} \mathbf{Y} - \mathbf{Y}^t \mathbf{A}^t \mathbf{b} - \mathbf{b}^t \mathbf{b} \right] \right\} \\
 &= \mathbb{E} \left\{ \text{tr} \left[ \mathbf{Y}^t \mathbf{A}^t \mathbf{X} \right] \right\} + \mathbb{E} \left[ \mathbf{b}^t \mathbf{X} \right] - \mathbb{E} \left\{ \text{tr} \left[ \mathbf{Y}^t \mathbf{A}^t \mathbf{A} \mathbf{Y} \right] \right\} - \mathbb{E} \left[ \mathbf{b}^t \mathbf{A} \mathbf{Y} \right] - \mathbb{E} \left[ \mathbf{Y}^t \mathbf{A}^t \mathbf{b} \right] - \mathbf{b}^t \mathbf{b} \\
 &= \mathbb{E} \left\{ \text{tr} \left[ \mathbf{A}^t \mathbf{X} \mathbf{Y}^t \right] \right\} + \mathbf{b}^t \mu_{\mathbf{X}} - \mathbb{E} \left\{ \text{tr} \left[ \mathbf{A}^t \mathbf{A} \mathbf{Y} \mathbf{Y}^t \right] \right\} - \mathbf{b}^t \mathbf{A} \mu_{\mathbf{Y}} - \mu_{\mathbf{Y}}^t \mathbf{A}^t \mathbf{b} - \mathbf{b}^t \mathbf{b} \\
 &= \text{tr} \left\{ \mathbb{E} \left[ \mathbf{A}^t \mathbf{X} \mathbf{Y}^t \right] \right\} + \mathbf{b}^t \mu_{\mathbf{X}} - \text{tr} \left\{ \mathbb{E} \left[ \mathbf{A}^t \mathbf{A} \mathbf{Y} \mathbf{Y}^t \right] \right\} - \mathbf{b}^t \mathbf{A} \mu_{\mathbf{Y}} - \mu_{\mathbf{Y}}^t \mathbf{A}^t \mathbf{b} - \mathbf{b}^t \mathbf{b} \\
 &= \text{tr} \left\{ \mathbf{A}^t \mathbb{E} \left[ \mathbf{X} \mathbf{Y}^t \right] \right\} + \mathbf{b}^t \mu_{\mathbf{X}} - \text{tr} \left\{ \mathbf{A}^t \mathbf{A} \mathbb{E} \left[ \mathbf{Y} \mathbf{Y}^t \right] \right\} - \mathbf{b}^t \mathbf{A} \mu_{\mathbf{Y}} - \mu_{\mathbf{Y}}^t \mathbf{A}^t \mathbf{b} - \mathbf{b}^t \mathbf{b} \\
 &= \text{tr} \left[ \mathbf{A}^t (\mathbf{R}_{\mathbf{X}\mathbf{Y}} - \mathbf{A} \mathbf{R}_{\mathbf{Y}} - \mathbf{b} \mu_{\mathbf{Y}}^t) \right] + \mathbf{b}^t [\mu_{\mathbf{X}} - \mathbf{A} \mu_{\mathbf{Y}} - \mathbf{b}].
 \end{aligned}$$



# LMMSE

La matriz **A** y el vector **b** que corresponden al estimador LMMSE deben cumplir el siguiente sistema de ecuaciones:

$$\begin{cases} \mathbf{A}\mathbf{R}_Y + \mathbf{b}\mu_Y^t = \mathbf{R}_{XY} \\ \mathbf{A}\mu_Y + \mathbf{b} = \mu_X \end{cases}$$

cuya solución es

$$\mathbf{A}_{lmmse} = [\mathbf{R}_{XY} - \mu_X\mu_Y^t] [\mathbf{R}_Y - \mu_Y\mu_Y^t]^{-1} = \mathbf{C}_{XY}\mathbf{C}_Y^{-1}$$

$$\mathbf{b}_{lmmse} = \mu_X - [\mathbf{R}_{XY} - \mu_X\mu_Y^t] [\mathbf{R}_Y - \mu_Y\mu_Y^t]^{-1} \mu_Y = \mu_X - \mathbf{C}_{XY}\mathbf{C}_Y^{-1} \mu_Y$$

# LMMSE

Estimador Lineal de Menor Error Cuadrático Medio (LMMSE)

$$\hat{\mathbf{X}}_{lmmse} = \mu_{\mathbf{X}} + \mathbf{C}_{\mathbf{XY}}\mathbf{C}_{\mathbf{Y}}^{-1}(\mathbf{Y} - \mu_{\mathbf{Y}}). \quad (2)$$

Cuando  $\mathbf{X}$  e  $\mathbf{Y}$  son dos vectores conjuntamente gaussianos,

$$\hat{\mathbf{X}}_{lmmse} = \hat{\mathbf{X}}_{mmse}$$

# LMMSE: Propiedades

- $\hat{\mathbf{X}}_{Immse}$  es un estimador *insesgado*. Se lo conoce también como el estimador BLU (Best Linear Unbiased).

$$\mathbb{E}[\hat{\mathbf{X}}_{Immse}] = \mathbb{E}[\mu_{\mathbf{X}} + \mathbf{C}_{\mathbf{X}\mathbf{Y}}\mathbf{C}_{\mathbf{Y}}^{-1}(\mathbf{Y} - \mu_{\mathbf{Y}})] = \mu_{\mathbf{X}}$$

# LMMSE: Propiedades

El error de estimación es:

$$\mathbf{E}_{lmmse} = \mathbf{X} - \hat{\mathbf{X}}_{lmmse} = \underbrace{(\mathbf{X} - \mu_{\mathbf{X}})}_{\delta_{\mathbf{X}}} - \mathbf{C}_{\mathbf{X}\mathbf{Y}}\mathbf{C}_{\mathbf{Y}}^{-1} \underbrace{(\mathbf{Y} - \mu_{\mathbf{Y}})}_{\delta_{\mathbf{Y}}}.$$

Recordemos que

$$\mathbf{C}_{\mathbf{X}} = \mathbb{E}[\delta_{\mathbf{X}}\delta_{\mathbf{X}}^t] \quad , \quad \mathbf{C}_{\mathbf{Y}} = \mathbb{E}[\delta_{\mathbf{Y}}\delta_{\mathbf{Y}}^t] \quad , \quad \mathbf{C}_{\mathbf{X}\mathbf{Y}} = \mathbb{E}[\delta_{\mathbf{X}}\delta_{\mathbf{Y}}^t].$$

Luego, la covarianza del error resulta:

$$\begin{aligned} \mathbf{Cov}[\mathbf{E}_{lmmse}] &= \mathbb{E} [\mathbf{E}_{lmmse} \mathbf{E}_{lmmse}^t] = \mathbb{E} \left[ \left( \delta_{\mathbf{X}} - \mathbf{C}_{\mathbf{X}\mathbf{Y}}\mathbf{C}_{\mathbf{Y}}^{-1}\delta_{\mathbf{Y}} \right) \left( \delta_{\mathbf{X}} - \mathbf{C}_{\mathbf{X}\mathbf{Y}}\mathbf{C}_{\mathbf{Y}}^{-1}\delta_{\mathbf{Y}} \right)^t \right] \\ &= \mathbb{E} [\delta_{\mathbf{X}}\delta_{\mathbf{X}}^t] - \mathbb{E} [\delta_{\mathbf{X}}\delta_{\mathbf{Y}}^t] \mathbf{C}_{\mathbf{Y}}^{-1} \mathbf{C}_{\mathbf{Y}\mathbf{X}} - \mathbf{C}_{\mathbf{X}\mathbf{Y}}\mathbf{C}_{\mathbf{Y}}^{-1} \mathbb{E} [\delta_{\mathbf{Y}}\delta_{\mathbf{X}}^t] \\ &\quad + \mathbf{C}_{\mathbf{X}\mathbf{Y}}\mathbf{C}_{\mathbf{Y}}^{-1} \mathbb{E} [\delta_{\mathbf{Y}}\delta_{\mathbf{Y}}^t] \mathbf{C}_{\mathbf{Y}}^{-1} \mathbf{C}_{\mathbf{Y}\mathbf{X}} \\ &= \mathbf{C}_{\mathbf{X}} - \mathbf{C}_{\mathbf{X}\mathbf{Y}}\mathbf{C}_{\mathbf{Y}}^{-1} \mathbf{C}_{\mathbf{Y}\mathbf{X}} \end{aligned}$$

# LMMSE: Propiedades

Finalmente, el error cuadrático medio es

$$\begin{aligned}
 MMSE &= \mathbb{E} \left[ \|\mathbf{E}_{lmmse}\|^2 \right] = \mathbb{E} [\mathbf{E}_{lmmse}^t \mathbf{E}_{lmmse}] \\
 &= \mathbb{E} [\text{tr}(\mathbf{E}_{lmmse}^t \mathbf{E}_{lmmse})] = \mathbb{E} [\text{tr}(\mathbf{E}_{lmmse} \mathbf{E}_{lmmse}^t)] \\
 &= \text{tr} \{ \mathbb{E} [\mathbf{E}_{lmmse} \mathbf{E}_{lmmse}^t] \} \\
 &= \text{tr} \{ \mathbf{Cov}[\mathbf{E}_{lmmse}] \}
 \end{aligned}$$

# LMMSE: resumen

$$\hat{\mathbf{X}}_{lmmse} = \mu_{\mathbf{X}} + \mathbf{C}_{\mathbf{XY}}\mathbf{C}_{\mathbf{Y}}^{-1}(\mathbf{Y} - \mu_{\mathbf{Y}}).$$

$$\mathbb{E}[\hat{\mathbf{X}}_{lmmse}] = \mu_{\mathbf{X}}.$$

$$\mathbf{Cov}[\mathbf{E}_{lmmse}] = \mathbf{C}_{\mathbf{X}} - \mathbf{C}_{\mathbf{XY}}\mathbf{C}_{\mathbf{Y}}^{-1}\mathbf{C}_{\mathbf{YX}}.$$

$$MMSE = \text{tr} \left\{ \mathbf{C}_{\mathbf{X}} - \mathbf{C}_{\mathbf{XY}}\mathbf{C}_{\mathbf{Y}}^{-1}\mathbf{C}_{\mathbf{YX}} \right\}.$$

# Estimación lineal de procesos aleatorios

Sean  $X(n)$  e  $Y(n)$  dos procesos aleatorios.

## Problema

A partir de muestras de una realización  $y(m)$ , recolectadas en el intervalo  $m_{init} \leq m \leq m_{fin}$ , hallar el estimador

$$\hat{x}(n) = \sum_{m=m_{init}}^{m_{fin}} k_{nm} y(m)$$

que minimice el error cuadrático medio

$$\mathbb{E} \left[ \left\| X - \hat{X}_{lmmse} \right\|^2 \right] = \mathbb{E} \left[ \sum_n \left| X(n) - \hat{X}_{lmmse}(n) \right|^2 \right]$$

El problema de estimación es entonces obtener los coeficientes  $k_{nm}$ .

# Dos posibles esquemas de estimación

① **Suavizado** (*smoothing*)  $m_{init} = m_0$ ,  $m_{fin} = m_0 + M$ .

Dado  $\{y(m), m_0 \leq m \leq m_0 + M\}$  obtener  $\{\hat{x}(n), n_1 \leq n \leq n_2\}$   
 donde  $m_0 \leq n_1 \leq n_2 \leq m_0 + M$ .

Estimador *no causal* ya que utiliza observaciones futuras.

② **Filtrado**  $m_{init} = n - M$ ,  $m_{fin} = n$ .

Dado  $\{y(m), n - M \leq m \leq n\}$  obtener  $\hat{x}(n)$ .

Estimador *causal* que utiliza pasado y presente.



# Análisis del problema

- Vamos a trabajar con observaciones en una ventana de duración finita es decir que todas las observaciones se pueden agrupar en un vector

$$\mathbf{Y} = \begin{bmatrix} Y(m_{init}) \\ \vdots \\ Y(m_{fin}) \end{bmatrix}$$

- Para cada valor de  $n$ , se puede considerar un problema de estimación de una VA,  $X_n = X(n)$  a partir de un VeA,  $\mathbf{Y}$ .
- La solución LMMSE a este problema la conocemos

$$\hat{X}_{lmmse}(n) = \mu_{X_n} + \mathbf{C}_{X_n \mathbf{Y}} \mathbf{C}_{\mathbf{Y}}^{-1} (\mathbf{Y} - \mu_{\mathbf{Y}}).$$

- El problema es entonces poder implementar esta solución en forma eficiente para cada instante de tiempo  $n$ .

# Hipótesis

Asumimos lo siguiente:

- $X(n)$  e  $Y(n)$  son conjuntamente ESA
- Las correlaciones siguientes son conocidas:

$$R_{XY}(k) = \mathbb{E}[X(n)Y(n+k)] \quad \text{y} \quad R_Y(k) = \mathbb{E}[Y(n)Y(n+k)].$$

- Como el estimador LMMSE es insesgado, sin falta de generalidad

$$\mathbb{E}[X(n)] = \mathbb{E}[Y(n)] = 0.$$

Entonces,

$$\hat{X}_{lmmse}(n) = \mathbf{R}_{X_n} \mathbf{R}_Y^{-1} \mathbf{Y}.$$


*→ cte en el tiempo*

*→ evoluciona en el tiempo*

# Problema de suavizado en una ventana fija

Como los procesos son CESA, sin falta de generalidad  $m_0 = 0$ .

$$\{y(m), m = 0, \dots, M\} \longrightarrow \hat{x}(n), 0 \leq n \leq M.$$



$$\hat{X}_{Immse}(n) = \hat{X}(n) = \mathbf{R}_{X_n Y} \mathbf{R}_Y^{-1} \mathbf{Y}.$$

# Problema de suavizado en una ventana fija (cont)

- *Matriz de autocorrelación* :  $\mathbf{R}_Y \in \mathbb{R}^{(M+1) \times (M+1)}$

$$\begin{aligned} \mathbf{R}_Y &= \mathbb{E} [\mathbf{Y}\mathbf{Y}^t] = \mathbb{E} \left\{ \begin{bmatrix} Y(0) \\ \vdots \\ Y(M) \end{bmatrix} \begin{bmatrix} Y(0) & \cdots & Y(M) \end{bmatrix} \right\} \\ &= \begin{bmatrix} R_Y(0) & \cdots & R_Y(M) \\ & \ddots & \\ R_Y(M) & \cdots & R_Y(0) \end{bmatrix} \end{aligned}$$

- Matriz Toeplitz simétrica.
- Se forma a partir de  $R_Y(k)$ , *función de autocorrelación* de  $Y(n)$ .
- Si  $Y(n)$  es ESA,  $\mathbf{R}_Y$  no depende de  $n$ .

# Problema de suavizado en una ventana fija (cont)

- *Vector de correlación cruzada* :  $\mathbf{R}_{X_n\mathbf{Y}} \in \mathbb{R}^{1 \times (M+1)}$ ,

$$\begin{aligned}\mathbf{R}_{X_n\mathbf{Y}} &= \mathbb{E}[X(n)\mathbf{Y}^t] \\ &= \mathbb{E}\{X(n)[Y(0), Y(1), \dots, Y(n), \dots, Y(M)]\} \\ &= [R_{XY}(-n), R_{XY}(-n+1), \dots, R_{XY}(0), \dots, R_{XY}(M-n)]\end{aligned}$$

$R_{XY}(k)$ : *correlación cruzada* entre los procesos  $X(n)$  e  $Y(n)$ .

- Pese a que  $X(n)$  e  $Y(n)$  son CESA, el vector  $\mathbf{R}_{X_n\mathbf{Y}}$  depende de  $n$ .

# Suavizado en una ventana fija

- Luego, en cada instante, *evoluciona con el tiempo*

$$\hat{X}(n) = \mathbf{k}_n \mathbf{Y} \text{ con } \mathbf{k}_n = \mathbf{R}_{X_n Y} \mathbf{R}_Y^{-1}.$$

$$\hat{X}(n) = \sum_{i=0}^M \underline{k_i(n)} \cdot y_i \rightarrow \text{Entón Coef. cambian con el tiempo}$$

- El procesamiento para resolver el problema de suavizado es no-causal y variante en el tiempo

# Suavizado en una ventana fija: error de estimación

Sea  $E(n) = X(n) - \hat{X}(n)$ , el error de estimación.

*A priori*, antes de realizar observación alguna,  $\mathbb{V}[X(n)] = \sigma_X^2$  es una indicación de la incertidumbre que se tiene sobre el proceso  $X(n)$ . Luego de obtener  $\hat{X}(n)$ , la incertidumbre en  $X(n)$  está dada por  $\mathbb{V}[E(n)] = \sigma_E^2(n)$ .

# Suavizado en una ventana fija: error de estimación

A partir del resultado del estimador LMMSE tenemos para cada valor de  $n$ :

- $\mathbb{E}[E(n)] = 0$  por ser un estimador insesgado.
- $\mathbb{V}[E(n)] = \mathbb{E}[|E(n)|^2] = \sigma_X^2 - \mathbf{R}_{X_n Y} \mathbf{R}_Y^{-1} \mathbf{R}_{X_n Y}^t$  (ver <sup>1</sup> al pie)
- Como  $\mathbf{R}_Y > 0$ , tenemos que

$$\mathbf{R}_{X_n Y} \mathbf{R}_Y^{-1} \mathbf{R}_{X_n Y}^t > 0 \quad \forall n.$$

Luego,  $\mathbb{V}[E(n)] < \sigma_X^2$  para todo  $n$ . Es decir, la estimación reduce la incertidumbre sobre  $X(n)$ .

Pregunta: El proceso  $E(n)$  es ESA?


---

<sup>1</sup>Recordemos que en el caso general,  $MMSE = \text{tr} \{ \mathbf{C}_X - \mathbf{C}_{XY} \mathbf{C}_Y^{-1} \mathbf{C}_{YX} \}$



# Filtrado en una ventana fija

$$\{y(m), n - M \leq m \leq n\} \longrightarrow \hat{x}(n).$$



El filtrado tiene una solución *causal* que sólo utiliza observaciones pasadas y presentes.

# Filtrado en una ventana fija: solución LMMSE

Para cada valor de  $n$ , queremos estimar  $\hat{X}(n)$  a partir de la realización

$$y(n-M), y(n-M+1), \dots, y(n).$$

A diferencia del problema de suavizado, la ventana de observación del filtrado se desplaza con  $n$ .

$\hat{X}(n)$  depende de valores pasados de la entrada, termina siendo un filtro con una ec. en diff

$y(n) \rightarrow \boxed{\text{FILTRO}} \rightarrow \hat{X}(n)$

# Filtrado en una ventana fija: solución LMMSE

Armamos el vector  $\mathbf{Y}$  que contiene las observaciones y calculamos la matriz de correlación

$$\begin{aligned} \mathbf{R}_Y &= \mathbb{E} [\mathbf{Y}\mathbf{Y}^t] = \mathbb{E} \left\{ \begin{bmatrix} Y(n-M) \\ \vdots \\ Y(n) \end{bmatrix} \begin{bmatrix} Y(n-M) & \cdots & Y(n) \end{bmatrix} \right\} \\ &= \begin{bmatrix} R_Y(0) & \cdots & R_Y(M) \\ & \ddots & \\ R_Y(M) & \cdots & R_Y(0) \end{bmatrix} \end{aligned}$$

# Filtrado en una ventana fija: solución LMMSE

Como en el caso del suavizado, también armamos el vector de correlación cruzada a partir de  $R_{XY}(k)$ , la función de correlación cruzada entre los procesos  $X(n)$  e  $Y(n)$ :

$$\begin{aligned}\mathbf{R}_{X_n\mathbf{Y}} &= \mathbb{E} [X(n)\mathbf{Y}^t] \\ &= \mathbb{E} \{ X(n) [Y(n-M), \dots Y(n-1), Y(n)] \} \\ &= [R_{XY}(M), \dots R_{XY}(1), R_{XY}(0)] = \mathbf{R}_{XY}.\end{aligned}$$

En este caso, el vector  $\mathbf{R}_{X_n\mathbf{Y}} = \mathbf{R}_{XY}$  no depende de  $n$ .

# Filtrado en una ventana fija

Finalmente,  $\hat{X}(n) = \underbrace{\mathbf{R}_{XY}\mathbf{R}_Y^{-1}}_{\mathbf{w}^t} \mathbf{Y}$

donde

$$\mathbf{w} = \mathbf{R}_Y^{-1} \mathbf{R}_{XY}^t = \begin{bmatrix} w(M) \\ w(M-1) \\ \vdots \\ w(0) \end{bmatrix} \quad \mathbf{Y} = \begin{bmatrix} y(n-M) \\ y(n-M+1) \\ \vdots \\ y(n) \end{bmatrix}.$$

Luego,

$$\begin{aligned} \hat{X}(n) &= w(M)y(n-M) + w(M-1)y(n-M+1) + \cdots + w(0)y(n) \\ &= \sum_{s=0}^M w(s)y(n-s). \end{aligned}$$


## Filtrado en una ventana fija (cont)

$$\hat{X}(n) = \sum_{s=0}^M w(s)y(n-s) = \sum_{m=n-M}^n w(n-m)y(m).$$

Asociamos los coeficientes  $w(s)$  a la respuesta impulsiva de un filtro FIR de longitud  $M + 1$  que realiza el filtrado causal. Este filtro se lo conoce como *Filtro de Wiener*.

# Filtro de Wiener

Al hdp de Wiener le preocupaba sacar el ruido de su radio, x eso rompía las pelotas con esto



$\hat{X}_{Immse}(n)$  resulta al filtrar linealmente las observaciones  $Y(n)$ .

- La respuesta impulsiva FIR del filtro  $W$  se obtiene como los componentes del vector

$$\mathbf{w} = \mathbf{R}_Y^{-1} \mathbf{R}_{XY}^t$$


donde  $\mathbf{R}_Y$  y  $\mathbf{R}_{XY}$  depende del largo del filtro  $M$  pero no del instante de filtrado  $n$ .

- El *costo de Wiener* es igual a  $\rightarrow$  *Cuánto hay q barpar*

$$J_{Wiener} = \mathbb{E}[|E(n)|^2] = \sigma_X^2 - \mathbf{R}_{XY} \mathbf{R}_Y^{-1} \mathbf{R}_{XY}^t$$

# Notación

En cierta bibliografía del tema, se plantea el problema de filtrado con la siguiente nomenclatura, donde  $W$  es un filtro FIR de longitud  $M + 1$



$$\hat{d}(n) = \sum_{s=0}^M w(s)u(n-s)$$

Este problema es equivalente al ya visto si se considera que:

- Las observaciones  $y(n)$  son las *entradas* del filtro  $u(n)$ .
- El proceso  $x(n)$  es la señal *deseada*  $d(n)$ .

Digamos que no tengo las observaciones  $y(n)$  y solo conozco la estadística de  $x(n)$ . La mejor estimación de  $x(n)$  es su media y el ecm es la varianza


$$\rightarrow \hat{X}(n) = E[X(n)], \quad E[|X(n) - \hat{X}(n)|^2] = \sigma_X^2$$



# Notación

Si además conozco las observaciones de  $y(n)$ , queda que:

$$\hat{x}(M) = \sum_{i=0}^M w(i) y_{(M-i)} \quad \rightarrow \text{filtro de wiener}$$



$$E[|x(M) - \hat{x}(M)|^2] = \sigma_x^2 - \underbrace{R_{xy} R_y^{-1} R_{yx}}_{< \sigma_x^2} < \sigma_x^2$$

Principio de ortogonalidad:

$$\mathbb{E}[U^t(n)E(n)] = 0$$

Cuanto mayor sea la correlación entre  $x$  e  $y$ , más se resta en el segundo término del ecm y mejor es la estimación.

Planteando las ecuaciones normales:

$$\begin{bmatrix} w(M) \\ \vdots \\ w(0) \end{bmatrix} = \begin{bmatrix} R_u(0) & \cdots & R_u(M) \\ & \ddots & \\ R_u(-M) & \cdots & R_u(0) \end{bmatrix}^{-1} \begin{bmatrix} R_{du}(M) \\ \vdots \\ R_{du}(0) \end{bmatrix}$$

# Retomamos el diseño de $W$ *Acá se pudre el queso*

Hipótesis:

- ①  $X(n)$  e  $Y(n)$  son conjuntamente ESA,
- ②  $R_Y(k)$  y  $R_{XY}(k)$  son funciones conocidas.

Qué sucede si

- Los procesos no son estacionarios?
  - Ejemplo 1:  $X(n)$  tiene una deriva en el tiempo y  $\mathbb{E}[X(n)] = \mu_X(n)$ .
  - Ejemplo 2:  $X(n)$  es una constante, pero la fuente del ruido que afecta la observación varía con el tiempo.
- No se conoce la estadística de  $X(n)$  o de  $Y(n)$ ?
  - Por ejemplo, se sabe que  $Y(n) = X(n) + V(n)$ , pero no se tienen observaciones previas que permitan estimar  $R_Y$  y/o  $R_{XY}$ .

Encaramos estos problemas estimando  $X(n)$  a medida que observamos  $Y(n)$ , es decir, *adaptando* el diseño del filtro.

# Volvamos al planteo del LMMSE

Vimos que el filtro de Wiener es un filtro FIR causal que obtiene el estimador LMMSE. Sea  $w(l)$  la respuesta impulsiva del filtro,

$$\hat{X}(n) = \sum_{l=0}^M w(l) Y(n-l) = \underbrace{[w(M) \quad \dots \quad w(0)]}_{\mathbf{w}^t} \underbrace{\begin{bmatrix} Y(n-M) \\ \vdots \\ Y(n) \end{bmatrix}}_{\mathbf{Y}}$$

# Volvamos al planteo del LMMSE

Para cada instante  $n$ , podemos calcular el error cuadrático medio,

$$\begin{aligned}\mathbb{E} [|X(n) - \mathbf{w}^t \mathbf{Y}|^2] &= \mathbb{E}[|X(n)|^2] - \mathbb{E}[X(n) \mathbf{Y}^t \mathbf{w}] \\ &\quad - \mathbb{E}[\mathbf{w}^t \mathbf{Y} X(n)] + \mathbb{E}[\mathbf{w}^t \mathbf{Y} \mathbf{Y}^t \mathbf{w}] \\ \mathfrak{J}(\vec{\mathbf{w}}) &= \sigma_X^2 - \mathbf{R}_{X\mathbf{Y}} \mathbf{w} - \mathbf{w}^t \mathbf{R}_{\mathbf{Y}X} + \mathbf{w}^t \mathbf{R}_{\mathbf{Y}} \mathbf{w}\end{aligned}$$

Ésta es una función de  $\mathbf{w}$  que llamamos  $J(\mathbf{w})$ . Esta función se la conoce como función costo. Claramente, la solución LMMSE minimiza  $J(\mathbf{w})$ , es decir,

$$\mathbf{w}_{lmmse} = \arg \min J(\mathbf{w})$$

# Volvamos al planteo del LMMSE


Para minimizar  $J(\mathbf{w})$  calculamos el gradiente.

Sea  $w(l) = w_R(l) + \cancel{w_I(l)}$ . Luego,

$$\nabla J = \begin{bmatrix} \frac{\partial J}{\partial w_R(M)} + \cancel{\frac{\partial J}{\partial w_I(M)}} \\ \vdots \\ \frac{\partial J}{\partial w_R(0)} + \cancel{\frac{\partial J}{\partial w_I(0)}} \end{bmatrix} = 2 (\mathbf{R}_Y \mathbf{w} - \mathbf{R}_{XY}^t).$$

Claramente,  $\mathbf{w}_{lmmse}$  coincide con la solución de  $\nabla J = 0$ .

Pregunta: Es posible calcular  $\mathbf{w}$  en forma recursiva?



# Algoritmo *steepest descent* para optimización de funciones multivariables

- Sea  $f : \mathbb{R}^L \rightarrow \mathbb{R}$  y  $\bar{w}$  un mínimo local de  $f$ . Suponemos que  $f(\cdot)$  es diferenciable en todo punto de  $B(\bar{w}) \subset \mathbb{R}^L$ , un vecindario de  $\bar{w}$ .
- Para hallar  $\bar{w}$  de forma numérica armamos una trayectoria que luego de  $n$  pasos resulta

$$w_{n+1} = w_n + p$$

donde  $p$  es la dirección de actualización<sup>2</sup>.

---

<sup>2</sup>La referencia clásica para este tema es *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*, J. E. Dennis, Jr. and Robert B. Schnabel, Society for Industrial and Applied Mathematics, donde se desarrolla este tema en el contexto general de optimización de funciones.

# Algoritmo *steepest descent* para optimización de funciones multivariables

- p* tiene la dirección opuesta a  $\nabla f$
- Si  $\nabla f^t p < 0$ , y  $\delta$  pequeño,  $f(w_n + \delta p) < f(w_n)$
  - La dirección de descenso más rápido es

$$p = -\frac{\nabla f}{\|\nabla f\|}$$

- Algoritmo de descenso por la mayor pendiente o *steepest descent*

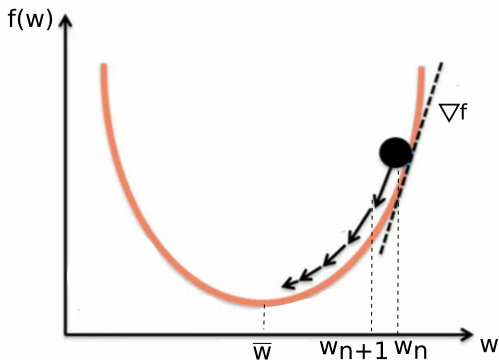
$$w_{n+1} = w_n - \mu \nabla f$$

donde  $\mu > 0$  es un parámetro que define el tamaño del paso.

# Algoritmo *steepest descent* para optimización de funciones multivariables

Si  $\bar{w}$  es un mínimo global, el algoritmo iterativo converge, es decir

$$w_n \rightarrow \bar{w} \quad n \rightarrow \infty.$$





# Volvamos al filtro de Wiener

Vimos que el filtro de Wiener se obtiene minimizando la función costo

$$J(\mathbf{w}) = \sigma_X^2 - \mathbf{R}_{XY}\mathbf{w} - \mathbf{w}^t\mathbf{R}_{YX} + \mathbf{w}^t\mathbf{R}_Y\mathbf{w} \quad \mathbf{w} \in \mathbb{R}^{M+1}.$$

Más aún, vimos que

$$\nabla J \propto (\mathbf{R}_Y\mathbf{w} - \mathbf{R}_{XY}^t).$$

Planteamos el esquema de steepest descent para minimizar  $J(\mathbf{w})$ .

# Planteo iterativo del filtro de Wiener

Filtrado de Wiener utilizando Steepest-descent

A partir de  $\mathbf{w}_n$ , la siguiente actualización es

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \underbrace{\mu (\mathbf{R}_Y \mathbf{w}_n - \mathbf{R}_{XY}^t)}_{\nabla J} \quad n = 0, 2, \dots$$

En cada iteración, se obtienen las  $M + 1$  componentes del vector

$$\mathbf{w}_n = \begin{bmatrix} w_n(M) \\ \vdots \\ w_n(0) \end{bmatrix}$$

El parámetro  $\mu > 0$  controla la velocidad de convergencia.  
Como  $J(\mathbf{w})$  es convexa,  $\mathbf{w}_{Immse}$  es mínimo global y

$$\mathbf{w}_n \rightarrow \mathbf{w}_{Immse}.$$

# Steepest descent para obtener el filtro de Wiener

El término de corrección luego del paso  $n$  es  $\mathbf{R}_Y \mathbf{w}_n - \mathbf{R}_{X(n)Y}^t$ .

$$\begin{aligned} \mathbf{R}_Y \mathbf{w}_n - \mathbf{R}_{X(n)Y}^t &= \mathbb{E} [\mathbf{Y} \mathbf{Y}^t] \mathbf{w}_n - \mathbb{E} [\mathbf{Y} X^t(n)] \\ &= \mathbb{E} \left[ \mathbf{Y} \underbrace{(\mathbf{w}_n^t \mathbf{Y} - X(n))^t}_{\mathbf{E}^t(n)} \right] \\ &= \mathbb{E} [\mathbf{Y} \mathbf{E}(n)^t] . \end{aligned}$$

La corrección en el paso  $n$  es igual al producto entre el error de estimación  $E(n) = \mathbf{w}_n^t \mathbf{Y} - X(n)$  y el vector de observaciones  $\mathbf{Y}$ .

# Algoritmo LMS

Para implementar el algoritmo de *steepest descent* se requiere conocer la estadística conjunta de  $X(n)$  e  $Y(n)$ . Esto no siempre es posible, o puede resultar muy complejo. Una alternativa es el algoritmo iterativo conocido como LMS (*Least-Mean-Square*).

Como referencia para este tema, sugiero leer el artículo donde Bernard Widrow cuenta cómo llegó a la formulación del algoritmo, “Thinking about thinking: the discovery of the LMS algorithm,” B. Widrow, en IEEE Signal Processing Magazine, vol. 22, no. 1, pp. 100-106, Enero 2005

# Algoritmo LMS

La idea del algoritmo LMS es aproximar el operador  $\mathbb{E}[\cdot]$  por el resultado de una realización del proceso, es decir

$$\mathbb{E}[\mathbf{Y}E(n)^t]$$

pasa a ser

$$\mathbf{y}(n)e(n)^t,$$

*aproximar al  
gradiente  
por esto hace*

$$\mathbf{y}(n) = \begin{bmatrix} y(n-M) \\ \vdots \\ y(n) \end{bmatrix}$$

*que el gradiente se vuelve aleatorio*  
 $y(k)$  es la realización del proceso observado.

Nunca voy a llegar al mínimo completamente, voy a empezar a oscilar

$e(n) = x(n) - \hat{x}(n)$  la realización del error de estimación

Para hacer énfasis en el aspecto adaptativo, incluimos el tiempo  $n$  en el vector de observaciones  $\mathbf{y}(n)$ .

# Adaptación de acuerdo al algoritmo *Least-Mean-Square*

## Algoritmo LMS

Sea  $\mathbf{w}_n$  el vector de coeficientes del filtro luego del  $n$ -ésimo paso de adaptación. En cada paso, tenemos:

$$\hat{x}(n) = \mathbf{w}_n^t \mathbf{y}(n)$$

y la adaptación los pesos del filtro van evolucionando con el tiempo  
El sistema los va "aprendiendo"

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \mu (\mathbf{y}(n) \mathbf{e}(n)^t)$$

¿cómo lo consigo?  
Se puede estimar

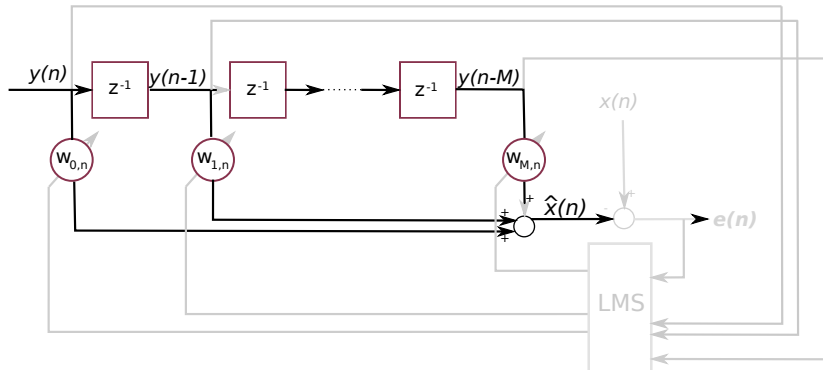
# Adaptación de acuerdo al algoritmo

## *Least-Mean-Square*

### Algunas observaciones preliminares

- La dirección de descenso del LMS no es determinística. Este algoritmo pertenece a la clase de algoritmos de *gradiente estocástico*.
- La convergencia del algoritmo no está asegurada, si bien su performance es muy buena bajo ciertas condiciones
- La enorme ventaja (y razón de su popularidad) del algoritmo LMS es su simplicidad.

# Implementación del algoritmo



$$\mathbf{w}_{n+1} = \mathbf{w}_n - \mu (\mathbf{y}(n)e(n)^t)$$



# Convergencia del Algoritmo *Least-Mean-Square*

Vamos a analizar si  $\mathbf{w}_n$  converge al filtro de Wiener a medida que aumenta  $n$ . Sea el vector de diferencias  $\varepsilon_n = \mathbf{w}_n - \mathbf{w}_{lmmse}$ .

- Como el límite de  $\varepsilon_n \neq 0$ , entonces  $\mathbf{w}_n$  no converge a  $\mathbf{w}_{lmmse}$ .
- El valor del costo  $J_{LMS}(\mathbf{w}_n)$  es superior al costo de Wiener,  
 $J_{Wiener} = \sigma_x^2 - \mathbf{R}_{XY} \mathbf{R}_Y^{-1} \mathbf{R}_{XY}^t$ .
- $J(\mathbf{w}_n) = J_{Wiener} + J_{ex}(n)$  donde

$$\lambda_{min} \leq \frac{J_{ex}(n)}{\mathbb{E}[\|\varepsilon(n)\|^2]} \leq \lambda_{max} \quad \forall n$$

Excedente

# Convergencia del Algoritmo

- En general, la convergencia del algoritmo LMS es *ruidosa*, ya que depende de una aproximación ruidosa de  $\nabla J$ .
- El algoritmo converge a un valor mayor al costo de Wiener  $J_{opt}$

# Convergencia del Algoritmo

- Para convergencia, necesitamos

$$0 < \mu < \frac{2}{\text{tr}(\mathbf{R}_Y)}$$

Crear @  
ventana

Cuando no se conoce  $\mathbf{R}_Y$  o sus autovalores, es difícil verificar que se cumpla. Observemos que

$$\text{tr}(\mathbf{R}_Y) = (M+1)R_Y(0) = (M+1)\mathbb{E}[|Y(n)|^2] \simeq \sum_{l=0}^M |y(n-l)|^2$$

donde  $\sum_{l=0}^M |y(n-l)|^2$  es la energía contenida en la señal observada durante la ventana de duración  $M+1$ . Luego, una indicación para elegir  $\mu$  puede ser

$$0 < \mu < \frac{2}{\sum_{l=0}^M |y(n-l)|^2}$$