

# Distribución Gaussiana Multivariable

Cecilia Galarza


Procesos Estocásticos  
Facultad de Ingeniería, Universidad de Buenos Aires

1er cuatrimestre 2025

# Distribución Gaussiana Multivariable

# Repaso de distribución gaussiana o normal

La VA  $Z$  tiene distribución gaussiana, o  $Z \sim \mathcal{N}(\mu, \sigma^2)$  si



$$f_Z(z) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(z-\mu)^2/2\sigma^2}, \quad z \in \mathbb{R}.$$

Algunas propiedades:

- $f_Z(z)$  es máxima en  $\mu$  y simétrica,

$$f_Z(\mu - z) = f_Z(\mu + z) \quad , \quad \forall z \in \mathbb{R}.$$

- $\mathbb{E}[Z] = \mu$     y     $\mathbb{V}[Z] = \mathbb{E}[(Z - \mu)^2] = \sigma^2.$


# Gaussiana o normal estándar , $\mathcal{N}(0, 1)$

Función distribución:

$$F_Z(z) = \Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-u^2/2} du.$$

Función  $Q(z)$ :

$$Q(z) = 1 - \Phi(z) = \frac{1}{\sqrt{2\pi}} \int_z^{+\infty} e^{-u^2/2} du.$$



Ambas funciones se obtienen de tablas.

# Distribución gaussiana Multivariable (Definición 1)

Un VeA  $\mathbf{X}$  tiene una distribución gaussiana multivariable si existe un vector  $\mu_{\mathbf{X}}$  y una matriz simétrica  $C_{\mathbf{X}} \geq 0$  tal que la PDF conjunta es:

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} \det(C_{\mathbf{X}})^{1/2}} e^{-\frac{1}{2}(\mathbf{x}-\mu_{\mathbf{X}})^T C_{\mathbf{X}}^{-1}(\mathbf{x}-\mu_{\mathbf{X}})} \quad , \quad \mathbf{x} \in \mathbb{R}^n.$$

Decimos que  $\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}})$ . Es posible demostrar que

- Esperanza:  $\mathbb{E}[\mathbf{X}] = \mu_{\mathbf{X}}$ .
- Covarianza:  $\mathbf{Cov}[\mathbf{X}] = C_{\mathbf{X}}$

Cuando  $\mu_{\mathbf{X}} = 0$  y  $C_{\mathbf{X}} = \mathbf{I}_n$  tenemos una distribución normal estándar.

## Distribución Gaussiana Multivariable (Definición 2)

$\mathbf{X}$  tiene una distribución gaussiana multivariable si y sólo si,  
 $\forall \mathbf{A} \in \mathbb{R}^{m \times n}$ ,  $m \leq n$ ,  $\mathbf{Y} = \mathbf{AX}$  sigue una distribución gaussiana. Esta última queda especificada por

$$\mathbb{E}[\mathbf{Y}] = \mathbf{A}\mu_{\mathbf{X}} \quad \mathbf{Cov}(\mathbf{Y}) = \mathbf{A}C_{\mathbf{X}}\mathbf{A}^T$$

# Distribución Gaussiana Multivariable - Observaciones

- Se puede partir de la Definición 1 y probar la Definición 2 como una propiedad o viceversa.
- La distribución gaussiana queda completamente definida por la esperanza y su matriz de covarianza.
- Decimos que  $\mathbf{X}$  sigue una distrución gaussiana multivariable o que sus componentes son conjuntamente gaussianas.

# Distribuciones marginales

Si  $\mathbf{X}$  es un VeA gaussiano, luego sus componentes y todo subvector son gaussianos.

Este resultado es una consecuencia de que toda transformación lineal de un VeA gaussiano produce otro VeA gaussiano.

- Como  $X_i = \mathbf{1}_i^T \mathbf{X}$ , donde  $\mathbf{1}_i = [0, \dots, 0, 1, 0, \dots, 0]^t$ , entonces  $X_i$  es el resultado de una transformación lineal de  $\mathbf{X}$ . Por lo tanto,  $X_i$  es gaussiana con

$$\mathbb{E}[X_i] = \mathbf{1}_i^t \mu_{\mathbf{X}} = (\mu_{\mathbf{X}})_i, \quad \mathbb{V}[X_i] = \mathbf{1}_i^t C_{\mathbf{X}} \mathbf{1}_i = (C_{\mathbf{X}})_{i,i}.$$

- En forma más general, un subvector  $\mathbf{X}_I = [X_{i_1}, \dots, X_{i_k}]^t$  de  $\mathbf{X}$  es gaussiano.

$$\mathbf{X}_I = \begin{bmatrix} \mathbf{1}_{i_1}^t \\ \vdots \\ \mathbf{1}_{i_k}^t \end{bmatrix} \mathbf{X} = \mathbf{1}_I^t \mathbf{X} \quad \longrightarrow \quad \begin{cases} \mathbb{E}[\mathbf{X}_I] = \mathbf{1}_I^t \mu_{\mathbf{X}} = (\mu_{\mathbf{X}})_I \\ \mathbf{Cov}(\mathbf{X}_I) = \mathbf{1}_I^t C_{\mathbf{X}} \mathbf{1}_I = (C_{\mathbf{X}})_{I,I} \end{cases}$$



# Gaussiana condicionada por Gaussiana

# PDF condicional

Sea  $\mathbf{X} \in \mathbb{R}^n$ ,  $\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}})$ ,

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \quad \mathbf{X}_1 \in \mathbb{R}^{n_1}, \mathbf{X}_2 \in \mathbb{R}^{n_2} \quad n_1 + n_2 = n.$$

Buscamos la distribución condicional de  $\mathbf{X}_1$  cuando  $\mathbf{X}_2 = \mathbf{x}_2$ . Vamos a demostrar que

$f_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1|\mathbf{X}_2 = \mathbf{x}_2)$  es gaussiana con

- $\mathbb{E}[\mathbf{X}_1|\mathbf{X}_2 = \mathbf{x}_2] = \mu_{\mathbf{X}_1} + C_{\mathbf{X}_1, \mathbf{X}_2} C_{\mathbf{X}_2, \mathbf{X}_2}^{-1} (\mathbf{x}_2 - \mu_{\mathbf{X}_2})$
- $\text{Cov}(\mathbf{X}_1|\mathbf{X}_2 = \mathbf{x}_2) = C_{\mathbf{X}_1} - C_{\mathbf{X}_1, \mathbf{X}_2} C_{\mathbf{X}_2, \mathbf{X}_2}^{-1} C_{\mathbf{X}_2, \mathbf{X}_1}.$

# PDF condicional cuando $n = 2$

- Consideremos primero el caso bidimensional, es decir,  $\mathbf{X} = [X_1, X_2]^t$ .

$$\begin{aligned} f_{X_1|X_2}(x_1|X_2 = x_2) &= \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_2}(x_2)} \\ &= \frac{1}{2\pi\sigma_1\sigma_2(1-\rho^2)^{1/2}} e^{-\frac{1}{2} \frac{1}{1-\rho^2} \left[ \frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{x_1-\mu_1}{\sigma_1} \frac{x_2-\mu_2}{\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2} \right]} \\ &= \frac{1}{\sqrt{2\pi\sigma_2^2}} e^{-\frac{1}{2} \frac{(x_2-\mu_2)^2}{\sigma_2^2}} \\ &= \frac{1}{\sqrt{2\pi\sigma_1^2(1-\rho^2)}} e^{-\frac{1}{2\sigma_1^2(1-\rho^2)} \left[ x_1 - \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2) - \mu_1 \right]^2}. \end{aligned}$$

- Luego,  $f_{X_1|X_2}(x_1|X_2 = x_2)$  corresponde a una pdf gaussiana con

$$\mathbb{E}[X_1|X_2 = x_2] = \mu_1 + \frac{\rho\sigma_{X_1}}{\sigma_2}(x_2 - \mu_2).$$

$$\mathbb{V}[X_1|X_2 = x_2] = (1 - \rho^2)\sigma_1^2.$$

## PDF condicional cuando $n = 2$

- La media condicional  $\mu_{X_1|X_2=x_2}$  es una función afín de  $x_2$ .
- La varianza condicional  $\sigma_{X_1|X_2=x_2}^2$  es independiente del valor de  $x_2$ .
- Si  $\rho = 0$ ,  $X_1$  y  $X_2$  son independientes. Luego,  
 $f_{X_1|X_2}(x_1|X_2 = x_2) = f_{X_1}(x_1)$ . Esto queda claro en las ecuaciones anteriores considerando  $\rho = 0$ ,  $\mu_{X_1|X_2=x_2} = \mu_1$  y  $\sigma_{X_1|X_2=x_2}^2 = \sigma_1^2$ .
- Si  $|\rho| = 1$ , las variables están perfectamente correlacionadas. Luego al observar  $\mathbf{X}_2 = \mathbf{x}_2$  podemos determinar perfectamente  $\mathbf{X}_1$ , es decir  $\sigma_{X_1|X_2=x_2}^2 = 0$ . Nuevamente, esto se verifica en las ecuaciones anteriores.

# PDF condicional: caso general

Partimos de la definición

$$\begin{aligned} f_{\mathbf{x}_1|\mathbf{x}_2}(\mathbf{x}_1|\mathbf{x}_2) &= \frac{f_{\mathbf{x}_1, \mathbf{x}_2}(\mathbf{x}_1, \mathbf{x}_2)}{f_{\mathbf{x}_2}(\mathbf{x}_2)} = \frac{f_{\mathbf{x}}(\mathbf{x})}{f_{\mathbf{x}_2}(\mathbf{x}_2)} \\ &= \frac{\frac{1}{(2\pi)^{n/2} \det(C_{\mathbf{x}})^{1/2}} e^{-\frac{1}{2}(\mathbf{x}-\mu_{\mathbf{x}})^t C_{\mathbf{x}}^{-1}(\mathbf{x}-\mu_{\mathbf{x}})}}{\frac{1}{(2\pi)^{n_2/2} \det(C_{\mathbf{x}_2})^{1/2}} e^{-\frac{1}{2}(\mathbf{x}_2-\mu_{\mathbf{x}_2})^t C_{\mathbf{x}_2}^{-1}(\mathbf{x}_2-\mu_{\mathbf{x}_2})}} \end{aligned}$$

Para calcular  $f_{\mathbf{x}}$  necesitamos invertir  $C_{\mathbf{x}}$  y calcular su determinante.  
Para ello, particionamos la matriz de covarianza

$$C_{\mathbf{x}} = \begin{bmatrix} C_{\mathbf{x}_1} & C_{\mathbf{x}_1, \mathbf{x}_2} \\ C_{\mathbf{x}_2, \mathbf{x}_1} & C_{\mathbf{x}_2} \end{bmatrix}.$$

Presentamos dos resultados auxiliares para matrices en bloques.

# Inversión de matrices por bloques

Sea  $\mathbf{A} \in \mathbb{R}^{n \times n}$  una matriz no singular particionada del siguiente modo:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{1,1} & \mathbf{A}_{1,2} \\ \mathbf{A}_{2,1} & \mathbf{A}_{2,2} \end{bmatrix}$$

Definimos

$$\mathbf{A}_* = \mathbf{A}_{1,1} - \mathbf{A}_{1,2} \mathbf{A}_{2,2}^{-1} \mathbf{A}_{2,1}.$$

Esta matriz se la conoce como el complemento de Schur del bloque  $\mathbf{A}_{2,2}$  de la matriz  $\mathbf{A}$ . Asumimos que todas las inversas involucradas existen. Luego:

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_*^{-1} & -\mathbf{A}_*^{-1} \mathbf{A}_{1,2} \mathbf{A}_{2,2}^{-1} \\ -\mathbf{A}_{2,2}^{-1} \mathbf{A}_{2,1} \mathbf{A}_*^{-1} & \mathbf{A}_{2,2}^{-1} + \mathbf{A}_{2,2}^{-1} \mathbf{A}_{2,1} \mathbf{A}_*^{-1} \mathbf{A}_{1,2} \mathbf{A}_{2,2}^{-1} \end{bmatrix}$$

$$\det(\mathbf{A}) = \det(\mathbf{A}_{2,2}) \det(\mathbf{A}_*).$$

# PDF condicional: caso general

Retomamos la derivación de  $f_{\mathbf{x}_1|\mathbf{x}_2}$

- Aplicando el resultado de inversión por bloques a la matriz  $C_{\mathbf{x}}$  calculamos el complemento de Schur

$$C_{\mathbf{x}*} = C_{\mathbf{x}_1} - C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1}$$

Luego,

$$\begin{aligned} C_{\mathbf{x}}^{-1} &= \begin{bmatrix} C_{\mathbf{x}_1} & C_{\mathbf{x}_1, \mathbf{x}_2} \\ C_{\mathbf{x}_2, \mathbf{x}_1} & C_{\mathbf{x}_2} \end{bmatrix}^{-1} \\ &= \begin{bmatrix} C_{\mathbf{x}*}^{-1} & -C_{\mathbf{x}*}^{-1} C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} \\ -C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} C_{\mathbf{x}*}^{-1} & C_{\mathbf{x}_2}^{-1} + C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} C_{\mathbf{x}*}^{-1} C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} \end{bmatrix} \end{aligned}$$

$$\det(C_{\mathbf{x}}) = \det(C_{\mathbf{x}_2}) \det(C_{\mathbf{x}*}).$$

# PDF condicional: caso general

- Utilizando la partición de  $C_{\mathbf{X}}^{-1}$ , calculamos:

$$\begin{aligned}
 (\mathbf{x} - \mu_{\mathbf{X}})^t C_{\mathbf{X}}^{-1} (\mathbf{x} - \mu_{\mathbf{X}}) &= \begin{bmatrix} \mathbf{x}_1 - \mu_{\mathbf{x}_1} \\ \mathbf{x}_2 - \mu_{\mathbf{x}_2} \end{bmatrix}^t \begin{bmatrix} C_{\mathbf{x}_1} & C_{\mathbf{x}_1, \mathbf{x}_2} \\ C_{\mathbf{x}_2, \mathbf{x}_1} & C_{\mathbf{x}_2} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{x}_1 - \mu_{\mathbf{x}_1} \\ \mathbf{x}_2 - \mu_{\mathbf{x}_2} \end{bmatrix} \\
 &= (\mathbf{x}_1 - \mu_{\mathbf{x}_1})^t C_{\mathbf{x}_*}^{-1} (\mathbf{x}_1 - \mu_{\mathbf{x}_1}) \\
 &\quad - (\mathbf{x}_1 - \mu_{\mathbf{x}_1})^t C_{\mathbf{x}_*}^{-1} C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} (\mathbf{x}_2 - \mu_{\mathbf{x}_2}) - (\mathbf{x}_2 - \mu_{\mathbf{x}_2})^t C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} C_{\mathbf{x}_*}^{-1} (\mathbf{x}_1 - \mu_{\mathbf{x}_1}) \\
 &\quad + (\mathbf{x}_2 - \mu_{\mathbf{x}_2})^t \left\{ C_{\mathbf{x}_2}^{-1} + C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} C_{\mathbf{x}_*}^{-1} C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} \right\} (\mathbf{x}_2 - \mu_{\mathbf{x}_2}) \\
 &= \begin{bmatrix} \mathbf{x}_1 - \underbrace{(\mu_{\mathbf{x}_1} + C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} (\mathbf{x}_2 - \mu_{\mathbf{x}_2}))}_{\mu_*} \end{bmatrix}^t C_{\mathbf{x}_*}^{-1} \begin{bmatrix} \mathbf{x}_1 - \underbrace{(\mu_{\mathbf{x}_1} + C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} (\mathbf{x}_2 - \mu_{\mathbf{x}_2}))}_{\mu_*} \\ \mathbf{x}_2 - \mu_{\mathbf{x}_2} \end{bmatrix} \\
 &\quad + (\mathbf{x}_2 - \mu_{\mathbf{x}_2})^t C_{\mathbf{x}_2}^{-1} (\mathbf{x}_2 - \mu_{\mathbf{x}_2}).
 \end{aligned}$$

Definimos  $\mu_* = \mu_{\mathbf{x}_1} + C_{\mathbf{x}_1, \mathbf{x}_2} C_{\mathbf{x}_2}^{-1} C_{\mathbf{x}_2, \mathbf{x}_1} (\mathbf{x}_2 - \mu_{\mathbf{x}_2})$ .

*no debería estar, me dan las dim*



# PDF condicional: caso general

- Incorporando esta expresión y la de  $\det(C_{\mathbf{X}})$  en  $f_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1|\mathbf{x}_2)$  obtenemos

$$e^{-\frac{1}{2}[(\mathbf{x}-\mu_{\mathbf{X}})^t C_{\mathbf{X}}^{-1}(\mathbf{x}-\mu_{\mathbf{X}}) - (\mathbf{x}_2 - \mu_{\mathbf{X}_2})^t C_{\mathbf{X}_2}^{-1}(\mathbf{x}_2 - \mu_{\mathbf{X}_2})]} = e^{-\frac{1}{2}(\mathbf{x}_1 - \mu_*)^t C_{\mathbf{X}*}^{-1}(\mathbf{x}_1 - \mu_*)}$$

$$\frac{\frac{1}{(2\pi)^{n/2} \det(C_{\mathbf{X}})^{1/2}}}{\frac{1}{(2\pi)^{n_2/2} \det(C_{\mathbf{X}_2})^{1/2}}} = \frac{1}{(2\pi)^{n_1/2} \det(C_{\mathbf{X}*})^{1/2}}$$

- Luego,

$$f_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1|\mathbf{x}_2) = \frac{1}{(2\pi)^{n_1/2} \det(C_{\mathbf{X}*})^{1/2}} e^{-\frac{1}{2}(\mathbf{x}_1 - \mu_*)^t C_{\mathbf{X}*}^{-1}(\mathbf{x}_1 - \mu_*)}.$$

Ésta es una pdf gaussiana de media  $\mu_*$  y covarianza  $C_{\mathbf{X}*}$ , es decir,

$$f_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1|\mathbf{x}_2) = \mathcal{N}(\mu_{\mathbf{X}_1} + C_{\mathbf{X}_1, \mathbf{X}_2} C_{\mathbf{X}_2}^{-1}(\mathbf{x}_2 - \mu_{\mathbf{X}_2}), C_{\mathbf{X}_1} - C_{\mathbf{X}_1, \mathbf{X}_2} C_{\mathbf{X}_2}^{-1} C_{\mathbf{X}_2, \mathbf{X}_1}).$$

¿ $C_{\mathbf{X}_2, \mathbf{X}_1}$ ?

# Independencia y Correlación

# Observación

- En general

$X_1, \dots, X_n$  V.A independientes  $\implies X_1, \dots, X_n$  V.A descorrelacionadas

Claramente, si  $X_i, X_j$  son independientes, su covarianza es

$$\text{Cov}(X_i, X_j) = \mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])] = \mathbb{E}[X_i - \mathbb{E}[X_i]] \mathbb{E}[X_j - \mathbb{E}[X_j]] = 0 \quad \square$$

Pero

$X_1, \dots, X_n$  V.A descorrelacionadas  $\not\implies X_1, \dots, X_n$  V.A independientes

- Se plantea una excepción cuando  $X_1, \dots, X_n$  son V.A conjuntamente gaussianas

# Gaussianas Independientes

El vector  $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{X}}, C_{\mathbf{X}})$  tiene componentes descorrelacionadas (es decir,  $C_{\mathbf{X}}$  es diagonal) si y sólo si sus componentes son independientes, es decir,

$$C_{\mathbf{X}} \text{ es diagonal} \iff f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^n f_{X_i}(x_i).$$

En este caso,

$$X_1, \dots, X_n \text{ V.A descorrelacionadas} \iff X_1, \dots, X_n \text{ V.A independientes}$$

# Demostracion

- ( $\Rightarrow$ ):  $C_{\mathbf{X}} = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$ . Luego,

$$(\mathbf{x} - \mu_{\mathbf{X}})^T C_{\mathbf{X}}^{-1} (\mathbf{x} - \mu_{\mathbf{X}}) = \sum_{i=1}^n \frac{(x_i - \mu_i)^2}{\sigma_i^2}, \quad \det(C_{\mathbf{X}}) = \prod_{i=1}^n \sigma_i^2$$

Usando las propiedades de la función exponencial,

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} \det(C_{\mathbf{X}})^{1/2}} e^{-\frac{1}{2}(\mathbf{x} - \mu_{\mathbf{X}})^T C_{\mathbf{X}}^{-1} (\mathbf{x} - \mu_{\mathbf{X}})} = \prod_{i=1}^n \underbrace{\frac{1}{(2\pi\sigma_i^2)^{1/2}} e^{-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}}}_{f_{X_i}(x_i)}.$$

- ( $\Leftarrow$ ):  $f_{\mathbf{X}}(\mathbf{x}) = \prod f_{X_i}(x_i)$ . Por ser  $\mathbf{X}$  una gaussiana multivariable, sus componentes tienen que ser VA gaussianas. Luego,

$$f_{X_i}(x_i) = \frac{e^{-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}}}{\sqrt{2\pi\sigma_i^2}} \Rightarrow f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^n \underbrace{\frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}}}_{f_{X_i}(x_i)} \Rightarrow C_{\mathbf{X}} = \text{diag}(\sigma_i^2)$$

# Independencia y PDF condicional

Vimos que si  $\mathbf{X}_1$  y  $\mathbf{X}_2$  son dos VeA conjuntamente gaussianos, la PDF condicional es una gaussiana de media y matriz de covarianza

$$\mathbb{E}[\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2] = \mu_{\mathbf{X}_1} + \mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} \mathbf{C}_{\mathbf{X}_2}^{-1} (\mathbf{x}_2 - \mu_{\mathbf{X}_2}) \quad \mathbf{Cov}(\mathbf{X}_1 | \mathbf{X}_2) = \mathbf{C}_{\mathbf{X}_1} - \mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} \mathbf{C}_{\mathbf{X}_2}^{-1} \mathbf{C}_{\mathbf{X}_2, \mathbf{X}_1}$$

- Si  $\mathbf{X}_1$  y  $\mathbf{X}_2$  están descorrelacionados,  $\mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} = 0$ . Por ende,

$$\mathbb{E}[\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2] = \mu_{\mathbf{X}_1} \quad \mathbf{Cov}(\mathbf{X}_1 | \mathbf{X}_2) = \mathbf{C}_{\mathbf{X}_1}$$

y  $f_{\mathbf{X}_1 | \mathbf{x}_2} = f_{\mathbf{X}_1}$ , es decir  $\mathbf{X}_1$  y  $\mathbf{X}_2$  son independientes.

- Por otro lado, si  $\mathbf{X}_1$  y  $\mathbf{X}_2$  son independientes  $f_{\mathbf{X}_1 | \mathbf{x}_2} = f_{\mathbf{X}_1}$ . Para ello,

$$\mu_{\mathbf{X}_1} + \mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} \mathbf{C}_{\mathbf{X}_2}^{-1} (\mathbf{x}_2 - \mu_{\mathbf{X}_2}) = \mu_{\mathbf{X}_1} \quad \text{y} \quad \mathbf{C}_{\mathbf{X}_1} - \mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} \mathbf{C}_{\mathbf{X}_2}^{-1} \mathbf{C}_{\mathbf{X}_2, \mathbf{X}_1} = \mathbf{C}_{\mathbf{X}_1}$$

La única posibilidad que esto se cumpla  $\forall \mathbf{x}_2$  es que  $\mathbf{C}_{\mathbf{X}_1, \mathbf{X}_2} = 0$ .

## Transformación afín de un VeA gaussiano

# Transformaciones afines de un VeA gaussiano

Vimos que si  $\mathbf{X} \in \mathbb{R}^n$  es un VeA Gaussiano, luego toda transformación lineal del mismo es también gaussiano. Analicemos qué ocurre cuando tomamos una transformación afín. Sean  $A \in \mathbb{R}^{m \times n}$  y  $b \in \mathbb{R}^m$ . Noten que  $m$  puede ser distinto a  $n$ , es decir  $A$  puede ser rectangular. Definimos

$$\mathbf{Y} = A\mathbf{X} + b.$$

- Vimos que en una transformación afín

$$\mu_{\mathbf{Y}} = A\mathbb{E}[\mathbf{X}] + b, \quad C_{\mathbf{Y}} = AC_{\mathbf{X}}A^t$$

- Sabemos que  $A\mathbf{X}$  sigue una distribución gaussiana. Luego,  $\mathbf{Y} \sim \mathcal{N}(\mu_{\mathbf{Y}}, C_{\mathbf{Y}})$ .
- Usando transformaciones afines, podemos transformar cualquier distribución gaussiana en una normal estándar y viceversa. Vamos a trabajar sólo con gaussianas no-degeneradas.



# Transformaciones afines de un VeA gaussiano

Sea  $\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}})$ , con  $C_{\mathbf{X}} > 0$ .

- Descomponemos  $C_{\mathbf{X}} = P_{\mathbf{X}} \Lambda_{\mathbf{X}} P_{\mathbf{X}}^t \rightarrow \text{??}$
- Como  $\Lambda_{\mathbf{X}} > 0$ , entonces  $\Lambda_{\mathbf{X}} = \Lambda_{\mathbf{X}}^{1/2} \Lambda_{\mathbf{X}}^{1/2}$
- Definimos una transformación  $\mathbf{Z} = A\mathbf{X}$  con  $A = \Lambda_{\mathbf{X}}^{-1/2} P_{\mathbf{X}}^t$ . Entonces

$$C_{\mathbf{Z}} = \underbrace{\Lambda_{\mathbf{X}}^{-1/2} P_{\mathbf{X}}^t}_A C_{\mathbf{X}} \underbrace{P_{\mathbf{X}} \Lambda_{\mathbf{X}}^{-1/2}}_{A^t} = \Lambda_{\mathbf{X}}^{-1/2} \underbrace{P_{\mathbf{X}}^t P_{\mathbf{X}} \Lambda_{\mathbf{X}}}_{\text{ME CASO EN EL ÁLGEBRA LINEAL}} \underbrace{P_{\mathbf{X}}^t P_{\mathbf{X}} \Lambda_{\mathbf{X}}^{-1/2}}_{A^t} = \mathbf{I}_n$$

- Completamos con el desplazamiento  $b = -A\mu_{\mathbf{X}}$ ,  $\mathbf{Z} = A\mathbf{X} + b$ .  
Luego este desplazamiento no afecta la covarianza pero desplaza la media.

$$\mathbb{E}[\mathbf{Z}] = A\mu_{\mathbf{X}} + (-A\mu_{\mathbf{X}}) = 0$$

$$\mathbf{Z} = A\mathbf{X} - A\mu_{\mathbf{X}} = A(\mathbf{X} - \mu_{\mathbf{X}})$$

# Transformaciones afines de $\mathbf{X}$

## Normalización de VeA Gaussiano

Sea  $\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}})$ . La transformación

$$\mathbf{Z} = \underbrace{\Lambda_{\mathbf{X}}^{-1/2}}^{\mathbf{A}} P_{\mathbf{X}}^t (\mathbf{X} - \mu_{\mathbf{X}})$$

resulta en un VeA normal estandar, es decir  $\mathbf{Z} \sim \mathcal{N}(0, \mathbf{I}_n)$

# Transformaciones afines de $\mathbf{X}$

Del mismo modo, partiendo de un VeA normal estándar, podemos obtener un VeA gaussiano con media y covarianza dadas.

## Normalización de VeA Gaussiano

Sean  $\mathbf{Z} \sim \mathcal{N}(0, \mathbf{I}_n)$ ,  $\mathbf{Y} \sim \mathcal{N}(\mu_{\mathbf{Y}}, C_{\mathbf{Y}})$  donde  $C_{\mathbf{Y}} = P_{\mathbf{Y}} \Lambda_{\mathbf{Y}} P_{\mathbf{Y}}^t$ . Luego,


$$\mathbf{Y} = P_{\mathbf{Y}} \Lambda_{\mathbf{Y}}^{1/2} \mathbf{Z} + \mu_{\mathbf{Y}}$$

$\mathbf{X}$  e  $\mathbf{Y}$  deben ser de la misma dimensión. ¿Y si quiero otra cosa?

# Transformaciones afines de $\mathbf{X}$ (recap)

$$\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}}) \quad C_{\mathbf{X}} = P_{\mathbf{X}} \Lambda_{\mathbf{X}} P_{\mathbf{X}}^t$$

$$\mathbf{Y} \sim \mathcal{N}(\mu_{\mathbf{Y}}, C_{\mathbf{Y}}) \quad C_{\mathbf{Y}} = P_{\mathbf{Y}} \Lambda_{\mathbf{Y}} P_{\mathbf{Y}}^t$$



# Componentes principales

# Conjuntos de nivel

- Una forma de visualizar y comprender mejor la forma de la PDF de un vector gaussiano es analizar los conjuntos de nivel. Dado un  $\alpha$  constante, se define el conjunto de nivel

$$\{\mathbf{x} \in \mathbb{R}^n : f_{\mathbf{x}}(\mathbf{x}) = \alpha\}$$

$$f_{\mathbf{x}}(\mathbf{x}) = \frac{1}{\sqrt{\det(2\pi \mathbf{C}_{\mathbf{x}})}} e^{-(\mathbf{x} - \mu_{\mathbf{x}})^T \mathbf{C}_{\mathbf{x}}^{-1} (\mathbf{x} - \mu_{\mathbf{x}})/2} = \alpha,$$

$$\implies (\mathbf{x} - \mu_{\mathbf{x}})^T \mathbf{C}_{\mathbf{x}}^{-1} (\mathbf{x} - \mu_{\mathbf{x}}) = \beta, \quad \text{donde } \beta \text{ es otra constante.}$$

Esta ecuación describe a un elipsoide en  $\mathbb{R}^n$ .

# Direcciones principales

Vimos que  $C_X = P\Lambda P^t$ , con  $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$  y  $PP^t = I_n$

Reemplazando esta expresión en la ecuación de la elipsoide, tenemos

*¿cómo mierda se llamaba → ¿o es composición diagonal?*  
*es de composición?*

$$\beta = \underbrace{(x - \mu_X)^t P}_{\text{DIAGONALIZACIÓN}} \underbrace{\Lambda^{-1}}_{\text{y}} \underbrace{P^t (x - \mu_X)}_{y \in \mathbb{R}^n}$$

Definimos un vector auxiliar  $y = P^t(x - \mu_X)$ . Luego recordando que

$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ ,  $y_i = \frac{1}{\lambda_i} (x - \mu_X)^t P^t e_i$  ←  $y = \begin{bmatrix} e^{\mu_1}, x - \mu_X \\ e^{\mu_2}, x - \mu_X \\ \vdots \end{bmatrix}$

$$\beta = y^t \Lambda^{-1} y = \sum_{i=1}^n \frac{y_i^2}{\lambda_i}.$$

↓  
AVES

Los auto-vec de  $C_X$  son las *Direcciones principales* del elipsoide cuyos ejes tienen una longitud proporcional a los auto-val de  $C_X$ .

WTF

## Ejemplo: curvas de nivel en $\mathbb{R}^2$

- $\mathbf{X} = [X, Y] \sim \mathcal{N}(0, C_X)$ .

- La matriz de covarianza es

$$C_X = \begin{bmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{bmatrix} \rightarrow C_X^{-1} = \frac{1}{\sigma_X^2\sigma_Y^2(1-\rho^2)} \begin{bmatrix} \sigma_Y^2 & -\rho\sigma_X\sigma_Y \\ -\rho\sigma_X\sigma_Y & \sigma_X^2 \end{bmatrix}.$$

- Luego,

$$\mathbf{x}^T C_X^{-1} \mathbf{x} = \frac{1}{1-\rho^2} \left[ \frac{x^2}{\sigma_X^2} - 2\rho \frac{x}{\sigma_X} \frac{y}{\sigma_Y} + \frac{y^2}{\sigma_Y^2} \right].$$


Las curvas de nivel son  $\{(x, y) \in \mathbb{R}^2 : \frac{x^2}{\sigma_X^2} - 2\rho \frac{x}{\sigma_X} \frac{y}{\sigma_Y} + \frac{y^2}{\sigma_Y^2} = c\}$

- Las longitudes de los semiejes principales son proporcionales a  $\sigma_X$  y  $\sigma_Y$ .



*invierte la diag principal y multiplica x' menor en la secundaria*



# Ejemplo: curvas de nivel en $\mathbb{R}^2$



$\rho = 0 \rightarrow X, Y$   
descorrelacionadas



**FLASHBACKS de Álgebra**

$\rho > 0$  Para eso nos hacían dibujar esas  
elipses del orto

$\rho < 0$

# Análisis de componentes principales

- Los conjuntos de nivel de la pdf de  $\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, C_{\mathbf{X}})$  son elipsoides cuyas direcciones son los auto-vec  $\{p_1, \dots, p_n\}$ . El largo de cada eje es proporcional al auto-val asociado  $\{\lambda_1, \dots, \lambda_n\}$ .  
Supongamos que los auto-vec están ordenados de modo que  $\lambda_1 \geq \dots \geq \lambda_n$ .
- Si a partir de un auto-val, los auto-val restantes son mucho más pequeños, es decir,  $\lambda_1 \geq \dots \geq \lambda_r \gg \lambda_{r+1} \geq \dots \geq \lambda_n$ , las realizaciones de  $\mathbf{X}$  van a tener mayor variación en las direcciones  $p_1, \dots, p_r$  que en las restantes direcciones de  $\mathbb{R}^n$
- Una idea para *comprimir* la información contenida en el vector  $\mathbf{X}$  es observar solamente las primeras  $r$  componentes.
- Es decir, vamos a aproximar  $\mathbf{X}$  por un VeA en el subespacio generado por  $\{p_1, \dots, p_r\}$ . De ahí lo de *dirección principal*

# Análisis de componentes principales

Sin falta de generalidad, vamos a considerar que  $\mu_{\mathbf{X}} = 0$ .

Las *componentes principales* de  $\mathbf{X}$  son las proyecciones de  $\mathbf{X}$  en cada una de sus direcciones principales. Es decir, la  $i$ -ésima componente principal tiene la forma

$$Y_i = p_i^t \mathbf{X} = \langle \mathbf{v}_i, \mathbf{X} \rangle$$

- $Y_i$  es una V.A (pregunta: es gaussiana?)  $\rightarrow$  Sí, es CL de GAUSS
- Para representar  $\mathbf{X}$  como combinación lineal de  $\{p_1, \dots, p_r\}$  utilizamos las primeras  $r$  componentes principales:

$$\mathbf{X} \approx \hat{\mathbf{X}}_r = \sum_{i=1}^r Y_i p_i = \sum_{i=1}^r p_i^t \mathbf{X} p_i = \underbrace{\langle \mathbf{v}_i, \mathbf{X} \rangle}_{\substack{\text{Una proyección} \\ \text{de las de toda la} \\ \text{vida}}} \cdot \mathbf{v}_i$$

$\| \mathbf{v}_i \|^2 \rightarrow 1$

Obviamente, cuando  $r = n$ ,  $\hat{\mathbf{X}}_n = \mathbf{X}$ .

- Este análisis se llama *Análisis de componentes principales* o PCA (principal component analysis).

## Ejemplo: PCA en $\mathbb{R}^2$

Sea  $\mathbf{X} = [X_1, X_2]^t$  de media nula y matriz de covarianza

$$\mathbf{C}_{\mathbf{X}} = \begin{bmatrix} \sigma^2 & \rho\sigma^2 \\ \rho\sigma^2 & \sigma^2 \end{bmatrix}.$$

Cuál es la media cuadrática del error de representación  $\mathbb{E}[\|\mathbf{X} - \hat{\mathbf{X}}_r\|^2]$ ?

- En este caso, la diagonalización de  $\mathbf{C}_{\mathbf{X}}$  resulta en

$$\lambda_1 = \sigma^2(1 + \rho), \quad \lambda_2 = \sigma^2(1 - \rho), \quad \rho_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \rho_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

## Ejemplo: PCA en $\mathbb{R}^2$

- La primera componente principal de  $\mathbf{X}$

$$Y_1 = p_1^t \mathbf{X} = \frac{X_1 + X_2}{\sqrt{2}}$$

y la mejor representación en un subespacio de dimensión 1 es

$$\hat{\mathbf{X}}_1 = Y_1 p_1 = \frac{X_1 + X_2}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

- La segunda componente principal de  $\mathbf{X}$  es

$$Y_2 = p_2^t \mathbf{X} = \frac{X_1 - X_2}{\sqrt{2}}$$

## Ejemplo: PCA en $\mathbb{R}^2$

- Claramente, si tomamos ambas componentes obtenemos

$$\hat{\mathbf{X}}_2 = Y_1 p_1 + Y_2 p_2 = \frac{X_1 + X_2}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \frac{X_1 - X_2}{2} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \mathbf{X}.$$

*→  $X_1, p_1, p_2$  son ort.*

- Como  $\mathbf{X} - \hat{\mathbf{X}}_1 = Y_2 p_2 = (p_2^t \mathbf{X}) p_2$ , el error de la representación es

$$\mathbb{E} [\|\mathbf{X} - \hat{\mathbf{X}}_1\|^2] = \mathbb{E} [ |p_2^t \mathbf{X}|^2 \|p_2\|^2 ] = \mathbb{E} [ |p_2^t \mathbf{X}|^2 ] \quad \text{por ser } \|p_2\| = 1$$

$$= \mathbb{E} [ |p_2^t \mathbf{X} \cdot p_2^t \mathbf{X}| ] = \mathbb{E} [ p_2^t \mathbf{X} \mathbf{X}^t p_2 ] = p_2^t C_X p_2 = \lambda_2 = \sigma^2(1 - \rho).$$

*→  $E[\mathbf{X} \cdot \mathbf{X}^t] = C_X$  si  $\mu_X = 0$*

- Interpretación:* cuánto más fuerte sea la correlación entre las variables, menor será el error. En el caso degenerado las dos componentes se desplazan en un subespacio de dimensión 1. Como  $\rho = 1$ ,  $\mathbb{E} [\|\mathbf{X} - \hat{\mathbf{X}}_1\|^2] = 0$ .

# Reducción de la dimensionalidad en imágenes



Reconstrucciones de una imagen del dígito 4 de la base de datos MNIST usando (a)  $r = 1$ , (b)  $r = 2$ , (c)  $r = 4$ , (d)  $r = 8$ , (e)  $r = 16$ , (f)  $r = 32$ , (g)  $r = 64$ , (h)  $r = 128$ , (i)  $r = 400$  componentes principales.

Divisimo primo. La matemática es infinita

## Ejercicios



## Ejercicio: Vector gaussiano degenerado

Sea  $Z \sim \mathcal{N}(0, 1)$ . Definimos el VeA

$$\mathbf{x} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} Z \\ 2Z + 1 \end{bmatrix}.$$

Calcular la pdf conjunta  $f_{\mathbf{x}}(\mathbf{x})$ .

# Solución

- De la definición de  $\mathbf{X}$ , deducimos que  $X_1 \sim \mathcal{N}(0, 1)$ .
- Igualmente,  $X_2 = 2X_1 + 1$ , y por ende  $X_2$  es gaussiana por ser transformación afín de una gaussiana. Más aún,  $X_2 \sim \mathcal{N}(1, 4)$ .
- Como  $X_2 = 2X_1 + 1$ , observamos que la realización  $x_1$  determina sin ambigüedades la realización de  $X_2$ .
- Utilizando la ley de cadena obtenemos


$$\begin{aligned}f_{\mathbf{X}}(\mathbf{x}) &= f_{X_1, X_2}(x_1, x_2) = f_{X_1}(x_1) f_{X_2|X_1=x_1}(x_2|x_1) \\&= \frac{1}{\sqrt{2\pi}} e^{-x_1^2/2} \delta(x_2 - (2x_1 + 1)).\end{aligned}$$

- No hay una única forma de escribir la PDF conjunta.


$$\begin{aligned}f_{\mathbf{X}}(\mathbf{x}) &= f_{X_1, X_2}(x_1, x_2) = f_{X_2}(x_2) f_{X_1|X_2=x_2}(x_1) \\&= \frac{1}{\sqrt{8\pi}} e^{-(x_2-1)^2/2} \delta\left(x_1 - \frac{x_2 - 1}{2}\right).\end{aligned}$$

# Solución

Realizaciones de  $\mathbf{X}$



Curvas de Nivel de  $f_{\mathbf{X}}$



## Ejercicio: V.As marginalmente pero no conjuntamente gaussianas

Sean  $X \sim \mathcal{N}(0, 1)$  y  $B \sim \text{Ber}(1/2)$ , independientes entre sí. Definimos

$$Y = (2B - 1)X.$$

Determinar si  $X$  e  $Y$  son conjuntamente gaussianas o no.

# Solución

- Para que las V.A sean conjuntamente gaussianas, las dos deben ser gaussianas.  $X$  lo es. Tenemos que ver qué pasa con  $Y$ . Para ello, calculamos la cdf:

$$\begin{aligned}F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(B = 1)\mathbb{P}(X \leq y) + \mathbb{P}(B = 0)\mathbb{P}(-X \leq y) \\&= \frac{1}{2}\mathbb{P}(X \leq y) + \frac{1}{2}\mathbb{P}(X \geq -y) = \mathbb{P}(X \leq y).\end{aligned}$$

Es decir,  $Y$  es gaussiana y tiene la misma distribución que  $X$ .

- La suma resulta  $W = X + Y = 2BX$ . Luego,

$$\begin{aligned}F_W(w) &= \mathbb{P}(W \leq w) = \mathbb{P}(B = 1)\mathbb{P}(2X \leq w) + \mathbb{P}(B = 0)\mathbb{P}(0 \leq w) \\&= \frac{1}{2}\mathbb{P}(X \leq \frac{w}{2}) + \frac{1}{2}\mathbb{1}\{w \geq 0\} \rightarrow W \text{ no es normal.}\end{aligned}$$

- Como hay una combinación lineal de  $X$  e  $Y$  que no es gaussiana, entonces  $X$  e  $Y$  no son conjuntamente gaussianas, pese a ser cada una marginalmente gaussianas.

# Solución

Cómo es la distribución conjunta  $f_{X,Y}(x, y)$ ?

- Como  $Y = (2B - 1)X$ , cuando  $X = x$ ,  $Y = x$  o  $Y = -x$  dependiendo de si  $B = 1$  o  $B = 0$ . Es decir que

$$f_{Y|X}(y|X = x) = \mathbb{P}[B = 1]\delta(y - x) + \mathbb{P}[B = 0]\delta(y + x)$$

- Utilizando la regla de la cadena

$$f_{X,Y}(x, y) = f_{Y|X}(y|X = x)f_X(x) = \frac{1}{2} [\delta(y - x) + \delta(y + x)] f_X(x)$$

Claramente, no es gaussiana.

# Ejercicio: Gaussianas independientes

Un transmisor de radio envía una señal  $s > 0$  que es recibida en un receptor utilizando tres caminos. Las señales que llegan al receptor por cada camino son:

$$X_1 = s + N_1 \quad X_2 = s + N_2 \quad X_3 = s + N_3$$

donde  $N_1, N_2, N_3$  son variables aleatorias gaussianas independientes con media cero y varianza unitaria.

- 1 Hallar la pdf conjunta de  $\mathbf{X} = [X_1, X_2, X_3]^t$
- 2 Determine si las componentes de  $\mathbf{X}$  son variables aleatorias independientes.
- 3 Hallar la probabilidad de que el mínimo de las tres señales sea positivo.
- 4 Hallar la probabilidad de que la mayoría de las señales sean positivas.

# Ejercicio: Canal de comunicaciones

La señal transmitida por un canal de comunicaciones se suele modelar con un  $\text{VeA } \mathbf{X} \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$  de módulo  $A$  y módulo al cuadrado  $B$

$$\mathbf{X} = \begin{bmatrix} U \\ V \end{bmatrix} \quad A = \sqrt{U^2 + V^2} \quad B = A^2.$$

Luego,  $A \sim \text{Rayleigh}(\sigma)$  y  $B \sim \text{Exp}(\frac{\sigma^2}{2})$ .

$$f_A(a) = \frac{a}{\sigma^2} e^{-a^2/(2\sigma^2)} \quad , \quad f_B(b) = \frac{\sigma^2}{2} e^{-b\sigma^2/2} \quad a, b \geq 0$$

Para combatir las perturbaciones del canal se agrega redundancia en el mensaje. En un modelo sencillo, se envían  $N$  versiones independientes de una misma señal en forma consecutiva,  $\mathbf{X}_1, \dots, \mathbf{X}_N$ . Una señal es descartada si su amplitud al cuadrado  $B_k$  está por debajo de un umbral  $\gamma$ .

Hallar la probabilidad de que las  $N$  señales estén por debajo de ese umbral.



# V.A conjuntamente gaussianas

Sean  $X$  e  $Y$  dos V.A conjuntamente gaussianas de media nula.  
Demuestre que

$$\mathbb{E}[X^2 Y^2] = \mathbb{E}[X^2]\mathbb{E}[Y^2] + 2\mathbb{E}^2[XY]$$

*Ayuda:* Utilice el resultado de gaussiana condicionada por gaussiana y la expresión de los momentos de una gaussiana.