

Procesos Estocásticos y Sistemas


Cecilia Galarza

Procesos Estocásticos
Facultad de Ingeniería, Universidad de Buenos Aires

1er cuatrimestre 2025

Identificación de sistemas

Un sistema general, tiene un proceso de entrada, uno de salida y sufre perturbaciones, algunas observables otras no.



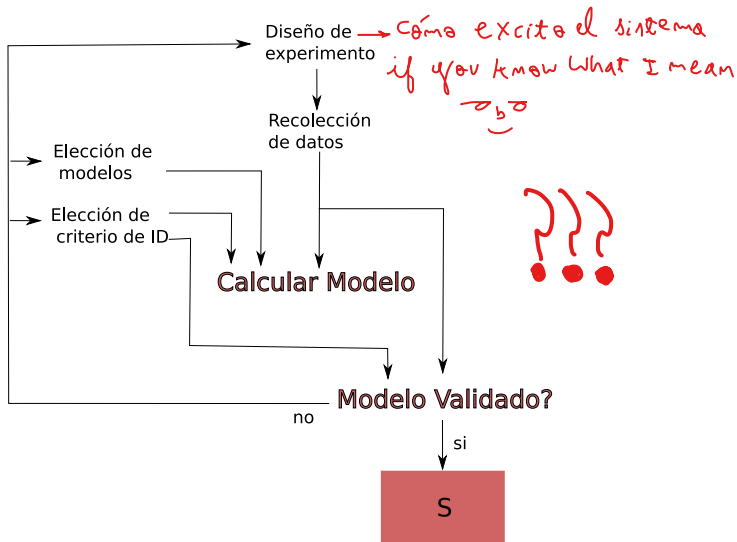
$X(n), Y(n)$: par (entrada, salida)

$D(n)$: perturbación observables

$W(n)$: perturbación no-observable (ruido)

Identificación de sistemas: procedimiento general

Se ve q'
hay muchas
entidades de
esto



Identificación de sistemas

El problema de identificación del sistema S , utiliza realizaciones de $(X(n), Y(n))$, eventualmente de $D(n)$ para caracterizar la dinámica del sistema. A modo de introducción, vamos a desarrollar la solución cuando

- S es un sistema LTI caracterizado por su respuesta impulsiva $h(n)$ y la respuesta en frecuencia $H(\omega)$.
- $D(n) = 0$.
- $X(n)$ es un proceso ESA.

Identificación de sistemas usando $S_{XY}(\omega)$

- Supongamos que un sistema desconocido $H(\omega)$ es excitado con ruido blanco $X(n)$ con PSD $S_X(\omega) = \sigma^2$. Entonces,

$$R_{XY}(k) = h(k) * \underbrace{R_X(k)}_{\sigma^2 \delta(k)} \implies S_{X,Y}(\omega) = \sigma^2 H(\omega).$$

- Sea $\hat{S}_{X,Y}(\omega)$ una estimación de la PSD cruzada obtenida a partir de una realización de la salida del sistema $y(0), y(1), \dots, y(L)$.
Planteamos

$$\hat{H}(\omega) = \frac{\hat{S}_{X,Y}(\omega)}{\sigma^2}.$$

Identificación de sistemas usando $S_{XY}(\omega)$

- Éste es un método de identificación *no paramétrico*.
- No es necesario conocer la estructura del sistema (cuántos polos, ceros, etc).
- La calidad de la estimación de H depende directamente de la calidad de la estimación de $S_{X,Y}$.

Identificación paramétrica

Supongamos que la respuesta en frecuencia $H(\omega)$ se modela como

¿Y K?

$$H(\omega) = \frac{1 + \sum_{k=1}^M b_k e^{-j\omega k}}{1 + \sum_{k=1}^N a_k e^{-j\omega k}}, \quad \omega \in [-\pi, \pi]$$

Esto impone la cantidad de polos y ceros. Es más restrictiva

para N y M conocidos. Identificar $H(\omega)$ es hallar

$$\{\hat{a}_k, k = 1, \dots, N\} \quad \text{y} \quad \{\hat{b}_k, k = 1, \dots, M\}$$

a partir de las realizaciones $\{y(n), n = 0, \dots, L\}$.

Identificación paramétrica

Se podría plantear el problema de optimización


minimizar la diferencia entre \hat{S} y S variando a_k y b_k

$$\min_{a_k, b_k} \int_{-\pi}^{+\pi} |\hat{S}_{XY}(\omega) - \sigma^2 H(\omega)|^2 d\omega$$

seguramente termine acá

Este problemita tan inocente es casi imposible de resolver con algoritmos.

Problema no-convexo



Pero éste es un problema no-convexo y tiene múltiples mínimos locales. Vamos a utilizar la estructura del modelo para salvar este problema cuando sea posible. Para ello, asociamos la salida del sistema a distintos tipos de procesos:

La idea sería: estimo S^A con realizaciones de y y luego busco los a_k, b_k que minimicen el error para hallar $H(\omega)$

• Si $\forall \omega, \sum_{k=1}^M b_k e^{-j\omega k} = 0 \rightarrow$ proceso AR.

• Si $\forall \omega, \sum_{k=1}^N a_k e^{-j\omega k} = 0 \rightarrow$ proceso MA.

• En el caso general, se asocia el modelo a un proceso ARMA.

Modelado por procesos autoregresivos

- Son sistemas sólo con polos, lo que permite modelar señales de banda angosta con picos colocando polos cerca de la circunferencia unitaria.
- El sistema $h(k)$ es causal y estable con respuesta impulsiva de duración infinita

$$Y(k) = \sum_{q=0}^{\infty} h(q)X(k-q) \quad (h[0] = 1).$$

- La estimación de los coeficientes del AR se obtienen resolviendo ecuaciones lineales, lo que lo hace un técnica atractiva.

Recordando Yule-Walker

Ecuaciones YW

$$R_Y(p) + \sum_{i=1}^N a_i R_Y(p-i) = \sigma^2 \delta(p) \quad p = 0, \dots, N$$

Nota: Si $h(0) \neq 1$, entonces tomamos $\sigma^2 = \sigma_X^2 h(0)$.

Sistema de ecuaciones con incógnitas \mathbf{a}_N y σ^2 .

$$\begin{cases} \begin{bmatrix} R_Y(0) & \mathbf{r}_N^t \end{bmatrix} \begin{bmatrix} 1 \\ \mathbf{a}_N \end{bmatrix} = \sigma^2 \\ \mathbf{r}_N + \mathbf{R}_N \mathbf{a}_N = \mathbf{0} \end{cases}$$

Identificación utilizando ecuaciones YW

ESTARÍA BUENO ENTENDER ESTO

- Seleccionar el orden del modelo N
- Estima $\hat{R}_Y(k)$, $k = 0 \cdots N$ utilizando el estimador sesgado
- Armar la matriz $\hat{\mathbf{R}}_N$ y el vector $\hat{\mathbf{r}}_N$.
- Estiman los coeficientes del AR y la varianza de la entrada

$$\hat{\mathbf{a}}_N = -\hat{\mathbf{R}}_N^{-1} \hat{\mathbf{r}}_N \quad \sigma^2 = \hat{R}_Y(0) - \hat{\mathbf{r}}_N^t \hat{\mathbf{R}}_N^{-1} \hat{\mathbf{r}}_N$$

Solución alternativa

Volvemos a la descripción del proceso de salida del sistema con entrada ruido blanco de media nula,

$$Y(n) + \underbrace{\sum_{i=1}^N a_i Y(n-i)}_{V(n-1)} = X(n) \quad \begin{cases} \mathbb{E}[X(n)] = 0 \\ R_X(k) = \sigma_X^2 \delta(k) \end{cases}$$

En el instante n y habiendo observado $y(n-1), y(n-2), \dots$, contamos con una realización del término $V(n-1)$. Luego,

$$\begin{aligned} \mathbb{E}[Y(n) | Y(n-1), \dots, Y(n-N)] &= \mathbb{E}[X(n) - V(n-1) | V(n-1)] \\ &= -v(n-1) \\ &\quad \downarrow \\ &\quad \mathbb{E}[X(n)] = 0 \end{aligned}$$

Solución alternativa: error de predicción

Predicción de un paso en adelante para $Y(n)$ (*one-step ahead prediction*)

Esto es la mejor apuesta que puedo hacer con esta información
Mentira, la mejor apuesta es todo al rojo, siempre y en todo lugar

$$\hat{y}(n|n-1) = \mathbb{E}[Y(n)|Y(n-1), \dots, Y(n-N)] = -V(n-1)$$

El desarrollo anterior asume que también conocemos \mathbf{a}_N , es decir

$$\hat{y}(n|n-1; \mathbf{a}_N) = [-y(n-1) \quad \dots \quad -y(n-N)] \begin{bmatrix} a_1 \\ \vdots \\ a_N \end{bmatrix}$$

✓
Vector de coeficientes

Error de predicción:

$$|y(n) - \hat{y}(n|n-1; \mathbf{a}_N)| = |y(n) + \sum_{i=1}^N a_i y(n-i)|$$

Solución alternativa: error de predicción de varianza mínima

Un criterio de identificación es hallar los coeficientes que minimicen la varianza del error de predicción, es decir

$$\min_{\mathbf{a}_N} \mathbb{E} [|Y(n) - \hat{y}(n|n-1; \mathbf{a}_N)|^2]$$

Desarrollando el error de predicción,

$$\left| Y(n) + \sum_{i=1}^N a_i y(n-i) \right| = \left| Y(n) + \begin{bmatrix} y(n-1) & y(n-2) & \cdots & y(n-N) \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_N \end{bmatrix} \right|$$

$\hat{y}(n) = -V(n-1) = - \begin{bmatrix} y(n-1) & \cdots & y(n-N) \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_N \end{bmatrix}$

Solución alternativa: error de predicción de varianza mínima

A partir de la realización $y(0), \dots, y(L)$, $L \gg N$, definimos:

Esto es la ecuación ~~de~~ para distintos instantes de tiempo

$$\mathbf{y} = \begin{bmatrix} y(N) \\ y(N+1) \\ \vdots \\ y(L) \end{bmatrix} \quad \mathbf{Y} = \begin{bmatrix} y(N-1) & y(N-2) & \dots & y(0) \\ y(N) & \ddots & \dots & y(1) \\ \vdots & \vdots & \dots & \vdots \\ y(L-1) & y(L-2) & \dots & y(L-N) \end{bmatrix}.$$

Para cada instante $N, N+1, \dots, L$, el error de predicción resulta

$$\text{ERROR} = \begin{bmatrix} y(N) \\ y(N+1) \\ \vdots \\ y(L) \end{bmatrix} + \begin{bmatrix} y(N-1) & y(N-2) & \dots & y(0) \\ y(N) & \ddots & \dots & y(1) \\ \vdots & \vdots & \dots & \vdots \\ y(L-1) & y(L-2) & \dots & y(L-N) \end{bmatrix} \mathbf{a}_N.$$

Solución alternativa: error de predicción de varianza mínima

- Aproximamos la varianza del error de predicción por $\|\mathbf{y} + \mathbf{Y} \mathbf{a}_N\|^2$.
- El problema a resolver es entonces

$$\min_{\mathbf{a}_N} \|\mathbf{y} + \mathbf{Y} \mathbf{a}_N\|^2$$

ESTE problema
es convexo

Estimador LS

El estimador de los parámetros del AR por **cuadrados mínimos** es (si las columnas de \mathbf{Y} son LI):

SOLUCIÓN ÚNICA

$$\hat{\mathbf{a}}_N = -(\mathbf{Y}^t \mathbf{Y})^{-1} (\mathbf{Y}^t \mathbf{y}).$$

La puta madre que te remil
pario

Creo que es la pseudo inversa de los hijos de remil puta de moore-penrose

Breve repaso de álgebra para resolver $\min ||\mathbf{y} + \mathbf{Y}\mathbf{a}||^2$

- Sea $\mathbf{Y} \in \mathbb{R}^{p \times q}$ (en este caso, $p = L - N + 1$, y $q = N$).
- A partir de \mathbf{Y} se definen dos espacios complementarios, $\text{col}(\mathbf{Y})$ y $\text{ker}(\mathbf{Y}^t)$ tal que $\forall \mathbf{y} \in \mathbb{R}^p$,

$$\mathbf{y} = \hat{\mathbf{y}} + \mathbf{y}_0 \quad \hat{\mathbf{y}} \in \text{col}(\mathbf{Y}), \quad \mathbf{y}_0 \in \text{ker}(\mathbf{Y}^t), \quad \hat{\mathbf{y}} \perp \mathbf{y}_0.$$

- *Observación:* $\mathbf{Y}\mathbf{a} \in \text{col}(\mathbf{Y})$. Luego, se necesita encontrar el elemento de $\text{col}(\mathbf{Y})$ más cercano a $(-\mathbf{y})$, es decir, la proyección ortogonal de $-\mathbf{y}$ sobre $\text{col}(\mathbf{Y})$. Ésta es $\hat{\mathbf{y}} = -\mathbf{Y}\mathbf{a}$.
- Integrando estas ideas, $\mathbf{y}^t \cdot \mathbf{y}_0 = 0$

$$\mathbf{Y}^t \mathbf{y} = \mathbf{Y}^t (\hat{\mathbf{y}} + \mathbf{y}_0) \stackrel{\uparrow}{=} \mathbf{Y}^t \hat{\mathbf{y}} = -\mathbf{Y}^t \mathbf{Y} \mathbf{a} \longrightarrow \mathbf{Y}^t \mathbf{y} = -\mathbf{Y}^t \mathbf{Y} \mathbf{a}$$

- Si \mathbf{Y} de rango completo, $\mathbf{Y}^t \mathbf{Y}$ invertible, *Se puede ret. como ditiu Johnny Viale? LA res?*

$$\mathbf{a} = -[\mathbf{Y}^t \mathbf{Y}]^{-1} \mathbf{Y}^t \mathbf{y}$$

Modelado AR: comparación técnicas

Usando YW con estimación de la autocorrelación

$$\hat{\mathbf{a}}_N = -\hat{\mathbf{R}}_N^{-1} \hat{\mathbf{r}}_N$$

Usando mínimos cuadrados

$$\hat{\mathbf{a}}_N = -(\mathbf{Y}^t \mathbf{Y})^{-1} \mathbf{Y}^t \mathbf{y}$$

- $(\mathbf{Y}^t \mathbf{Y})$ es una estimación de $\hat{\mathbf{R}}_N$, $(\mathbf{Y}^t \mathbf{y})$ una estimación de $\hat{\mathbf{r}}_N$
- El método LS no requiere estimar \hat{R}_Y .
- Pero, cuando L es pequeño, $\mathbf{Y}^t \mathbf{Y}$ no es necesariamente positiva
- Para L grande ambas técnicas obtienen resultados similares.

Sistemas de promedio móvil

- Sistemas de sólo ceros, con polo múltiple en el origen

$$Y(n) = X(n) + \sum_{i=1}^M b_i X(n-i)$$

- Se asume que el *orden del modelo* M es conocido.
- A partir de la observación de $y(0), \dots, y(L)$, se necesita estimar

$$b_1, \dots, b_M.$$

Volvemos a la predicción de un paso en adelante

Volviendo a la definición del sistema

$$Y(n) = X(n) + \sum_{i=1}^M b_i X(n-i)$$

Como en el caso, anterior, obtenemos la predicción de un paso

$$\hat{y}(n|n-1; \mathbf{b}_M) = \mathbb{E} [Y(n) | Y(n-1, \dots)] = \sum_{i=1}^M b_i x(n-i)$$

donde \mathbf{b}_M es el vector de parámetros y $x(k)$ es la realización de la entrada. El error de predicción resulta

$$\varepsilon(n; \mathbf{b}_M) = y(n) - \hat{y}(n|n-1; \mathbf{b}_M)$$

Volvemos a la predicción de un paso en adelante

Si \mathbf{b}_M corresponde a los parámetros del sistema,

$$\varepsilon(n; \mathbf{b}_M) = x(n).$$

Luego,

$$\begin{aligned} \varepsilon(n; \mathbf{b}_M) &= y(n) - \sum_{i=1}^M b_i \varepsilon(n-i; \mathbf{b}_M) \\ &= y(n) - \underbrace{\begin{bmatrix} \varepsilon(n-1; \mathbf{b}_M) & \varepsilon(n-2; \mathbf{b}_M) & \cdots & \varepsilon(n-M; \mathbf{b}_M) \end{bmatrix}}_{\varepsilon(n-1; \mathbf{b}_M)^t} \underbrace{\begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_M \end{bmatrix}}_{\mathbf{b}_M} \end{aligned}$$

Identificación de menor error de predicción

Dada una observación $y(0), \dots, y(L)$ podemos plantear como antes la minimización de la varianza del error de predicción

$$\min_{\mathbf{b}_M} \sum_{n=M}^L |y(n) - \varepsilon(n; \mathbf{b}_M)^t \mathbf{b}_M|^2$$

- Ahora el problema es no-lineal dado que $\varepsilon(n; \mathbf{b}_M)$ depende de \mathbf{b}_M .
- Un modo de resolverlo de modo iterativo
 - Dado $\mathbf{b}_M^{(0)}$, obtener $\varepsilon(n; \mathbf{b}_M^{(0)})$
 - Resolver problema de mínimos cuadrados $\longrightarrow \mathbf{b}_M^{(1)}$
 - Iterar

Modelado ARMA

- El modelo ARMA es más general. Tiene polos y ceros
- Sea $H(z)$ la transferencia del modelo a identificar (se asume estable):

$$H(z) = \frac{B(z)}{A(z)} = \frac{1 + b_1 z^{-1} + b_M z^{-M}}{1 + a_1 z^{-1} + a_N z^{-N}}$$

- El problema es obtener a_i y b_i .

Modelado ARMA: técnica LS en dos etapas

- Si fuera posible conocer la secuencia de entradas $x(k)$ al ARMA, podría utilizarse una técnica para estimar la respuesta del sistema como un problema de identificación de un sistema.
- La técnica LS en dos pasos se basa en estimar primero dicha secuencia.
- El modelo ARMA puede elegirse de fase mínima (ceros estables) de modo que tiene inversa estable y puede interpretarse a $X(k)$ como la salida mientras que $Y(k)$ es la entrada:

$$X(z) = \frac{A(z)}{B(z)} Y(z) = V(z) Y(z)$$

- Al ser causal, la respuesta de este “nuevo” sistema puede expandirse como una respuesta impulsiva infinita:

$$x(k) = y(k) + \sum_{p=1}^{\infty} v[p]y[k-p],$$

Modelado ARMA: técnica LS en dos etapas

- La respuesta $v(k)$ tiene infinitos coeficientes, no puede ser estimada con una cantidad finita de muestras.
- Sin embargo puede truncarse la respuesta a un orden K que contenga la mayor parte de la energía:

$$\hat{x}(k) = y(k) + \sum_{p=1}^K \tilde{v}[p]y[p-k].$$

- Se puede resolver el problema como un AR de orden K .
- Utilizando la solución $\tilde{v}[p]$, $p = 1, \dots, K$, se estima la entrada del ARMA: $\{\hat{x}[K+1], \dots, \hat{x}[N]\}$.

Modelado ARMA: técnica LS en dos etapas (III)

- Se definen:

$$\mathbf{w} \triangleq \left[\begin{array}{ccc|ccc} a_1 & \dots & a_N & b_1 & \dots & b_M \end{array} \right]^t$$

y

$$\mathbf{u}(k) = \left[\begin{array}{ccc|ccc} y[k-1] & \dots & y[k-N] & -\hat{x}[k-1] & \dots & -\hat{x}[k-M] \end{array} \right]^t.$$

- Volviendo al modelo ARMA, tenemos:

$$y(k) + \mathbf{u}(k)^t \mathbf{w} = \hat{x}(k) \quad k \geq K.$$

Modelado ARMA: técnica LS en dos etapas (IV)

Sea $T = K + M$. Usando una realización $y(0), \dots, y(L)$, definimos:

$$\mathbf{Z} \triangleq \begin{bmatrix} y[T-1] & \dots & y[T-M] & -\hat{x}[T-1] & \dots & -\hat{x}[T-M] \\ y[T] & \dots & y[T-M+1] & -\hat{x}[T] & \dots & -\hat{x}[T-M+1] \\ \vdots & & \vdots & \vdots & & \vdots \\ y[L-1] & \dots & y[L-M] & -\hat{x}[L-1] & \dots & -x[L-M] \end{bmatrix}$$

$$\mathbf{z} = [y[T] \quad y[T+1] \quad \dots \quad y[L]]^t$$

$$\hat{\mathbf{x}} = [\hat{x}[T] \quad \hat{x}[T+1] \quad \dots \quad \hat{x}[L]]^t$$

$$\min_{\mathbf{w}} \|\mathbf{z} + \mathbf{Z}\mathbf{w}\|^2$$

$$\hat{\mathbf{w}} = -(\mathbf{Z}^t \mathbf{Z})^{-1} (\mathbf{Z}^t \mathbf{z}).$$

Modelado ARMA: técnica LS en dos etapas (V)

Algunas observaciones:

- El estimador es positivo por construcción.
- Por el truncado del modelo AR, el estimador tiene sesgo. Tomando K grande se compensa esto.
- Sin embargo, K no debería ser tan grande que reduzca la exactitud del segundo paso.