

Vectores Aleatorios

Cecilia Galarza

Procesos Estocásticos
Facultad de Ingeniería, Universidad de Buenos Aires

1er cuatrimestre 2025

Vector aleatorio

- Un *espacio de probabilidad* queda definido por $(\Omega, \mathcal{F}, \mathbb{P})$
 - Ω : *espacio muestral* que contiene a todos los posibles resultados del experimento
 - \mathcal{F} : conjunto de eventos donde cada evento es un subconjunto de Ω
 - \mathbb{P} : función de probabilidad.
- En algunos experimentos aleatorios, nos interesa analizar más de una característica del resultado. Por ejemplo
 - Experimento: seleccionar una persona en la calle.
 - Observación: peso, altura, ancho de cintura.
- El resultado del experimento está caracterizado por 3 VA distintas. Resulta conveniente agruparlas en un *Vector Aleatorio* (VeA).

Vector aleatorio

Formalmente, un *vector aleatorio* de dimensión n es una función (medible)

$$\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$$

$$\mathbf{X}(\xi) = [X_1(\xi), \dots, X_n(\xi)]^T.$$

X es un vector aleatorio de dimensión n si $X_i, i = 1, \dots, n$, son todas variables aleatorias.

Función de distribución

Función de distribución multivariable

Cómo caracterizamos un vector de VA o un Vector aleatorio $\mathbf{X} = [X_1, \dots, X_n]^t$? Utilizando la *función de distribución cumulativa*¹.

Sea $\mathbf{x} = [x_1, \dots, x_n]^t \in \mathbb{R}^n$ el vector realización de \mathbf{X} . Luego,

$$F_{\mathbf{X}} : \mathbb{R}^n \rightarrow \mathbb{R}$$


$$F_{\mathbf{X}}(\mathbf{x}) := F_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n).$$

Cuando $n = 1$, recuperamos la definición de la CDF de una VA.

¹CDF, Cumulative Distribution Function

Función de distribución multivariable

$$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2)$$



$$F_{\mathbf{X}}(\mathbf{x}) = \mathbb{P}(\mathbf{X} \leq \mathbf{x}).$$


$\mathbf{X} \leq \mathbf{x}$ es una desigualdad simultánea en todas las componentes de \mathbf{X} .

Propiedades de la función de distribución

- *Monótona en cada uno de sus argumentos.* Si $x_i \leq x'_i, i = 1, \dots, n$

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) \leq F_{X_1, \dots, X_n}(x'_1, \dots, x'_n).$$

- *Probabilidad de rectángulos*



Cuál es la probabilidad de observar \mathbf{X} en A ?

$$A = \{(x_1, x_2) \in \mathbb{R}^2 : a < x_1 \leq b, c < x_2 \leq d\}$$

$$\begin{aligned} \mathbb{P}(a < X_1 \leq b, c < X_2 \leq d) &= F_{X_1, X_2}(b, d) - F_{X_1, X_2}(a, d) - \\ &\quad F_{X_1, X_2}(b, c) + F_{X_1, X_2}(a, c). \end{aligned}$$

Propiedades de la función de distribución

- *Límite inferior:* Si algún x_i toma el valor $-\infty$, la CDF se anula.

$$\lim_{x_i \rightarrow -\infty} F_{X_1, \dots, X_n}(x_1, \dots, x_i, \dots, x_n) =$$

$$\lim_{x_i \rightarrow -\infty} \mathbb{P}(X_1 \leq x_1, \dots, X_i \leq x_i, \dots, X_n \leq x_n) = 0,$$

- *Límite superior:* Si todos los x_i toma el valor $+\infty$, la CDF llega a 1.

$$\lim_{x_1, x_2, \dots, x_n \rightarrow +\infty} F_{X_1, \dots, X_n}(x_1, \dots, x_i, \dots, x_n) =$$

$$\lim_{x_1, x_2, \dots, x_n \rightarrow +\infty} \mathbb{P}(X_1 \leq x_1, \dots, X_i \leq x_i, \dots, X_n \leq x_n) = 1,$$

Distribuciones marginales

Si algún argumento toma el valor $+\infty$, la CDF se *marginaliza*.

$$\lim_{x_i \rightarrow +\infty} F_{X_1, \dots, X_n}(x_1, \dots, x_i, \dots, x_n) =$$

$$\lim_{x_i \rightarrow +\infty} \mathbb{P}(X_1 \leq x_1, \dots, X_i \leq x_i, \dots, X_n \leq x_n) =$$

$$\mathbb{P}(X_1 \leq x_1, \dots, X_{i-1} \leq x_{i-1}, X_{i+1} \leq x_{i+1}, \dots, X_n \leq x_n)$$

$$= F_{X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n}(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n).$$

$F_{X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n}$ es la distribución marginal con respecto a X_i . Por ejemplo, en el caso bivariable:

$$F_{X_1, X_2}(\infty, x_2) = F_{X_2}(x_2), \quad F_{X_1, X_2}(x_1, \infty) = F_{X_1}(x_1)$$

Claramente, $F_{X_1, X_2}(\infty, \infty) = 1$.

Función de densidad

Vector aleatorio continuo

X es un vector aleatorio continuo si F_X es continua y existen sus derivadas parciales de orden n . Su *función de densidad de probabilidad*² resulta:

$$f_{\mathbf{X}}(\mathbf{x}) = f_{X_1, \dots, X_n}(x_1, \dots, x_n) = \frac{\partial^n F_{X_1, \dots, X_n}(x_1, \dots, x_n)}{\partial x_1 \dots \partial x_n}.$$

²PDF, *Probability Density Function*

Función de densidad continua: Propiedades

X es un VeA continuo. Su PDF, $f_{\mathbf{X}}$, satisface las siguientes propiedades:

- $f_{X_1, \dots, X_n}(x_1, \dots, x_n) \geq 0, \forall \mathbf{x} \in \mathbb{R}^n.$
- $F_{\mathbf{X}}(\mathbf{x}) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f_{\mathbf{X}}(\mathbf{u}) d\mathbf{u}$ para $\mathbf{x} = [x_1, \dots, x_n]^t.$

Función de densidad multivariable: Propiedades

- *Probabilidad de una región*

$$\mathbb{P}(\mathbf{X} \in A) = \int_{\mathbf{u} \in A} f_{\mathbf{X}}(\mathbf{u}) d\mathbf{u}.$$

Claramente, $\int_{\mathbb{R}^n} f_{\mathbf{X}}(\mathbf{x}) dx_1 \dots dx_n = \mathbb{P}(\mathbf{X} \in \mathbb{R}^n) = 1$.

- *Probabilidad de un punto.* Si \mathbf{X} es un VeA continuo, entonces

$$\mathbb{P}(\mathbf{X} = \mathbf{x}_0) = 0, \quad \forall \mathbf{x}_0 \in \mathbb{R}^n.$$

Funciones de densidad de probabilidad marginales

A partir de la PDF $f_{\mathbf{X}}(\mathbf{x})$ podemos obtener las PDFs *marginales*, integrando con respecto al resto de las variables. Por ejemplo:

$$f_{X_1}(x_1) = \int_{\mathbb{R}} f_{X_1, X_2}(x_1, x_2) dx_2.$$

$$f_{X_3}(x_3) = \int_{\mathbb{R}^2} f_{X_1, X_2, X_3}(x_1, x_2, x_3) dx_1 dx_2.$$

$$f_{X_1, X_3}(x_1, x_3) = \int_{\mathbb{R}^2} f_{X_1, X_2, X_3, X_4}(x_1, x_2, x_3, x_4) dx_2 dx_4.$$

Función de masa de probabilidad

Vector aleatorio discreto

\mathbf{X} es un vector aleatorio discreto si $F_{\mathbf{X}}$ es constante por regiones y tiene un número finito o infinito numerable de discontinuidades. Su *función de masa de probabilidad*³ resulta:

$$p_{\mathbf{X}}(\mathbf{x}) = p_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = \mathbb{P}(\mathbf{X} = \mathbf{x}),$$

donde \mathbf{x} es uno de los puntos de discontinuidad de $F_{\mathbf{X}}$. Llamamos \mathcal{X} al conjunto que contiene a todos los puntos de discontinuidad de $F_{\mathbf{X}}$.

³PMF *Probability Mass Function*

Vectores aleatorios discretos y funciones de masa de probabilidad

\mathbf{X} es un VeA discreto. Su PMF, $p_{\mathbf{X}}(\mathbf{x})$, satisface las siguientes propiedades:

- $p_{\mathbf{X}}(\mathbf{x}) \geq 0, \forall \mathbf{x} \in \mathcal{X}.$
- $F_{\mathbf{X}}(\mathbf{x}) = \sum_{\mathbf{u} \in \mathcal{X}: \mathbf{u} \leq \mathbf{x}} p_{\mathbf{X}}(\mathbf{u}).$

Vectores aleatorios discretos y funciones de masa de probabilidad

- *Probabilidad de una región.*

$$\mathbb{P}(\mathbf{X} \in A) = \sum_{\mathbf{u} \in \mathcal{X} \cap A} p_{\mathbf{X}}(\mathbf{u}).$$

Nuevamente, $\sum_{\mathbf{x} \in \mathcal{X}} p_{\mathbf{X}}(\mathbf{x}) = \mathbb{P}(\mathbf{X} \in \mathbb{R}^n) = 1$.

- *Probabilidad de un punto.* Por definición

$$\mathbb{P}(\mathbf{X} = \mathbf{x}) = p_{\mathbf{X}}(\mathbf{x}), \quad \forall \mathbf{x} \in \mathcal{X}.$$

En este caso, $\mathbb{P}(\mathbf{X} = \mathbf{x})$ puede ser no nula.

Funciones de masa de probabilidad marginales

De forma análoga al caso continuo, podemos marginalizar la PMF conjunta para obtener las *PMFs marginales*. Por ejemplo:

$$p_{X_1}(x_1) = \sum_{x_2: (x_1, x_2) \in \mathcal{X}} p_{X_1, X_2}(x_1, x_2).$$

$$p_{X_3}(x_3) = \sum_{(x_1, x_2): (x_1, x_2, x_3) \in \mathcal{X}} p_{X_1, X_2, X_3}(x_1, x_2, x_3).$$

$$p_{X_1, X_3}(x_1, x_3) = \sum_{(x_2, x_4): (x_1, x_2, x_3, x_4) \in \mathcal{X}} p_{X_1, X_2, X_3, X_4}(x_1, x_2, x_3, x_4).$$

Función de densidad generalizada

En general, para no tener que diferenciar entre VeA continuo y discreto vamos a considerar una función de densidad generalizada

- Si \mathbf{X} está compuesto por VA continuas, entonces $f_{\mathbf{X}}$ sigue la definición vista.
- Si \mathbf{X} está compuesto por V.A discretas que toman valores en $\mathbf{x} = \xi_i, i = 1, 2, \dots$ entonces la función de densidad generalizada toma la siguiente forma

$$f_{\mathbf{X}}(\mathbf{x}) = \sum_i p_{\mathbf{X}}(\xi_i) \delta(\mathbf{x} - \xi_i)$$

Utilizando esta generalización, podemos trabajar las fórmulas en forma más genérica, sin tener que diferenciar entre la existencia de una función de densidad o no.

Condicionalidad

Distribuciones condicionales

Al analizar varias VA en forma conjunta es interesante introducir el concepto de condicionalidad. Para ello, definimos la CDF condicionada a un evento A que caracteriza el comportamiento de \mathbf{X} cuando sabemos que A ocurrió. Si $\mathbb{P}(A) > 0$, tenemos:

$$F_{\mathbf{X}|A}(\mathbf{x}) = \mathbb{P}(\mathbf{X} \leq \mathbf{x}|A) = \frac{\mathbb{P}(\mathbf{X} \leq \mathbf{x}, A)}{\mathbb{P}(A)}.$$

PDF condicional

Analizamos primero el caso de un VeA continuo. Para hacer el tratamiento más concreto tomamos $n = 3$. Queremos obtener

$$F_{X_2, X_3 | X_1=x_1}(x_2, x_3 | x_1).$$

Consideramos el evento $A = \{x_1 < X_1 \leq x_1 + \Delta\}$. Entonces,

$$\begin{aligned} F_{X_2, X_3 | A}(x_2, x_3 | A) &= \mathbb{P}(X_2 \leq x_2, X_3 \leq x_3 | x_1 < X_1 \leq x_1 + \Delta) \\ &= \frac{\mathbb{P}(X_2 \leq x_2, X_3 \leq x_3, x_1 < X_1 \leq x_1 + \Delta)}{\mathbb{P}(x_1 < X_1 \leq x_1 + \Delta)}. \end{aligned}$$

Hay que calcular:

$$\mathbb{P}(X_2 \leq x_2, X_3 \leq x_3, x_1 < X_1 \leq x_1 + \Delta) \text{ y } \mathbb{P}(x_1 < X_1 \leq x_1 + \Delta).$$

PDF condicional

$$\begin{aligned}\mathbb{P}(X_1 \in A, X_2 \leq x_2, X_3 \leq x_3) &= \int_{x_1}^{x_1 + \Delta} \int_{-\infty}^{x_2} \int_{-\infty}^{x_3} f_{X_1 X_2 X_3}(u, v, w) du dv dw \\ &= F_{X_1, X_2, X_3}(x_1 + \Delta, x_2, x_3) - F_{X_1, X_2, X_3}(x_1, x_2, x_3)\end{aligned}$$

y

$$\mathbb{P}(X_1 \in A) = \int_{u \in A} f_{X_1}(u) du = \int_{x_1}^{x_1 + \Delta} f_{X_1}(u) du = F_{X_1}(x_1 + \Delta) - F_{X_1}(x_1).$$

PDF condicional

Luego,

$$\begin{aligned} F_{X_2, X_3|A}(x_2, x_3|A) &= \frac{F_{X_1, X_2, X_3}(x_1 + \Delta, x_2, x_3) - F_{X_1, X_2, X_3}(x_1, x_2, x_3)}{F_{X_1}(x_1 + \Delta) - F_{X_1}(x_1)} \\ &= \frac{\frac{F_{X_1, X_2, X_3}(x_1 + \Delta, x_2, x_3) - F_{X_1, X_2, X_3}(x_1, x_2, x_3)}{\Delta}}{\frac{F_{X_1}(x_1 + \Delta) - F_{X_1}(x_1)}{\Delta}}. \end{aligned}$$

Usando límites, tenemos

$$\begin{aligned} F_{X_2, X_3|\{X_1=x_1\}}(x_2, x_3|x_1) &= \\ \lim_{\Delta \rightarrow 0} F_{X_2, X_3|\{x_1 \leq X_1 \leq x_1 + \Delta\}}(x_2, x_3|x_1 \leq X_1 \leq x_1 + \Delta) &= \frac{\frac{\partial F_{X_1, X_2, X_3}(x_1, x_2, x_3)}{\partial x_1}}{\frac{dF_{X_1}(x_1)}{dx_1}}. \end{aligned}$$

PDF condicional

Finalmente, la PDF condicional resulta

$$\begin{aligned}
 f_{X_2, X_3 | X_1 = x_1}(x_2, x_3 | x_1) &= \frac{\partial^2}{\partial x_2 \partial x_3} F_{X_2, X_3 | \{X_1 = x_1\}}(x_2, x_3 | x_1) \\
 &= \frac{\partial^2}{\partial x_2 \partial x_3} \frac{\frac{\partial F_{X_1, X_2, X_3}(x_1, x_2, x_3)}{\partial x_1}}{\frac{dF_{X_1}(x_1)}{dx_1}} \\
 &= \frac{\frac{\partial^3 F_{X_1, X_2, X_3}(x_1, x_2, x_3)}{\partial x_1 \partial x_2 \partial x_3}}{f_{X_1}(x_1)} = \frac{f_{X_1, X_2, X_3}(x_1, x_2, x_3)}{f_{X_1}(x_1)}.
 \end{aligned}$$

En forma general

PDF condicional

$$f_{\mathbf{X}|\mathbf{Y}}(\mathbf{x}, \mathbf{y}) = \frac{f_{\mathbf{X}, \mathbf{Y}}(\mathbf{x}, \mathbf{y})}{f_{\mathbf{Y}}(\mathbf{y})}$$

PMF condicional

Cuando \mathbf{X} es un VeA discreto es posible condicionar en un valor específico de una VA. Luego, la *PMF condicional* se define directamente a partir de la definición de probabilidad condicional. Por ejemplo:

$$p_{X_1, X_3 | X_2 = x_2}(x_1, x_3) = \frac{p_{X_1, X_2, X_3}(x_1, x_2, x_3)}{p_{X_2}(x_2)}.$$

$$p_{X_1 | X_2 = x_2, X_3 = x_3}(x_1) = \frac{p_{X_1, X_2, X_3}(x_1, x_2, x_3)}{p_{X_2, X_3}(x_2, x_3)}.$$

En este caso nuevamente,

PMF condicional

$$p_{\mathbf{X}|\mathbf{Y}}(\mathbf{x}, \mathbf{y}) = \frac{p_{\mathbf{X}, \mathbf{Y}}(\mathbf{x}, \mathbf{y})}{p_{\mathbf{Y}}(\mathbf{y})}$$

Notación

Vamos a utilizar la siguiente notación en forma equivalente para determinar condicionalidad en distribuciones, densidades, y funciones de masa de probabilidad:

$$F_{\mathbf{X}_1|\mathbf{X}_2=\mathbf{x}_2}(\mathbf{x}_1) = F_{\mathbf{X}_1}(\mathbf{x}_1|\mathbf{X}_2 = \mathbf{x}_2) = F(\mathbf{x}_1|\mathbf{x}_2)$$

$$f_{\mathbf{X}_1|\mathbf{X}_2=\mathbf{x}_2}(\mathbf{x}_1) = f_{\mathbf{X}_1}(\mathbf{x}_1|\mathbf{X}_2 = \mathbf{x}_2) = f(\mathbf{x}_1|\mathbf{x}_2)$$

$$p_{\mathbf{X}_1|\mathbf{X}_2=\mathbf{x}_2}(\mathbf{x}_1) = p_{\mathbf{X}_1}(\mathbf{x}_1|\mathbf{X}_2 = \mathbf{x}_2) = p(\mathbf{x}_1|\mathbf{x}_2)$$

Regla de la cadena

Podemos hallar la PDF y la PMF conjuntas a partir de las condicionadas. Por ejemplo:

$$\begin{aligned}
 f_{X_1, X_2, X_3}(x_1, x_2, x_3) &= \\
 &= f_{X_1}(x_1)f_{X_2, X_3}(x_2, x_3 | X_1 = x_1) = f_{X_1}(x_1)f_{X_2}(x_2)f_{X_3}(x_3 | X_1 = x_1, X_2 = x_2) \\
 &= f_{X_3}(x_3)f_{X_1, X_2}(x_1, x_2 | X_3 = x_3) = f_{X_3}(x_3)f_{X_2}(x_2)f_{X_1}(x_1 | X_2 = x_2, X_3 = x_3) \\
 &= f_{X_2}(x_2)f_{X_1, X_3}(x_1, x_3 | X_2 = x_2) = f_{X_2}(x_2)f_{X_3}(x_3)f_{X_1}(x_1 | X_2 = x_2, X_3 = x_3)
 \end{aligned}$$

En forma similar, tenemos las PMF conjunta de 3 VAD:

$$\begin{aligned}
 p_{X_1, X_2, X_3}(x_1, x_2, x_3) &= \\
 &= p_{X_1}(x_1)p_{X_2, X_3}(x_2, x_3 | X_1 = x_1) = p_{X_1}(x_1)f_{X_2}(x_2)p_{X_3}(x_3 | X_1 = x_1, X_2 = x_2) \\
 &= p_{X_3}(x_3)p_{X_1, X_2}(x_1, x_2 | X_3 = x_3) = p_{X_3}(x_3)p_{X_2}(x_2)p_{X_1}(x_1 | X_2 = x_2, X_3 = x_3) \\
 &= p_{X_2}(x_2)p_{X_1, X_3}(x_1, x_3 | X_2 = x_2) = p_{X_2}(x_2)p_{X_3}(x_3)p_{X_1}(x_1 | X_2 = x_2, X_3 = x_3)
 \end{aligned}$$

Independencia entre VA

Independencia entre variables aleatorias

Dos VA X e Y son *independientes* si

$$F_{X,Y}(x,y) = \mathbb{P}(X \leq x, Y \leq y) = \mathbb{P}(X \leq x)\mathbb{P}(Y \leq y) = F_X(x)F_Y(y).$$

- Si X, Y son VA discretas, la condición es equivalente a

$$p_{X,Y}(x,y) = p_X(x)p_Y(y).$$

- Si X, Y son VA continuas la condición es equivalente a

$$f_{X,Y}(x,y) = f_X(x)f_Y(y).$$

Independencia entre vectores aleatorias

- Las componentes de un vector aleatorio \mathbf{X} son mutuamente independientes si

$$F_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^n F_{X_i}(x_i).$$

- Dos VeAs $\mathbf{X} \in \mathbb{R}^n$ e $\mathbf{Y} \in \mathbb{R}^m$ son independientes si

$$F_{\mathbf{X}, \mathbf{Y}}(\mathbf{x}, \mathbf{y}) = F_{\mathbf{X}}(\mathbf{x})F_{\mathbf{Y}}(\mathbf{y}).$$

Ejercicios

Ejercicio

Sea $Y = X + N$, con X y N variables aleatorias independientes.

- ① Demostrar que $f_{Y|X}(y|x) = f_N(y - x)$.
- ② Si $X \in \{0, 1\}$ es una variable aleatoria Bernoulli con $\mathbb{P}(X = 0) = p$ y $\mathbb{P}(X = 1) = q = 1 - p$, expresar y representar $f_Y(y)$ y $f_{Y|X}(y|x)$.

Ejercicio

Sea $\mathbf{X} = [X_1, X_2]$ un vector aleatorio continuo. Si $f_{\mathbf{X}}(\mathbf{x})$ fuera conocida, cómo haría para calcular las siguientes probabilidades?

- $\mathbb{P}(X_1 - X_2 \leq 2)$
- $\mathbb{P}(\max(X_1, X_2) \leq -1)$
- $\mathbb{P}(\min(|X_1|, |X_2|) \geq 2)$
- $\mathbb{P}(X_1 X_2 \geq 0)$

Ejercicio

Sean X , Y , y Z V.A independientes. Hallar las siguientes probabilidades en función de $F_X(x)$, $F_Y(y)$, $F_Z(z)$

- $\mathbb{P}(|X| \leq 5, Y > 3, Z^2 \leq 2)$
- $\mathbb{P}(\max(X, Y, Z) \leq -1)$

Ejercicio

Sea $\mathbf{X} = [X_1, X_2]$ un vector aleatorio continuo cuya PDF es

$$F_{\mathbf{X}}(x_1, x_2) = k(x_1 + x_2) \quad 0 < x_1 < 1 \quad 0 < x_2 < 1$$

- Hallar k
- Hallar $F_{\mathbf{X}}$
- Hallar $f_{X_1}(x_1)$ y $f_{X_2}(x_2)$.

Esperanza

Lo último q' se pierde

El operador esperanza

Sea $\mathbf{X} \in \mathbb{R}^n$ un vector aleatorio n -dimensional. La media o esperanza de \mathbf{X} es vector de las esperanzas de sus componentes:

$$\mathbb{E}[\mathbf{X}] = \mu_{\mathbf{X}} = \begin{bmatrix} \mathbb{E}[X_1] \\ \vdots \\ \mathbb{E}[X_n] \end{bmatrix}.$$

El vector de esperanzas es un vector con cada una de sus esperanzas

Demostración

$$\mathbb{E}[\mathbf{X}] = \int_{-\infty}^{\infty} \mathbf{x} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = \underbrace{\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty}}_n \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} f_{x_1 \dots x_n}(x_1, \dots, x_n) dx_1 \cdots dx_n$$

Marginalizar, me saco de encima todos los que integro (i.e. todos menos x_1)

vector de integrantes

$$\begin{aligned}
 &= \begin{bmatrix} \int_{-\infty}^{\infty} x_1 dx_1 \left[\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_{x_1 \dots x_n}(x_1, x_2 \dots, x_n) dx_2 \cdots dx_n \right] \\ \vdots \\ \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_{x_1 \dots x_n}(x_1, \dots, x_{n-1}, x_n) dx_1 \cdots dx_{n-1} \int_{-\infty}^{\infty} x_n dx_n \end{bmatrix} \\
 &= \begin{bmatrix} \int_{-\infty}^{\infty} x_1 f_{x_1}(x_1) dx_1 \\ \vdots \\ \int_{-\infty}^{\infty} x_n f_{x_n}(x_n) dx_n \end{bmatrix} \\
 &= \begin{bmatrix} \mathbb{E}[X_1] \\ \vdots \\ \mathbb{E}[X_n] \end{bmatrix}
 \end{aligned}$$

Todo esto para mostrar que lo de arriba NO es una definición, sino una deducción

→ Pero we

Chirardo, pero el resultado es fácil

El operador esperanza: Propiedades

→ Esto pretende ser un Corazón

- El operador $\mathbb{E}[\cdot]$ es lineal, luego $\forall \mathbf{A} \in \mathbb{R}^{m \times n}$ y $\forall \mathbf{b} \in \mathbb{R}^m$ tenemos:

$$\mathbb{E}[\mathbf{AX} + \mathbf{b}] = \mathbf{A}\mathbb{E}[\mathbf{X}] + \mathbf{b}.$$

- En forma general, si \mathbf{g} es una función $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^m$, tenemos

Donde $\vec{g}(\vec{x}) = \begin{pmatrix} g_1(\vec{x}) \\ g_2(\vec{x}) \\ \vdots \\ g_m(\vec{x}) \end{pmatrix}$

$$\mathbb{E}[\mathbf{g}(\mathbf{X})] = \begin{bmatrix} \mathbb{E}[g_1(\mathbf{X})] \\ \vdots \\ \mathbb{E}[g_m(\mathbf{X})] \end{bmatrix}.$$

La esperanza condicional

Sea un evento A . Luego, definimos el operador $\mathbb{E}[\cdot|A]$

$$\mathbb{E}[\mathbf{X}|A] = \int_{\mathbb{R}^n} \mathbf{x} f_{\mathbf{X}|A}(\mathbf{x}|A) d\mathbf{x}.$$

Propiedades de la esperanza condicional

- Esperanza condicional de una constante. $\mathbb{E}[a|\mathbf{X} = \mathbf{x}] = a$.
- Linealidad. $\mathbb{E}[a\mathbf{Y} + b\mathbf{Z}|\mathbf{X} = \mathbf{x}] = a\mathbb{E}[\mathbf{Y}|\mathbf{X} = \mathbf{x}] + b\mathbb{E}[\mathbf{Z}|\mathbf{X} = \mathbf{x}]$.

- Esperanza condicional de una función.

$$\mathbb{E}[g(\mathbf{X})h(\mathbf{Y})|\mathbf{X} = \mathbf{x}] = g(\underline{\mathbf{x}})\mathbb{E}[h(\mathbf{Y})|\mathbf{X} = \mathbf{x}]$$

Si: \vec{X} es fija ($\vec{X} = \vec{x}$)
 , $g(\vec{x})$ vale como
 constante ($g(\vec{x})$)

- Redundancia en condiciones.

$$\mathbb{E}[\mathbf{Y}|\mathbf{X} = \mathbf{x}, g(\mathbf{X}) = g(\mathbf{x})] = \mathbb{E}[\mathbf{Y}|\mathbf{X} = \mathbf{x}]$$

\downarrow Significan lo mismo, redundante

Ley de la esperanza total I

→ *Sumamente importante*

$$\mathbf{X}_1 \in \mathbb{R}^n, \mathbf{X}_2 \in \mathbb{R}^m$$

A.K.A. "Ley de suavización", por si eso te dice algo

$$\mathbb{E}[\mathbf{X}_2] = \mathbb{E}[\mathbb{E}[\mathbf{X}_2 | \mathbf{X}_1]] \quad \text{y} \quad \mathbb{E}[\mathbf{X}_1] = \mathbb{E}[\mathbb{E}[\mathbf{X}_1 | \mathbf{X}_2]]$$

Demostración:

¿?

- Consideramos evento $A = \{\mathbf{X}_1 = \mathbf{x}_1\}$

También es un
vector

$$\mathbb{E}[\mathbf{X}_2 | A] = \int \mathbf{x}_2 f_{\mathbf{X}_2 | \mathbf{X}_1}(\mathbf{x}_2 | \mathbf{X}_1 = \mathbf{x}_1) d\mathbf{x}_2 = g(\mathbf{x}_1).$$

- $g(\mathbf{x}_1)$ es una función de \mathbf{x}_1 . Si consideramos todas sus posibles realizaciones, $g(\mathbf{X}_1)$ es un VeA de m componentes como \mathbf{X}_2 .

Ley de la esperanza total II

- Calculando la esperanza de $g(\mathbf{X}_1) = \int \mathbf{x}_2 f_{\mathbf{X}_2|\mathbf{X}_1}(\mathbf{x}_2|\mathbf{X}_1 = \mathbf{x}_1) d\mathbf{x}_2$,

$$\begin{aligned} \mathbb{E}[g(\mathbf{X}_1)] &= \mathbb{E}\left[\mathbb{E}[\mathbf{X}_2|\mathbf{X}_1]\right] = \int_{\mathbb{R}} g(\mathbf{x}_1) f_{\mathbf{X}_1}(\mathbf{x}_1) d\mathbf{x}_1 = \\ &= \boxed{\int_{\mathbb{R}} \int_{\mathbb{R}} \mathbf{x}_2 \underbrace{f_{\mathbf{X}_2|\mathbf{X}_1}(\mathbf{x}_2|\mathbf{X}_1)}_{f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2)} d\mathbf{x}_2 f_{\mathbf{X}_1}(\mathbf{x}_1) d\mathbf{x}_1} = \\ &= \int_{\mathbb{R}} \mathbf{x}_2 \underbrace{\int_{\mathbb{R}} f_{\mathbf{X}_1, \mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) d\mathbf{x}_1}_{f_{\mathbf{X}_2}(\mathbf{x}_2)} d\mathbf{x}_2 = \mathbb{E}[\mathbf{X}_2] \end{aligned}$$

randomigo → Técnica interesante para demostrar cosas q implican condicionalidad

De todos modos, parece medio contradictorio. Imponer una condición es asumir que X_1 tomó un valor, pero después digo " X_1 puede tomar cualquier valor". Flojo de papeles?

$$\therefore \mathbb{E}[\vec{g}(\vec{X}_1)] = \mathbb{E}[E[\vec{x}_2|\vec{x}_1]] = E[\vec{x}_2]$$

Más allá de la demostración
④ { ¿Qué significa esto? }

Esperanza condicional de VA independientes

$$\text{Dada una realización de } X_1, X_2 \text{ tiene cierta esperanza, } E[X_2 | X_1 = x_1]. \text{ Si desconozco ese valor de } X_1, \text{ la esperanza de } X_2 \text{ no cambia.}$$

Si no sé cuánto valió \tilde{x}_1 , la esperanza de X_2 no cambia → y sí, analítico
Lo estoy entendiendo bien? Consultar? ¿ x_1 es tan importante en el teorema?

Si \mathbf{X} y \mathbf{Y} son independientes, entonces $E[\mathbf{X}|\mathbf{Y}] = E[\mathbf{X}]$.

¿Qué es la esperanza? ¿El valor más probable? => NO!

Es el valor esperado. ¿Y qué cuénta eso?

Es una suma de todos los posibles valores de mi variable ponderados por su probabilidad → $E[X] = \sum_{\forall x} p(x) \cdot x$

De alguna manera, la esperanza representa un centro de masa en el gráfico de $p(x)$.


Esta propiedad es una consecuencia directa de

$$f_{\mathbf{X}, \mathbf{Y}}(\mathbf{x}, \mathbf{y}) = f_{\mathbf{X}}(\mathbf{x})f_{\mathbf{Y}}(\mathbf{y}) \iff \mathbf{X}, \mathbf{Y} \text{ independientes}$$

Con esta interpretación, el teorema sería: "El C de M de la variable aleatoria $g(X_1)$ es el mismo que el de la variable aleatoria X_2 "

¿Tiene sentido hablar de C de M de una V.A. que es un vector? => Sí, es la posición promedio de la función de distribución de ese vector, que puede ser una función de R a R. Además, decir C de M y posición promedio es lo mismo.

Entonces, el teorema sería: "Dada una realización de X_1 , la posición promedio de X_2 cambia. Si yo no sé cuál es el valor de X_1 , ¿cuál es la posición promedio de la posición promedio de X_2 ? => Resulta que es exactamente igual a la posición promedio de X_2 !!!! Ahora el teorema no es tan obvio."



31/3 => Además, puede que no conozca la distribución de X_2 , pero si conozca la distribución de $X_2 | X_1 = x_1$

Sumar una dimensión al problema ayuda a visualizar, aunque tal vez no sea tan difícil verlo el R1.

Ver más allá del resultado

Si voy a hacer esto por cada teorema me quedo peladísimo

Repasso varianza y correlación

Si X es una V.A de media es μ_X , su varianza está definida como

$$\mathbb{V}[X] = \sigma_X^2 = \mathbb{E}[(X - \mu_X)^2].$$

Tenemos que

$$\mathbb{V}[X] = \mathbb{E}[X^2] - \mu_X^2.$$

Centro la variable,
 Quiero ver cómo se
 comporta alrededor de la
 media

Cuadrado del binomio

Momentos cruzados entre variables aleatorias

Sean X e Y dos V.A. con $\mathbb{E}[X] = \mu_X$ y $\mathbb{E}[Y] = \mu_Y$.

- Momento cruzado central o *covarianza cruzada*

Multiplico ambas variables

$$C_{X,Y} = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)]$$

- Momento cruzado o *correlación cruzada* (*sin centrar*) el video

$$R_{X,Y} = \mathbb{E}[XY]$$

Tenemos que

$$C_{X,Y} = R_{X,Y} - \mu_X \mu_Y \rightarrow \begin{array}{l} \text{desarrollar el} \\ \text{producto} \end{array}$$

Matriz de covarianza

Sea $\mathbf{X} \in \mathbb{R}^n$ un VeA. La **Matriz de Covarianza** de \mathbf{X} es

$$\mathbf{Cov}(\mathbf{X}) = C_{\mathbf{X}} = \mathbb{E}[\underbrace{(\mathbf{X} - \mu_{\mathbf{X}})(\mathbf{X} - \mu_{\mathbf{X}})^t}_{\in \mathbb{R}^{n \times n}}]$$

La esperanza de la matriz es la matriz de las esperanzas

donde

$$\mathbf{X} - \mu_{\mathbf{X}} = \begin{bmatrix} X_1 - \mu_{X_1} \\ \vdots \\ X_n - \mu_{X_n} \end{bmatrix} \begin{bmatrix} x_1 - \mu_{x_1} \\ x_2 - \mu_{x_2} \\ \vdots \\ x_m - \mu_{x_m} \end{bmatrix} \cdot [x_1, x_2, \dots]$$

$$(\vec{\mathbf{X}} - \vec{\mu}_{\vec{\mathbf{X}}}) \cdot (\vec{\mathbf{X}} - \vec{\mu}_{\vec{\mathbf{X}}})^t \in \mathbb{R}^{n \times n}$$

Armado de la matriz de covarianza

$$\begin{aligned}
 C_X &= \mathbb{E} \left\{ \begin{bmatrix} X_1 - \mu_{X_1} \\ \vdots \\ X_n - \mu_{X_n} \end{bmatrix} \begin{bmatrix} X_1 - \mu_{X_1} & \cdots & X_n - \mu_{X_n} \end{bmatrix} \right\} \\
 \text{Hoy q'queremos} \\
 \text{a esta} \\
 \text{matriz} &= \mathbb{E} \left\{ \begin{bmatrix} (X_1 - \mu_{X_1})^2 & \cdots & (X_1 - \mu_{X_1})(X_n - \mu_{X_n}) \\ \ddots & \ddots & \ddots \\ (X_n - \mu_{X_n})(X_1 - \mu_{X_1}) & \cdots & (X_n - \mu_{X_n})^2 \end{bmatrix} \right\} \\
 &= \begin{bmatrix} \underbrace{\mathbb{E}[(X_1 - \mu_{X_1})^2]}_{\mathbb{V}[X_1]} & \cdots & \underbrace{\mathbb{E}[(X_1 - \mu_{X_1})(X_n - \mu_{X_n})]}_{Cov[X_1, X_n]} \\ \ddots & \ddots & \ddots \\ Cov[X_n, X_1] & \cdots & \underbrace{\mathbb{V}[X_n]}_{\text{Varianza en la diagonal principal}} \end{bmatrix} \\
 &\quad \text{Covarianza cruzada} \qquad \text{Covarianza cruzada} \qquad \text{Varianzas en la diagonal principal}
 \end{aligned}$$

Construcción de C_X :

- Diagonal principal: $\mathbb{V}[X_1], \dots, \mathbb{V}[X_n]$
- Término (i, j) : $Cov[X_i, X_j]$

Matriz de correlación

Como la Covarianza, pero sin centros

Sea $\mathbf{X} \in \mathbb{R}^n$ un VeA. La **Matriz de correlación** de \mathbf{X} es:

Si la media del Ve.A. es cero, la matriz de correlación y la de covarianza es la misma

$$R_{\mathbf{X}} = \mathbb{E}[\mathbf{X}\mathbf{X}^t] \xrightarrow{\text{Como la matriz de Covarianzas, pero sin centros}}$$

Considerando la PDF generalizada $f_{\mathbf{X}}$ para incluir tanto el caso continuo como el discreto, tenemos:

$$R_{\mathbf{X}} = \int_{\mathbb{R}^n} \mathbf{x}\mathbf{x}^t f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = \begin{bmatrix} \mathbb{E}[X_1^2] & \mathbb{E}[X_1 X_2] & \cdots & \mathbb{E}[X_1 X_n] \\ \mathbb{E}[X_2 X_1] & \mathbb{E}[X_2^2] & \cdots & \mathbb{E}[X_2 X_n] \\ \vdots & \vdots & \ddots & \vdots \\ \mathbb{E}[X_n X_1] & \mathbb{E}[X_n X_2] & \cdots & \mathbb{E}[X_n^2] \end{bmatrix}.$$

Propiedades de C_X y R_X

- Matrices cuadradas, $R_X, C_X \in \mathbb{R}^{n \times n}$

- Matrices simétricas: $R_X = R_X^t, C_X = C_X^t$

- $\mathbb{E}[X_i X_j] = \mathbb{E}[X_j X_i]$ y en forma similar, $Cov_{X_i X_j} = Cov_{X_j X_i}$

- Elemento $(i, j) =$ elemento (j, i) .

Nos gustan las simetrías no?

Propiedades de C_x y R_x

- Relación entre C_x y R_x

{formas cuadráticas?}

$$C_x = \mathbb{E} \left[(\mathbf{X} - \mu_{\mathbf{X}}) (\mathbf{X} - \mu_{\mathbf{X}})^t \right]$$

$$= \mathbb{E}[\mathbf{X}\mathbf{X}^t - \mathbf{X}\mu_{\mathbf{X}}^t - \mu_{\mathbf{X}}\mathbf{X}^t + \mu_{\mathbf{X}}\mu_{\mathbf{X}}^t] = R_x - \mu_{\mathbf{X}}\mu_{\mathbf{X}}^t.$$

$$C_x = R_x - \mu_{\mathbf{X}}\mu_{\mathbf{X}}^t. \text{ Do U}$$

- Matrices semidefinidas positivas:

donde $f(\cdot)$ es una función lineal de $\mathbb{R}^m \rightarrow \mathbb{R}^m$

$$\forall \mathbf{a} \in \mathbb{R}^n : \mathbf{a}^t (R_x \mathbf{a}) \geq 0 \quad \text{y} \quad \mathbf{a}^t C_x \mathbf{a} \geq 0.$$

$\xleftarrow{\mathbf{a}^t f(\mathbf{a})}$ $\xrightarrow{\mathbf{a}^t \cdot \mathbf{a}}$ \rightarrow producto interno
 ¿cuádricas?

Muy
IMPORTANTE

Si yo tomo la imagen de \mathbf{a} a través de R_x y le hago el P.I. con \mathbf{a} , el resultado es mayor a cero, el ángulo entre \mathbf{a} y $R_x \mathbf{a}$ no es mayor a 90° . Ponele. ¿Qué cuernos es un angulo entre 0 y 90° en 7 dimensiones??? ¿Qué significa esta propiedad?

$C_x \geq 0$ y $R_x \geq 0$: Demostración

- Armamos una nueva V.A. Y combinando linealmente las componentes de \mathbf{X} .
- $Y = \sum_{i=1}^n a_i X_i = \mathbf{a}^t \mathbf{X}$, donde $\mathbf{a} \in \mathbb{R}^n$ es un vector determinístico.
- Claramente $0 \leq \mathbb{E}[Y^2]$ para cualquier valor de \mathbf{a} . Por otro lado,

$\mathbb{E}[Y^2] = \mathbb{E}[\mathbf{a}^t \mathbf{X} \mathbf{X}^t \mathbf{a}] = \mathbf{a}^t \mathbf{R}_x \mathbf{a} \geq 0 \rightarrow \text{VANANA}$



 Xq un real al cuadrado siempre es mayor a cero. ¿Y los complejos? ¿Será por eso lo de "semi" definida?

- Haciendo el mismo razonamiento con $Z = \sum_{i=1}^n a_i (X_i - \mu_i) = \mathbf{a}^t (\mathbf{X} - \boldsymbol{\mu}_x)$ obtenemos

$$\mathbb{E}[Z^2] = \mathbf{a}^t \mathbf{C}_x \mathbf{a} \geq 0.$$

- Ambas desigualdades se cumplen para cualquier $\mathbf{a} \in \mathbb{R}^n$, por ende $\mathbf{R}_x \geq 0$ y $\mathbf{C}_x \geq 0$.

Cine, CINEMA
 PARADISO

Propiedades de R_X y C_X

Delta del hijo de remil puta de Kronecker

$$\mathbb{E}[x_i^2]$$



- Si R_X es una matriz diagonal, $\mathbb{E}[X_i X_j] = \delta_{i,j}$, y decimos que las componentes de \mathbf{X} son **ortogonales** de a dos.
- Si C_X es una matriz diagonal, $C_{X_i X_j} = \delta_{i,j} \mathbb{V}[X_i]$, decimos que las componentes de \mathbf{X} están **descorrelacionadas** de a dos.

"Definiciones sueltas" → Es decir, ¿Qué queremos significar esto?
 Pensar. ¿Quién definió esto así? ¿Cuándo? ¿Por qué, con qué fin?

Propiedades de C_X : VeA degenerado

Qué sucede si C_X es una matriz singular?

- Recordemos que cuando una V.A X tiene varianza nula

$$\sigma_X^2 = 0 \iff \mathbb{P}[X = \mu_X] = 1 \rightarrow \text{i.e. no hay dispersión}$$

La V.A se comporta como una constante igual a su media.

- Para el caso n -dimensional tenemos el siguiente resultado:

Teorema

Sea \mathbf{X} un VeA. Su matriz de covarianza C_X es singular si y solo si existe un vector $\mathbf{v} \neq \mathbf{0}$ tal que

$$\mathbb{P}[\mathbf{v}^t(\mathbf{X} - \mu_{\mathbf{X}}) = 0] = 1.$$


P.I: $\langle \mathbf{v}, \mathbf{X} - \mu_{\mathbf{X}} \rangle$ → q' tiene determinante cero
y q' no tiene inversa
(o q' tiene un A.V. nulo)

Esto significa: Todas las observaciones de \mathbf{X} centradas en la media $\mu_{\mathbf{X}}$ van a ser ortogonales a \mathbf{v} . Mi VeA. solo se da en una dirección. Loco, no?

En este caso decimos que \mathbf{X} es un VeA *degenerado*.

Propiedades de C_x : VeA degenerado

- Un modo de interpretar este resultado es ver que si \mathbf{X} es un VeA degenerado, entonces existe una dirección fija (\mathbf{v}) que va a ser ortogonal a todas las realizaciones ($\mathbf{x} - \mu_{\mathbf{X}}$). Es decir que con probabilidad 1 NO vamos a observar realizaciones de \mathbf{X} que se encuentren en el espacio generado por \mathbf{v} desplazado en $\mu_{\mathbf{X}}$.
- Es decir, hay componentes del VeA redundantes que se pueden determinar a partir de las demás componentes.



No hay realizaciones en dirección \mathbf{p}_2 . Si se proyecta \mathbf{X} sobre \mathbf{p}_1 , se describe el experimento con una sola VA, $Z = \mathbf{X}^t \mathbf{p}_1$

Los aleatorios no son las dos componentes de \mathbf{X} , si no que lo aleatorio es r , un escalar, donde: $\vec{X} = \mathbf{f} + \vec{p}_1 r$ → Es decir, me puedo ahorrar una dimensión!!!

VeA degenerados: demostración del teorema

- *Prueba ida.* C_X singular entonces $\exists \mathbf{v} \neq \mathbf{0}: \mathbb{P}(\mathbf{v}^t(\mathbf{X} - \mu_X) = 0) = 1$.
 C_X singular implica que C_X existe $\mathbf{v} \neq \mathbf{0}$ tal que $C_X \mathbf{v} = \mathbf{0}$.
Entonces $\mathbf{v}^t C_X \mathbf{v} = 0$. Ahora definimos $Y = \mathbf{v}^t(\mathbf{X} - \mu_X)$. Para cualquier $a > 0$, la cota de Markov establece que

Y entero complejo $\forall a \in \mathbb{R}$ $\leftarrow \mathbb{P}(Y^2 \geq a) \leq \frac{\mathbb{E}[Y^2]}{a} = \frac{\mathbf{v}^t C_X \mathbf{v}}{a} = 0$, $\overset{\text{Porque } a \text{ dia } 55}{\underset{Y \in \mathbb{R}}{\rightarrow}}$

$\left\{ \begin{array}{l} Y \text{ nula} \Rightarrow ? \\ \text{Qué dice Markov?} \end{array} \right. \left\{ \begin{array}{l} \text{Soy un hincha pelotaz?} \\ \text{?} \end{array} \right.$

Luego, $\mathbb{P}(Y^2 = 0) = 1$, y por ende, $\mathbb{P}(\mathbf{v}^t(\mathbf{X} - \mu_X) = 0) = 1$.

- *Prueba vuelta.* $\exists \mathbf{v} \neq \mathbf{0}: \mathbb{P}(\mathbf{v}^t(\mathbf{X} - \mu_X) = 0) = 1$ luego, C_X es singular.

$Y = \mathbf{v}^t(\mathbf{X} - \mu_X) \in \mathbb{R}$ es una V.A. de media nula. Vimos que si $\mathbb{P}[Y = 0] = 1$ implica que su varianza es nula, es decir

$$\sigma_Y^2 = \mathbb{E}[Y^2] = \mathbf{v}^t C_X \mathbf{v} = 0.$$

Esto implica que C_X es singular.



Transformación afín de \mathbf{X}

Sea \mathbf{X} un VeA con covarianza $C_{\mathbf{X}}$. Consideramos una transformación afín formada a partir de la matriz $A \in \mathbb{R}^{m \times n}$ y el vector $\mathbf{b} \in \mathbb{R}^m$,

\hookrightarrow No lineal

$$\mathbf{Y} = A\mathbf{X} + \mathbf{b}.$$

Entonces

$$\mathbb{E}[\mathbf{Y}] = \mathbb{E}[A\mathbf{X} + \mathbf{b}] = A\mathbb{E}[\mathbf{X}] + \mathbf{b}$$

$$\begin{aligned}
 \text{Cov}(\mathbf{Y}) &= \mathbb{E} \{ [\mathbf{Y} - \mathbb{E}[\mathbf{Y}]] [\mathbf{Y} - \mathbb{E}[\mathbf{Y}]]^t \} \\
 &= \mathbb{E} \{ [A\mathbf{X} + \cancel{\mathbf{b}} - A\mathbb{E}[\mathbf{X}] - \cancel{\mathbf{b}}] [A\mathbf{X} + \cancel{\mathbf{b}} - A\mathbb{E}[\mathbf{X}] - \cancel{\mathbf{b}}]^t \} \\
 &= \mathbb{E} \left\{ [A(\mathbf{X} - \mathbb{E}[\mathbf{X}])] [\cancel{A}(\mathbf{X} - \mathbb{E}[\mathbf{X}])]^t \right\} \\
 &= \mathbb{E} \left\{ [A(\mathbf{X} - \mathbb{E}[\mathbf{X}])] [(\mathbf{X} - \mathbb{E}[\mathbf{X}])]^t A^t \right\} \\
 &= A \mathbb{E} \{ [\mathbf{X} - \mathbb{E}[\mathbf{X}]] [\mathbf{X} - \mathbb{E}[\mathbf{X}]]^t \} A^t = A C_{\mathbf{X}} A^t
 \end{aligned}$$

Muy conveniente
 para el
 desarrollo de
 la trama

Transformación afín (recap importante!)

$$\mathbf{Y} = A\mathbf{X} + \mathbf{b}$$

$$\mathbb{E}[\mathbf{Y}] = \mu_{\mathbf{Y}} = A\mathbb{E}[\mathbf{X}] + \mathbf{b}$$

$$\text{Cov}(\mathbf{Y}) = C_{\mathbf{Y}} = AC_{\mathbf{X}}A^t$$

Observaciones:

- \mathbf{b} desplaza la media
- \mathbf{b} no afecta $C_{\mathbf{Y}}$ pero SI afecta $R_{\mathbf{Y}}$



Xq la $C_{\mathbf{X}}$ se centra en la media.
Trabaja al rededor de la media

Relación entre correlación e independencia

- X e Y están *descorrelacionadas* si y sólo si $C_{X,Y} = 0$. En este caso, $R_{X,Y} = \mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$.
- X e Y son *ortogonales* si y sólo si $R_{X,Y} = 0$. En este caso, $C_{X,Y} = -\mathbb{E}[X]\mathbb{E}[Y]$.
- X e Y son independientes si y sólo si $f_{X,Y}(x,y) = f_X(x)f_Y(y)$
- X, Y independientes $\implies X, Y$ descorrelacionadas.
- X, Y independientes $\not\implies X, Y$ descorrelacionadas.

Que la covarianza sea nula NO implica que las variables sean independientes. Como serían dos variables dependientes y con covarianza distinta de cero?

Desigualdad de Cauchy-Schwarz

Sean X e Y dos VA. Luego,

¿Normas? ¿Ángulos? ¿Distancia?
 ¿Cuál es la norma de una V.A?
 ¿Cuál es la base de todos los
 VA?
 ¿Tienen sentido estas
 preguntas?

$$\mathbb{E}^2[XY] \leq \mathbb{E}[X^2]\mathbb{E}[Y^2]$$

Esta expresión es la *desigualdad de Cauchy-Schwarz*. Una formulación equivalente considera los momentos centrados, resultando

$$C_{X,Y}^2 \leq \sigma_X^2 \sigma_Y^2.$$

20/3 → Hasta acá llegó el amor

31/03 → ARRANCAMOS

Transformaciones de vectores aleatorios

Transformaciones de vectores aleatorios

Sea \mathbf{X}, \mathbf{Y} dos VeAs tal que $\mathbf{Y} = \mathbf{g}(\mathbf{X})$ donde

$$\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^m.$$

La función de distribución de \mathbf{Y} es

$$F_{\mathbf{Y}}(\mathbf{y}) = \mathbb{P}(\mathbf{Y} \leq \mathbf{y}) = \mathbb{P}(\mathbf{g}(\mathbf{X}) \leq \mathbf{y}) = \int_{R_y} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x},$$


EVENTO EQUIVALENTE

donde $\underbrace{R_y}_{=} = \{\mathbf{x} : \mathbf{g}(\mathbf{x}) \leq \mathbf{y}\}$. Podemos obtener la función de densidad de \mathbf{Y} (posiblemente generalizada) como

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{\partial^m F_{\mathbf{Y}}(\mathbf{y})}{\partial y_1 \dots \partial y_m}.$$

Transformación biyectiva y suave

- Supongamos $n = m$ y $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ una función inversible
- Luego, $\mathbf{g}(\mathbf{x}) = \mathbf{y}$ tiene una única solución.
- Sea $E(\mathbf{x}_0)$ un entorno alrededor de \mathbf{x}_0 y $F(\mathbf{x}_0) = \{\mathbf{g}(\mathbf{x}) : \mathbf{x} \in E(\mathbf{x}_0)\}$ el entorno alrededor de $\mathbf{g}(\mathbf{x}_0)$.
- Para satisfacer la equivalencia de eventos, planteamos:



Transformación biyectiva y suave

- Considerando un cambio de variable en la integral, obtenemos la siguiente relación entre las PDFs conjuntas:

$$f_Y(\mathbf{y}) = \frac{f_X(\mathbf{g}^{-1}(\mathbf{y}))}{|\det(J(\mathbf{g}^{-1}(\mathbf{y})))|},$$

donde J es el Jacobiano de la transformación dado por

$\mathbf{y}_i \neq \frac{\partial \mathbf{y}}{\partial \mathbf{x}}$?

De qué me

disfrazo?

→ No rompas las pelotas

$$J(\mathbf{x}) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1}(\mathbf{x}) & \dots & \frac{\partial g_1}{\partial x_n}(\mathbf{x}) \\ \vdots & \vdots & \vdots \\ \frac{\partial g_n}{\partial x_1}(\mathbf{x}) & \dots & \frac{\partial g_n}{\partial x_n}(\mathbf{x}) \end{bmatrix}.$$

Transformación general suave

- Si $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ es una función suave pero no inversible, dado un \mathbf{y} la ecuación $\mathbf{g}(\mathbf{x}) = \mathbf{y}$ tiene en general varias soluciones $\mathbf{x}_1, \dots, \mathbf{x}_k$. ~~lo de antes~~
- En este caso, hay que sumar las contribuciones de cada una de las soluciones. Luego,

$$f_{\mathbf{Y}}(\mathbf{y}) = \sum_{i=1}^k \frac{f_{\mathbf{X}}(\mathbf{x}_i)}{|\det(J(\mathbf{x}_i))|},$$

donde $J(\mathbf{x}_i)$ es el Jacobiano de la transformación dado por

$$J(\mathbf{x}_i) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1}(\mathbf{x}_i) & \dots & \frac{\partial g_1}{\partial x_n}(\mathbf{x}_i) \\ \vdots & \vdots & \vdots \\ \frac{\partial g_n}{\partial x_1}(\mathbf{x}_i) & \dots & \frac{\partial g_n}{\partial x_n}(\mathbf{x}_i) \end{bmatrix}.$$

Ejemplo: Magnitud y ángulo de vector aleatorio I

- Sea $\mathbf{X} = [X_1, X_2]^t$ un vector aleatorio. Nos interesa hallar la PDF conjunta de la representación del vector en coordenadas polares:

$$\mathbf{Y} = \begin{bmatrix} R \\ \Theta \end{bmatrix} = \begin{bmatrix} \sqrt{X_1^2 + X_2^2} \\ \arctan\left(\frac{X_2}{X_1}\right) \end{bmatrix}.$$

- Como el cambio de coordenadas cartesianas a polares es reversible, la transformación $\mathbf{Y} = \mathbf{g}(\mathbf{X})$ es reversible. La transformación inversa es

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} R \cos(\Theta) \\ R \sin(\Theta) \end{bmatrix} = \mathbf{g}^{-1}(\mathbf{Y}).$$

Ejemplo: Magnitud y ángulo de vector aleatorio II

- Primero calculamos la matriz Jacobiana y su determinante:

$$J(x_1, x_2) = \begin{bmatrix} \frac{x_1}{\sqrt{x_1^2 + x_2^2}} & \frac{x_2}{\sqrt{x_1^2 + x_2^2}} \\ \frac{-x_2}{x_1^2 + x_2^2} & \frac{x_1}{x_1^2 + x_2^2} \end{bmatrix}$$

$$\Rightarrow |\det(J(x_1, x_2))| = \frac{x_1^2 + x_2^2}{(x_1^2 + x_2^2)^{3/2}} = \frac{1}{r}.$$

- Aplicando la fórmula del método, tenemos que

$$f_{R,\Theta}(r, \theta) = r f_{X_1, X_2}(r \cos(\theta), r \sin(\theta)), \quad r \geq 0, \theta \in [0, 2\pi).$$

Transformación general suave

El método anterior también se puede aplicar a una transformación $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ con $m \neq n$ agregando variables auxiliares X_i o Y_i de forma tal que se obtenga una nueva transformación $\mathbf{h} : \mathbb{R}^p \rightarrow \mathbb{R}^p$ donde $p = \max(n, m)$.

Transformación lineal o afín (caso biyectivo)

$$\mathbf{Y} = \mathbf{AX} + \mathbf{b} \quad \det(\mathbf{A}) \neq 0$$

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{f_{\mathbf{X}}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}))}{|\det(\mathbf{A})|}$$

Suma de V.A independientes

Sean X_1, \dots, X_n independientes

Si $Y = \sum_{i=1}^n a_i X_i = \mathbf{a}^t \mathbf{X}$,

$$f_Y(y) = \frac{1}{|a_1|} f_{X_1}\left(\frac{y}{a_1}\right) * \dots * \frac{1}{|a_n|} f_{X_n}\left(\frac{y}{a_n}\right).$$

Comprobemos para que
 $f_Y(y)$ integre 1

~~WTF~~

Make love, not
convolution

Simulación de V.A.


- Todo paquete numérico tiene un algoritmo que genera muestras de una V.A uniforme. Es un generador *pseudo aleatorio*
- Pero cómo generamos muestras de una V.A. no uniforme?
- Es posible utilizar una transformación aplicada a una V.A.
 $U \sim \mathcal{U}[0, 1]$.

Simulación de V.A.: método de inversión

Montecarlo por inversión

Sea X una V.A. continua con distribución $F_X(x)$ y $U \sim \mathcal{U}[0, 1]$.

Obtenemos una realización de X utilizando una realización de $F^{-1}(U)$.



Muestreo de $\mathcal{U}[0, 1]$: $[u_1, u_2, u_3]$



Realizaciones de X : $[x_1, x_2, x_3]$

Método muy sencillo cuando se conoce F_X

Simulación de V.A.: método de inversión

Demostración:

- X continua $\implies F_X()$ estrictamente creciente. Entonces existe F_X^{-1}

$$F_X^{-1} : (0, 1) \rightarrow \mathbb{R}$$

$$\forall u, 0 < u < 1 \quad , \quad F_X^{-1}(u) = x.$$

- Recordemos que si $U \sim \mathcal{U}[0, 1]$, entonces $F_U(u) = u$.
- Luego,

$$\mathbb{P}\left[F_X^{-1}(U) \leq x\right] = \mathbb{P}(U \leq F_X(x)) = F_U(F_X(x)) = F_X(x)$$

Es decir, las realizaciones de $F_X^{-1}(U)$ están distribuidas como X .

Ejercicio

- **Ejercicio 1:** Demuestre que si $U \sim \mathcal{U}[0, 1]$, y $\lambda > 0$ luego,

Hacerlo

$$-\frac{1}{\lambda} \log(U) \sim \text{Exp}(\lambda)$$

- **Ejercicio 2: Algoritmo de Inversión para distribuciones discretas**

Sea X una V.A discreta con PMF $p_X(k)$, $k = 0, 1, \dots$ y distribución $F_X(j) = \sum_{k=0}^j p_X(k)$. Considere el siguiente pseudocódigo

- ① $j := -1$
- ② Generar $U \sim \mathcal{U}[0, 1]$
- ③ Repetir $j := j + 1$ hasta que $U < F_X(j)$
- ④ Devolver j

Demuestre que la salida del algoritmo sigue la distribución $F_X(x)$.